

BÁO CÁO KHOA HỌC: PHƯƠNG PHÁP LUẬN VÀ THIẾT KẾ KIẾN TRÚC KHAI THÁC CẶP ẢNH NỀN TĨNH VÀ PHƯƠNG TIỆN TRONG THỊ GIÁC GIAO THÔNG VỚI DINO

Nhóm Nghiên Cứu Thị Giác Máy Tính Đô Thị

Ngày 1 tháng 10 năm 2026

Tóm tắt nội dung

Trong hệ thống camera giám sát giao thông thông minh (CCTV), các camera cố định cung cấp một nguồn tín hiệu vật lý tự nhiên vô cùng quý giá: cặp ảnh quan sát bao gồm ảnh hiện trường có phương tiện giao thông và ảnh nền tĩnh sạch bóng xe được tổng hợp qua thời gian. Báo cáo này trình bày cơ sở lý thuyết, mô hình hóa toán học và phương pháp luận chuyên sâu của bốn hướng nghiên cứu tự giám sát (Self-Supervised Learning) nhằm khai thác triệt để cặp tín hiệu này. Bốn hướng nghiên cứu bao gồm: (1) Tiền huấn luyện Vision Transformer với chiến lược che có định hướng tiền cảnh (Foreground-Aware Masking); (2) Phân đoạn ngữ nghĩa phương tiện không cần nhãn (Zero-Shot Semantic Segmentation) qua dung hợp đặc trưng DINO PCA và sai khác quang học; (3) Mạng phân rã bối cảnh tự giám sát (Scene Decomposition Network) dựa trên mô hình hòa trộn Alpha Compositing; và (4) Mở rộng biểu diễn Patch Embedding 4 kênh (RGB + Δ) phục vụ bài toán đếm xe trong điều kiện ít mẫu (Few-shot learning). Tất cả các phương pháp đều được thiết kế chặt chẽ, tối ưu hóa toán học và không phụ thuộc vào nhãn gán thủ công từ con người.

1 ĐẶT VẤN ĐỀ VÀ BẢN CHẤT TÍN HIỆU QUANG HỌC VẬT LÝ

Trong giám sát giao thông đô thị bằng camera tĩnh, mỗi khung hình chụp tại một thời điểm t luôn gắn liền với hai trạng thái không gian quan sát:

- Ảnh nguồn chứa phương tiện** ($I_{\text{origin}} \in \mathbb{R}^{H \times W \times 3}$): Chứa các thực thể động (xe máy, ô tô con, xe tải, xe buýt) di chuyển trên nền tuyến đường, chịu sự thay đổi phức tạp về mật độ, góc chiếu sáng và độ che khuất lẫn nhau.
- Ảnh nền tĩnh** ($I_{\text{bg}} \in \mathbb{R}^{H \times W \times 3}$): Bề mặt lòng đường sạch hoàn toàn xe cộ, được trích xuất bằng thuật toán trung vị theo thời gian (Temporal Median Filtering) kết hợp chuẩn hóa cường độ sáng trong không gian màu HSV theo từng khung giờ quan sát trong ngày (00h – 23h).

Sự đối sánh giữa hai ảnh này xác lập một bản đồ sai khác vật lý tiên nghiệm (Physical Prior):

$$\Delta(u, v) = \|I_{\text{origin}}(u, v) - I_{\text{bg}}(u, v)\| \quad (1)$$

Thay vì chỉ sử dụng $\Delta(u, v)$ trong các thuật toán trừu tượng truyền thống vốn rất nhạy cảm với nhiễu thời tiết và bóng đổ, báo cáo này tích hợp tín hiệu Δ vào không gian biểu diễn sâu của các mô hình Vision Transformer (ViT), mở ra các hướng giải quyết mang tính đột phá cho các bài toán thị giác máy tính giao thông.

2 CƠ SỞ LÝ THUYẾT TỰ HỌC DINO: TỪ DINOv1 ĐẾN DINOv2

2.1 Bản Chất Tự Chứng Cát Tri Thức Không Nhãn (Self-Distillation With No Labels)

Mô hình tự giám sát DINO (Caron et al., ICCV 2021) vận hành dựa trên cơ chế tự chứng cát tri thức giữa hai mạng nơ-ron có cùng cấu trúc tham số: mạng **Học sinh (Student)** g_{θ_s} và mạng **Giáo viên (Teacher)** g_{θ_t} . Mỗi mạng bao gồm một bộ trích xuất đặc trưng Vision Transformer (Backbone) kết hợp với đầu chiếu đa tầng (MLP Projection Head) nhằm ánh xạ token đại diện $[CLS]$ sang không gian xác suất K chiều ($K = 4096$ hoặc 65536).

Quy trình tối ưu hóa thiết lập một sự bất đối xứng động học chặt chẽ:

1. **Cập nhật mạng Student qua Gradient Descent:** Mạng Student tiếp nhận trực tiếp dòng gradient truyền ngược từ hàm mất mát DINO Loss để tối ưu hóa vector trọng số θ_s .
2. **Cập nhật mạng Teacher qua Trung bình trượt hàm mũ (EMA):** Mạng Teacher không nhận gradient trực tiếp ($\nabla_{\theta_t} \mathcal{L} = 0$). Thay vào đó, trọng số θ_t được cập nhật chậm rãi theo hàm trung bình trượt động lượng (Momentum Encoder):

$$\theta_t \leftarrow \lambda \theta_t + (1 - \lambda) \theta_s \quad (2)$$

trong đó $\lambda \in [0.996, 1.0]$ được điều tiết tăng dần theo quy luật Cosine Schedule xuyên suốt quá trình huấn luyện. Cơ chế này đóng vai trò như một bộ tích hợp mô hình theo thời gian (Polyak-Ruppert Averaging), giúp Teacher tạo ra các phân phối xác suất bia mục tiêu ổn định và có tính khái quát hóa cao.

3. **Cơ chế chống sụp đổ biểu diễn (Collapse Prevention):** Trong học tự giám sát không có mẫu âm (Non-contrastive SSL), mô hình rất dễ rơi vào hai trạng thái suy biến: (i) Mọi ảnh đều ánh xạ ra cùng một vector hằng số, hoặc (ii) Một chiều xác suất duy nhất thống trị toàn bộ phân phối. DINO giải quyết triệt để bài toán này bằng sự kết hợp nghịch đảo giữa **Teacher Centering** và **Teacher Sharpening**:

$$P_t(x)^{(k)} = \frac{\exp\left(\frac{g_{\theta_t}(x)^{(k)} - c^{(k)}}{\tau_t}\right)}{\sum_{j=1}^K \exp\left(\frac{g_{\theta_t}(x)^{(j)} - c^{(j)}}{\tau_t}\right)}, \quad P_s(x)^{(k)} = \frac{\exp\left(\frac{g_{\theta_s}(x)^{(k)}}{\tau_s}\right)}{\sum_{j=1}^K \exp\left(\frac{g_{\theta_s}(x)^{(j)}}{\tau_s}\right)} \quad (3)$$

trong đó:

- Vector tâm $c \in \mathbb{R}^K$ được cập nhật liên tục theo mini-batch: $c \leftarrow m_c \cdot c + (1 - m_c) \frac{1}{B} \sum_{b=1}^B g_{\theta_t}(x_b)$. Phép trừ $g_{\theta_t}(x) - c$ khử độ lệch kỳ vọng, ngăn chặn một chiều tọa độ lấn át toàn thể.

- Nhiệt độ Teacher τ_t ($0.04 \rightarrow 0.07$) luôn nhỏ hơn nhiệt độ Student $\tau_s = 0.1$, tạo hiệu ứng làm nhọn phân phối xác suất (Sharpening), ngăn chặn phân phối rơi vào trạng thái sụp đổ đồng đều (Uniform Collapse).

2.2 Bước Chuyển Minh Đột Phá Từ DINOv1 Sang DINOv2

DINOv2 (Oquab et al., Meta AI 2023) đánh dấu bước nhảy vọt từ một phương pháp học đặc trưng ảnh đơn thuần thành một **Mô hình Nền tảng Thị giác (Vision Foundation Model)** với 4 cải tiến then chốt:

1. **Tích hợp song song Masked Image Modeling (MIM / iBOT):** DINOv1 chỉ tối ưu trên token đại diện toàn cục $[CLS]$. DINOv2 kế thừa kiến trúc iBOT, áp dụng cơ chế tự chưng cất đồng thời trên cả token $[CLS]$ lẫn các **Patch Tokens** bị che ngẫu nhiên. Hàm mất mát tổng hợp:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{DINO}}([CLS]) + \lambda_{\text{patch}} \mathcal{L}_{\text{iBOT}}(\text{Patch Tokens}) \quad (4)$$

nhờ đó mô hình vừa nắm bắt ngữ nghĩa cấp cao của toàn ảnh, vừa hiểu thấu đáo cấu trúc chi tiết từng điểm ảnh ở cấp độ dense patches.

2. **Hiện đại hóa kiến trúc Transformer:** DINOv2 loại bỏ hoàn toàn các lớp Batch Normalization (vốn gây rò rỉ thông tin thống kê giữa các mẫu trong batch); thay thế bằng **LayerScale** và hàm kích hoạt **SwiGLU** (Swish Gated Linear Unit), đảm bảo quá trình lan truyền gradient ổn định ở mô hình quy mô lớn (ViT-Small, Base, Large, Giant lên tới 1 tỷ tham số).
3. **Bổ sung Register Tokens:** DINOv2 bổ sung 4 token bộ nhớ ảo (Register Tokens) vào chuỗi đầu vào. Các token này có nhiệm vụ "hấp thụ" các tín hiệu kích hoạt bất thường (outliers) ở các vùng nền phẳng (bầu trời, mặt đường), giúp các Patch Tokens thực thụ bảo toàn năng lượng để mô tả chuẩn xác các vật thể nổi bật (tiền cảnh).
4. **Thích ứng đa độ phân giải (Multi-Resolution Adaptation):** DINOv2 thiết lập giao thức huấn luyện hai pha: pha pre-training diện rộng ở 224×224 (tiết kiệm tài nguyên) và pha tinh chỉnh ngắn hạn ở 518×518 (chuẩn hóa độ phân giải cao).

2.3 Chiến Lược Đa Góc Nhìn (Multi-Crop Strategy) và Các Đặc Tính Không Gian

Trái tim của cơ chế tự giám sát DINO là việc giải bài toán **"Học từ bộ phận đến toàn cảnh" (Part-to-Whole correspondence)** thông qua chiến lược Multi-crop:

1. **Phân loại các góc nhìn (Crops):** Từ mỗi khung hình quan sát x , hệ thống trích xuất V góc nhìn con:
 - **2 Global Crops ($x_g^{(1)}, x_g^{(2)}$):** Cắt ngẫu nhiên với tỷ lệ diện tích lớn $S_g \in [0.4, 1.0]$ của ảnh gốc, sau đó chuẩn hóa về kích thước 224×224 . Chứa đựng bối cảnh không gian tổng thể của tuyến đường và phương tiện. **Chỉ mạng Teacher được quyền nhìn thấy các Global crops này.**

- N_l **Local Crops** $(x_l^{(1)}, \dots, x_l^{(N_l)})$ (**mặc định** $N_l = 4$): Cắt ngẫu nhiên với diện tích nhỏ $S_l \in [0.05, 0.4]$, chuẩn hóa về kích thước 98×98 (đối với ViT patch-14, $98 = 7 \times 14$). Góc nhìn này zoom cận cảnh vào các cấu kiện cục bộ (bánh xe, đầu xe, gương chiếu hậu). **Mạng Student bắt buộc phải nhìn cả Global crops lẫn Local crops.**

2. **Bản chất toán học của chỉ số IoU giữa các góc nhìn:** Trong DINO, các góc nhìn được cắt **hoàn toàn ngẫu nhiên và độc lập (Unconditioned Independent Crops)**, không áp đặt điều kiện ràng buộc ngưỡng IoU.

Xét hai Global crops có diện tích tương đối $S_1, S_2 \in [0.4, 1.0]$. Theo nguyên lý hình học Dirichlet, do cả hai vùng cùng chiếm tỷ lệ lớn trên khung hình, xác suất để chúng giao thoa không gian $(A(x_g^{(1)}) \cap A(x_g^{(2)})) \neq \emptyset$ là áp đảo, với kỳ vọng toán học:

$$\mathbb{E}[\text{IoU}(x_g^{(1)}, x_g^{(2)})] \in [0.15, 0.60] \quad (5)$$

Việc không cố định IoU mang ý nghĩa bản chất:

- Nếu ép IoU ≈ 1.0 : Hai góc nhìn gần như trùng khít, mô hình sẽ học "lối tắt tầm thường" (trivial shortcut) bằng cách ghi nhớ điểm ảnh thay vì học ngữ nghĩa trừu tượng.
- Nếu IoU $\rightarrow 0$ (hai góc nhìn ở hai vị trí xa nhau trên xe buýt): Student bị ép phải liên kết thông tin cục bộ ở đầu xe với bối cảnh đuôi xe của Teacher, thúc đẩy hình thành tri thức ngữ cảnh toàn cục mạnh mẽ.

3. **Cơ chế xử lý ảnh đầu vào có kích thước nhỏ hơn ($< 224 \times 224$):** Khi ảnh đầu vào có độ phân giải thấp hơn 224×224 (ví dụ camera đường truyền yếu 160×120), toán tử 'RandomResizedCrop' thực hiện hai công đoạn: (i) Cắt vùng theo tỷ lệ diện tích S , và (ii) Phóng to vùng cắt đó lên chính xác 224×224 bằng thuật toán **Nội suy Bicubic bậc cao (Bicubic Upsampling)**. Nhờ tính liên tục của hàm cơ sở Bicubic, tensor đầu ra đưa vào ViT luôn có kích thước chuẩn $(3, 224, 224)$. Trong hệ thống camera giám sát thực tế (CCTV TP.HCM), độ phân giải thực luôn từ $720p \rightarrow 1080p$, do đó thao tác thực chất là phép lấy mẫu thu nhỏ (Downsampling) giúp loại bỏ nhiễu cảm biến và nén giữ tín hiệu trung thực nhất.

2.4 Cơ Chế Ghép Batch và Hàm Mất Mát DINO Cross-Entropy

Một hiểu lầm phổ biến trong triển khai là ghép nhiều ảnh theo chiều kênh (Channel concatenation). DINO thiết lập quy tắc kiến trúc chuẩn mực:

1. **Tuyệt đối không ghép theo chiều Kênh (Channel):** Lớp chiếu đầu vào của Vision Transformer là một phép biến đổi tuyến tính $W_{\text{patch}} \in \mathbb{R}^{D \times (P^2 \cdot C)}$ với số kênh cố định $C = 3$ (RGB). Nếu ghép V ảnh theo chiều channel ($C = 3V$), mô hình sẽ gặp lỗi bất tương thích chiều, đồng thời việc ép các ảnh chồng đè lên nhau tại cùng tọa độ pixel sẽ phá hủy hoàn toàn cấu trúc không gian hình học.
2. **Ghép theo chiều Mẫu (Batch Dimension):** Tất cả các góc nhìn của B khung hình trong mini-batch được xếp chồng dọc theo chiều thứ nhất ('dim=0'), tạo thành siêu tensor:

$$X_{\text{global}} \in \mathbb{R}^{(B \times 2) \times 3 \times 224 \times 224} \quad (6)$$

$$X_{\text{local}} \in \mathbb{R}^{(B \times N_l) \times 3 \times 98 \times 98} \quad (7)$$

Mỗi ảnh con được xử lý độc lập và song song qua ViT như một phần tử riêng biệt, xuất ra $B \times 2$ vector đặc trưng Teacher và $B \times (2 + N_l)$ vector đặc trưng Student.

3. **Hàm mất mát so khớp chéo (Cross-Entropy Matching):** Hàm mất mát DINO Loss tính toán độ lệch entropy chéo giữa 2 góc nhìn toàn cảnh của Teacher và toàn bộ các góc nhìn của Student (loại trừ trường hợp so khớp với chính nó):

$$\mathcal{L}_{\text{DINO}} = \frac{1}{2} \sum_{i=1}^2 \sum_{\substack{v=1 \\ v \neq i}}^{2+N_l} H\left(P_t(x_g^{(i)}), P_s(x^{(v)})\right) \quad (8)$$

trong đó $H(p, q) = -\sum_{k=1}^K p^{(k)} \log q^{(k)}$.

Cơ sở lý thuyết vững chắc này tạo tiền đề khoa học để tích hợp bản đồ sai khác vật lý Δ vào quá trình huấn luyện, tạo nên mô hình BG-Guided DINO vượt trội trong các phần tiếp theo.

3 HƯỚNG 1: BG-GUIDED DINO – TIỀN HUẤN LUYỆN TỰ GIÁM SÁT LIÊN TỤC VỚI FOREGROUND-AWARE MASKING

3.1 Hạn Chế của Cơ Chế Che Ngẫu Nhiên Đồng Đều

Trong các mô hình nền tảng tự giám sát hiện nay (DINOv2, DINOv3, Masked Autoencoders), chiến lược che ảnh (Masking) được áp dụng theo phân phối ngẫu nhiên đồng đều (Uniform Random Masking).

Tuy nhiên, trong bối cảnh camera giao thông đô thị:

- Hơn 70% – 80% diện tích khung hình là nền đường bê tông, nhựa đường, vạch kẻ sơn và vỉa hè cố định.
- Phương tiện giao thông chỉ chiếm từ 20% – 30% diện tích nhưng chứa đựng toàn bộ thông tin ngữ nghĩa quan trọng phục vụ giám sát và điều hành.
- Nếu che ngẫu nhiên đồng đều, phần lớn các patch bị che sẽ rơi vào mặt đường. Mô hình Vision Transformer bị lãng phí dung lượng biểu diễn và gradient cập nhật chỉ để học tái tạo lại các mảng nhựa đường vô nghĩa.

3.2 Cơ Sở Toán Học của Chiến Lược Che Foreground-Aware Masking (FAM)

Ảnh được chia thành $N_{\text{patches}} = \left(\frac{H}{P}\right) \times \left(\frac{W}{P}\right)$ patch rời rạc kích thước $P \times P$ (mặc định $P = 16$).

Bản đồ sai khác Δ được tính toán trong không gian màu CIE-LAB nhằm hạn chế ảnh hưởng của biến thiên độ sáng:

$$\Delta(u, v) = 0.5 \cdot \frac{|L_{\text{origin}} - L_{\text{bg}}|}{255} + 0.25 \cdot \frac{|a_{\text{origin}} - a_{\text{bg}}|}{255} + 0.25 \cdot \frac{|b_{\text{origin}} - b_{\text{bg}}|}{255} \quad (9)$$

Trọng số sai khác trung bình của patch thứ p được định nghĩa:

$$w_p = \frac{1}{P^2} \sum_{(u,v) \in \text{Patch}_p} \Delta(u, v) \quad (10)$$

Xác suất để một patch p được chọn để che được mô hình hóa theo công thức nội suy tuyến tính:

$$P_{\text{mask}}(p) = \alpha \cdot \frac{w_p}{\max_q w_q + \epsilon} + (1 - \alpha) \cdot \frac{1}{N_{\text{patches}}} \quad (11)$$

trong đó $\epsilon = 10^{-8}$ là hằng số chống chia cho 0 và $\alpha \in [0, 1]$ là hệ số cân bằng (chọn $\alpha = 0.75$).

3.3 Lý Giải Bản Chất Toán Học của Công Thức Xác Suất Che

Công thức (11) được thiết kế dựa trên nguyên lý cân bằng giữa Khai thác (Exploitation) và Thăm dò (Exploration) trong lý thuyết quyết định:

1. **Thành phần Khai thác Tiền cảnh** $\frac{w_p}{\max_q w_q + \epsilon}$ (**Foreground Exploitation Term**): Đóng vai trò là hàm mật độ nổi bật (Saliency Density). Phép chuẩn hóa cục bộ chia cho $\max_q w_q$ đưa cường độ biến động quang học của mọi patch về miền $[0, 1]$. Những patch chứa thân xe, đầu xe có độ sai khác lớn so với nền đường sẽ có $w_p \approx \max_q w_q$, khiến xác suất bị che đạt giá trị cực đại. Khi vùng xe bị che, mạng Student bị tước đi tín hiệu trực tiếp và bắt buộc phải học mối tương quan ngữ cảnh xung quanh để suy diễn ra phương tiện.
2. **Thành phần Thăm dò Nền** $\frac{1}{N_{\text{patches}}}$ (**Background Exploration Term**): Đây là phân phối đều tiên nghiệm (Uniform Prior). Nếu chọn $\alpha = 1.0$ (chỉ che theo Δ), hệ thống sẽ gặp hai lỗi nghiêm trọng:
 - *Sụp đổ ngữ cảnh nền (Background Context Collapse)*: Nền đường không bao giờ bị che, khiến mô hình bỏ qua việc học mối quan hệ không gian giữa lòng đường và xe cộ.
 - *Hiện tượng suy biến khi vắng xe*: Ban đêm hoặc khi đường vắng, $w_p \approx 0$ ở mọi patch, khiến phép chia mất ổn định số học hoặc không chọn đủ số lượng patch cần che. Phân phối đều đảm bảo luôn có một baseline ngẫu nhiên tối thiểu.
3. **Ý nghĩa lựa chọn $\alpha = 0.75$** : Đây là tỷ lệ điều tiết tối ưu: 75% ngân sách che ưu tiên tập trung vào vùng phương tiện (nơi chứa đặc trưng giao thông cốt lõi), trong khi 25% ngân sách che duy trì việc thăm dò ngẫu nhiên toàn diện khung hình.

3.4 Bản Chất Chiến Lược Multi-Crop: Global Views và Local Views

Kiến trúc tự chứng cất tri thức DINO vận hành dựa trên cơ chế đối sánh Multi-Crop:

- **Global Views (Góc nhìn toàn cảnh)**: Kích thước 224×224 pixel, cắt diện tích lớn từ 40% đến 100% khung hình gốc. Hệ thống sinh ra 2 Global Views (V_1^g, V_2^g). Teacher Network nhận Global Views ở trạng thái **nguyên bản không bị che (Unmasked)** để thiết lập mỏ neo ngữ nghĩa chuẩn (Semantic Ground-Truth Representation). Student Network nhận Global Views bị che bởi mặt nạ FAM.

- **Local Views (Góc nhìn chi tiết cục bộ):** Kích thước nhỏ 96×96 pixel, cắt phạm vi hẹp từ 5% đến 40% diện tích ảnh gốc, tập trung vào các chi tiết cấu trúc vi mô (bánh xe, biển số, đèn pha). Chỉ duy nhất Student Network được nhận các Local Views ($V_1^l, \dots, V_4^l$); Teacher hoàn toàn không nhận nhằm tiết kiệm bộ nhớ GPU và chống trôi dạt ngữ nghĩa.
- **Nguyên lý Chứng cất Cục bộ – Toàn thể (Local-to-Global Correspondence):** Hàm mất mát ép Student dù chỉ nhìn một mảnh cắt nhỏ 96×96 vẫn phải dự đoán ra phân bố xác suất ngữ nghĩa của toàn bộ khung cảnh lớn 224×224 mà Teacher quan sát:

$$\mathcal{L}_{\text{DINO}} = - \sum_{x \in \{V^g, V^l\}} \sum_{x' \in \{V_1^g, V_2^g\}, x' \neq x} P_t(x') \log P_s(x) \quad (12)$$

Nhờ đó, mô hình tự động trừu tượng hóa mối quan hệ giữa “bộ phận” và “tổng thể” mà hoàn toàn không cần nhãn.

4 HƯỚNG 2: ZERO-SHOT VEHICLE SEMANTIC SEGMENTATION

4.1 Đặt Vấn Đề

Gán nhãn mặt nạ phân đoạn pixel cho dữ liệu giao thông thực tế đòi hỏi chi phí nhân công khổng lồ. Hướng nghiên cứu này giải quyết bài toán: Tự động tạo ra mặt nạ phân đoạn pixel chính xác cho phương tiện mà hoàn toàn không cần con người gán nhãn thủ công (Zero-Shot), bằng cách dung hợp tín hiệu quang học cấp thấp với đặc trưng ngữ nghĩa sâu của DINO.

4.2 Cơ Chế Bù Trừ Giữa Tín Hiệu Vật Lý và Ngữ Nghĩa Sâu

Hệ thống kết hợp hai nhánh tín hiệu bù trừ hoàn hảo cho nhau:

1. **Nhánh Vật lý (Δ -Mask):** Phép trừ nền LAB kết hợp phân ngưỡng Otsu tự động và hình thái học (Morphological Open 5×5 , Close 11×11).
 - *Ưu điểm:* Bắt đường biên chuyển động chính xác đến từng pixel.
 - *Nhược điểm:* Luôn bị dính bóng đổ của xe in xuống mặt đường vì bóng đổ làm giảm độ sáng so với nền tĩnh.
2. **Nhánh Ngữ nghĩa (DINOv3 PCA PC1):** Trích xuất ma trận patch tokens $X \in \mathbb{R}^{N_{\text{patches}} \times D}$ ở tầng Transformer cuối cùng và chiếu lên thành phần chính thứ nhất (PC1) thông qua phép phân tích thành phần chính (PCA):

$$(X - \bar{X}) = U\Sigma V^T \implies \mathbf{z}_{\text{PC1}} = (X - \bar{X})v_1 \quad (13)$$

- *Ưu điểm:* Cơ chế Self-Attention của DINO gom cụm các patch theo ngữ nghĩa đối tượng. PC1 **hoàn toàn không bị đánh lừa bởi bóng đổ** vì bóng đổ về bản chất ngữ nghĩa sâu vẫn là bề mặt nhựa đường.
- *Nhược điểm:* Độ phân giải thô theo kích thước patch (14×14).

4.3 Động Cơ Dung Hợp (Mask Fusion Engine)

Sự kết hợp giao thoa giữa hai nhánh loại bỏ hoàn toàn các lỗi sai sót:

$$M_{\text{fused}} = \text{BilateralFilter}\left(M_{\Delta} \cap \text{Threshold}(\text{Resize}(\mathbf{z}_{\text{PC1}}))\right) \quad (14)$$

Phép giao thoa $\cap$ loại bỏ 100% bóng đổ mặt đường và dao động nền giả (lá cây, nước mưa). Sau đó, bộ lọc song phương (Bilateral Filter) khôi phục đường viền sắc nét theo độ tương phản cục bộ của ảnh gốc. Nhãn giả chất lượng cao này được sử dụng để huấn luyện mạng phân đoạn siêu nhẹ (Lightweight SegHead) đạt tốc độ thực thi trên 60 FPS tại thiết bị biên.

—

5 HƯỚNG 3: SELF-SUPERVISED SCENE DECOMPOSITION NETWORK

5.1 Mô Hình Hóa Vật Lý Alpha Compositing

Một khung cảnh giao thông quan sát được mô hình hóa theo phương trình hòa trộn quang học:

$$I_{\text{origin}} = M_{\alpha} \odot I_{\text{fg}} + (1 - M_{\alpha}) \odot I_{\text{bg}} \quad (15)$$

trong đó:

- $I_{\text{bg}} \in \mathbb{R}^{H \times W \times 3}$: Lớp nền đường sạch hoàn toàn xe cộ.
- $I_{\text{fg}} \in \mathbb{R}^{H \times W \times 3}$: Lớp chứa các thực thể phương tiện cô lập.
- $M_{\alpha} \in [0, 1]^{H \times W \times 1}$: Mặt nạ mờ trong suốt (Alpha Matte) thể hiện mức độ chiếm dụng không gian của phương tiện.

Thông thường, việc phân rã một ảnh duy nhất I_{origin} thành cả 3 thành phần $\{I_{\text{bg}}, I_{\text{fg}}, M_{\alpha}\}$ là bài toán nghịch đảo vô nghiệm xác định (Ill-posed Inverse Problem).

5.2 Đóng Góp Khoa Học và Hàm Mất Mát Đa Mục Tiêu

Đóng góp cốt lõi của hướng nghiên cứu này là sử dụng ảnh nền thật $I_{\text{bg_real}}$ (tổng hợp qua Temporal Median) làm mỏ neo vật lý giám sát tự thân. Mạng nơ-ron sử dụng chung Vision Transformer Encoder và phân rã thành ba đầu giải mã (Background Head, Foreground Head, Alpha Head).

Hàm mục tiêu tối ưu hóa toàn diện gồm 4 thành phần ràng buộc:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{rec}} \mathcal{L}_{\text{recon}} + \lambda_{\text{bg}} \mathcal{L}_{\text{bg}} + \lambda_{\text{sparse}} \mathcal{L}_{\text{sparse}} + \lambda_{\text{tv}} \mathcal{L}_{\text{tv}} \quad (16)$$

1. **Mất mát Tái tạo ($\mathcal{L}_{\text{recon}}$):** Kết hợp khoảng cách L_1 và chỉ số tương đồng cấu trúc SSIM ép ảnh hòa trộn tái tạo hoàn hảo ảnh gốc:

$$\mathcal{L}_{\text{recon}} = \|I_{\text{origin}} - \hat{I}_{\text{origin}}\|_1 + (1 - \text{SSIM}(I_{\text{origin}}, \hat{I}_{\text{origin}})) \quad (17)$$

2. **Mất mát Mỏ neo Nền Thật ($\mathcal{L}_{\text{bg}}$):** Khóa chặt đầu ra của Decoder nền vào cấu trúc lòng đường tĩnh:

$$\mathcal{L}_{\text{bg}} = \|\hat{I}_{\text{bg}} - I_{\text{bg_real}}\|_1 \quad (18)$$

ràng buộc Decoder phương tiện (I_{fg}) và Alpha (M_α) phải hấp thụ toàn bộ phần sai khác chuyển động.

3. **Ràng buộc Thừa Diện tích ($\mathcal{L}_{\text{sparsity}}$):** Chuẩn hóa L_1 trên mặt nạ Alpha:

$$\mathcal{L}_{\text{sparsity}} = \frac{1}{H \cdot W} \sum_{u=1}^H \sum_{v=1}^W M_\alpha(u, v) \quad (19)$$

ngăn ngừa nghiệm suy biến (nghiệm gán $M_\alpha = 1$ ở mọi nơi và sao chép toàn bộ ảnh gốc vào I_{fg}).

4. **Làm mịn Total Variation ($\mathcal{L}_{\text{tv}}$):** Khử nhiễu đốm hạt tiêu và viền răng cưa quanh thân xe:

$$\mathcal{L}_{\text{tv}} = \frac{1}{H \cdot W} \sum_{u,v} \left(|M_\alpha(u+1, v) - M_\alpha(u, v)| + |M_\alpha(u, v+1) - M_\alpha(u, v)| \right) \quad (20)$$

Mô hình cho phép thực hiện bài toán **Tự động xóa xe cộ trên đường (Inpainting)** trực tiếp từ một khung hình duy nhất mà không cần kỹ thuật vá ảnh thủ công.

—

6 HƯỚNG 4: FOREGROUND-ENHANCED TRAFFIC COUNTING

6.1 Cấu Trúc Tensor Đầu Vào 4 Kênh

Bài toán ước lượng lưu lượng phương tiện (đếm số lượng xe máy, ô tô con và tổng số xe) gặp thách thức lớn khi mật độ phương tiện ken đặc che khuất lẫn nhau và trong điều kiện học ít mẫu (Few-shot learning: 5%, 10%, 20% nhãn).

Thay vì chỉ sử dụng 3 kênh RGB thông thường, tensor đầu vào được mở rộng thành 4 kênh:

$$X_{4\text{ch}} = [\text{R}, \text{G}, \text{B}, \Delta_{\text{norm}}] \in \mathbb{R}^{4 \times H \times W} \quad (21)$$

trong đó kênh thứ 4 là bản đồ sai khác vật lý được chuẩn hóa:

$$\Delta_{\text{norm}} = \frac{\Delta - 0.5}{0.5} \in [-1.0, 1.0] \quad (22)$$

6.2 Kỹ Thuật Khởi Tạo Thích Ứng Ấm (Warm-Start Initialization)

Lớp Patch Embedding trong Vision Transformer biến đổi patch $P \times P$ thành vector D chiều có trọng số $W_{4\text{ch}} \in \mathbb{R}^{D \times 4 \times P \times P}$. Nếu khởi tạo ngẫu nhiên kênh thứ 4, nhiễu loạn activation ban đầu sẽ phá hủy toàn bộ tri thức tiền huấn luyện sâu của DINOv3.

Thuật toán khởi tạo thích ứng âm được áp dụng:

$$W_{4ch}[:, 0 : 3, :, :] = W_{\text{pretrained}} \quad (23)$$

$$W_{4ch}[:, 3, :, :] = \frac{1}{3} \sum_{c=0}^2 W_{\text{pretrained}}[:, c, :, :] \quad (24)$$

Ba kênh đầu giữ nguyên 100% các bộ lọc trích xuất cạnh và kết cấu đã học. Kênh thứ 4 lấy trung bình cộng cường độ của ba kênh RGB, đảm bảo tại epoch 0 kênh Δ đóng góp năng lượng đồng nhất vào hàm kích hoạt mà không làm sốc gradient.

6.3 Chiến Lược Đánh Giá Spatial Disjoint

Tập dữ liệu được phân chia theo danh sách Camera ID độc lập (camera dùng huấn luyện không bao giờ xuất hiện trong tập kiểm thử), loại bỏ hoàn toàn hiện tượng rò rỉ dữ liệu (Data Leakage) do nền đường giống nhau giữa các frame kế tiếp. Mô hình đánh giá khách quan năng lực tổng quát hóa của kênh Δ trên các góc nhìn tuyến đường hoàn toàn mới.

7 BẢNG TỔNG HỢP SO SÁNH 4 HƯỚNG NGHIÊN CỨU

Bảng 1: Tổng hợp so sánh phương pháp luận và đóng góp khoa học của 4 hướng nghiên cứu

Hướng	Tên Nghiên Cứu	Cơ Chế Cốt Lõi	Độ Mới	Venue Đề Xuất
Hướng 1	BG-Guided DINO Continual SSL	Foreground-Aware Masking (FAM) ép ViT che và học biểu diễn phương tiện	4/5	IEEE T-ITS, EAAI, Pattern Recognition
Hướng 2	Zero-Shot Vehicle Segmentation	Dùng hợp tín hiệu bù trừ Δ -Mask $\cap$ DINOv3 PCA PC1	3/5	CVPR Workshop, PR Letters
Hướng 3	Scene Decomposition Network	Mô hình hóa Alpha Compositing với mô neo giám sát nền thật	5/5	CVPR, ECCV, NeurIPS
Hướng 4	Foreground-Enhanced Counting	Mở rộng Patch Embed 4 kênh (RGB+ Δ) kết hợp Warm-Start	2.5/5	EAAI Journal

8 KẾT LUẬN

Bốn hướng nghiên cứu được trình bày xác lập một chu trình khoa học khép kín và có tính tương hỗ sâu sắc: Hướng 1 nâng cấp bộ trích xuất đặc trưng ViT chuyên biệt cho giao thông; Hướng 2 giải quyết điểm nghẽn thiếu hụt dữ liệu gán nhãn pixel; Hướng 3 mở ra đột phá lý thuyết về phân rã vật lý quang học và xóa xe tự động; trong khi Hướng 4 giải quyết trực tiếp bài toán đo lường

lưu lượng thực tế với độ chính xác cao. Toàn bộ phương pháp luận đều lấy nền tảng từ việc khai thác thông minh cặp ảnh nền tĩnh và ảnh hiện trường từ hệ thống camera quan sát đô thị.