

BÁO CÁO KHOA HỌC: PHƯƠNG PHÁP LUẬN VÀ THIẾT KẾ KIẾN TRÚC KHAI THÁC CẬP ẢNH NỀN TĨNH VÀ PHƯƠNG TIỆN TRONG THỊ GIÁC GIAO THÔNG VỚI DINO

Nhóm Nghiên Cứu Thị Giác Máy Tính Đô Thị

Ngày 1 tháng 10 năm 2026

Tóm tắt nội dung

Trong hệ thống camera giám sát giao thông thông minh (CCTV), các thiết bị thu hình cố định cung cấp cặp tín hiệu quang học bổ trợ: ảnh hiện trường ghi nhận phương tiện di chuyển và ảnh nền tĩnh (background) được ước lượng qua chuỗi thời gian. Báo cáo này trình bày cơ sở lý thuyết, mô hình hóa toán học và phương pháp luận của chín hướng nghiên cứu học tự giám sát (Self-Supervised Learning) nhằm khai thác cặp tín hiệu trên. Các nội dung chính bao gồm: (1) Tiền huấn luyện Vision Transformer với chiến lược che có định hướng tiền cảnh (Foreground-Aware Masking); (2) Phân đoạn ngữ nghĩa phương tiện không cần nhãn (Zero-Shot Semantic Segmentation) thông qua kết hợp đặc trưng DINO PCA và sai khác quang học; (3) Mạng phân rã bối cảnh tự giám sát (Scene Decomposition Network) dựa trên mô hình hòa trộn Alpha Compositing; và (4) Mở rộng biểu diễn Patch Embedding bốn kênh (RGB + Δ) phục vụ bài toán ước lượng lưu lượng phương tiện trong điều kiện ít mẫu (Few-shot learning). Các phương pháp đề xuất hướng tới tính tối ưu về mặt tính toán và giảm thiểu sự phụ thuộc vào dữ liệu gán nhãn thủ công.

1 ĐẶT VẤN ĐỀ VÀ MÔ HÌNH HÓA TÍN HIỆU QUANG HỌC

Trong bài toán giám sát giao thông đô thị qua camera tĩnh, mỗi khung hình tại thời điểm t được xem xét dưới hai trạng thái quan sát:

- Khung hình hiện trường** ($I_{\text{origin}} \in \mathbb{R}^{H \times W \times 3}$): Ghi nhận các phương tiện giao thông (xe máy, ô tô, xe buýt, xe tải) chuyển động trên bề mặt tuyến đường, kèm theo các yếu tố biến đổi về mật độ, điều kiện chiếu sáng và mức độ che khuất lẫn nhau.
- Ảnh nền tĩnh** ($I_{\text{bg}} \in \mathbb{R}^{H \times W \times 3}$): Thể hiện cấu trúc mặt đường khi không có phương tiện, được ước lượng thông qua thuật toán lọc trung vị theo thời gian (Temporal Median Filtering) kết hợp chuẩn hóa cường độ trong không gian màu HSV theo từng chu kỳ quan sát.

Mối quan hệ không gian giữa hai khung hình xác lập trường sai khác quang học:

$$\Delta(u, v) = \|I_{\text{origin}}(u, v) - I_{\text{bg}}(u, v)\| \quad (1)$$

Thay vì chỉ áp dụng $\Delta(u, v)$ trong các thuật toán phân đoạn ngưỡng cổ điển vốn nhạy cảm với biến thiên thời tiết và bóng đổ, báo cáo tích hợp tín hiệu sai khác vật lý này vào không gian biểu diễn sâu của Vision Transformer (ViT), tạo tiền đề phát triển các thuật toán phân tích giao thông tự động.

2 CƠ SỞ PHƯƠNG PHÁP LUẬN: MÔ HÌNH HỌC TỰ GIÁM SÁT DINO VÀ SỰ TIẾN HÓA KIẾN TRÚC

3 CƠ SỞ PHƯƠNG PHÁP LUẬN VỀ HỌC TỰ GIÁM SÁT DINO

3.1 Cơ Chế Chứng Cát Tự Thân và Động Học Ổn Định Biểu Diễn

Kiến trúc DINO (Caron et al., ICCV 2021) dựa trên nguyên lý tự chưng cất tri thức (self-distillation) giữa hai mạng nơ-ron có cấu trúc tham số tương đồng: mạng Student g_{θ_s} và mạng Teacher g_{θ_t} . Mỗi mạng bao gồm một bộ trích xuất đặc trưng Vision Transformer (ViT) kết hợp đầu chiếu phi tuyến đa tầng (MLP Projection Head) nhằm ánh xạ vector đặc trưng $[CLS]$ sang không gian phân phối xác suất K chiều ($K \in \{4096, 65536\}$).

Hệ thống tối ưu hóa vận hành theo quy tắc cập nhật tham số bất đối xứng:

1. **Tối ưu hóa Student qua lan truyền ngược:** Tham số θ_s được cập nhật trực tiếp bằng thuật toán tối ưu hóa ngẫu nhiên (SGD hoặc AdamW) dựa trên độ dốc của hàm mất mát entropy chéo giữa đầu ra Student và Teacher.
2. **Cập nhật Teacher theo trung bình trượt hàm mũ (EMA):** Trọng số của Teacher không tiếp nhận trực tiếp gradient ($\nabla_{\theta_t} \mathcal{L} = 0$), mà tiến hóa theo trung bình trượt động lượng từ tham số Student:

$$\theta_t \leftarrow \lambda \theta_t + (1 - \lambda) \theta_s \quad (2)$$

trong đó hệ số động lượng $\lambda \in [0.996, 1.0]$ được điều chỉnh tăng dần theo lịch trình cosin. Về mặt giải tích, cơ chế EMA đóng vai trò như bộ lọc thông thấp trong không gian tham số (Polyak-Ruppert Averaging), giúp mạng Teacher cung cấp phân phối xác suất mục tiêu ổn định và có phương sai thấp qua các bước huấn luyện.

3. **Cơ chế kiểm soát sự sụp đổ biểu diễn (Representation Collapse Prevention):** Trong các mô hình học tự giám sát không sử dụng mẫu âm (non-contrastive SSL), hàm mục tiêu có nguy cơ suy biến về hai trạng thái: (i) sụp đổ hằng số (mọi đầu vào đều cho ra cùng một vector đặc trưng), hoặc (ii) sụp đổ đơn chiều (một chiều tọa độ chiếm ưu thế tuyệt đối trong phân phối). DINO kiểm soát hai trạng thái suy biến này bằng việc kết hợp kỹ thuật định tâm (*Centering*) và kỹ thuật làm nhọn phân phối (*Sharpening*):

$$P_t(x)^{(k)} = \frac{\exp\left(\frac{g_{\theta_t}(x)^{(k)} - c^{(k)}}{\tau_t}\right)}{\sum_{j=1}^K \exp\left(\frac{g_{\theta_t}(x)^{(j)} - c^{(j)}}{\tau_t}\right)}, \quad P_s(x)^{(k)} = \frac{\exp\left(\frac{g_{\theta_s}(x)^{(k)}}{\tau_s}\right)}{\sum_{j=1}^K \exp\left(\frac{g_{\theta_s}(x)^{(j)}}{\tau_s}\right)} \quad (3)$$

trong đó:

- Vector định tâm $c \in \mathbb{R}^K$ ước lượng kỳ vọng bậc một của phân phối đầu ra Teacher, được cập nhật đệ quy theo từng mini-batch: $c \leftarrow m_c \cdot c + (1 - m_c) \frac{1}{B} \sum_{b=1}^B g_{\theta_t}(x_b)$. Việc dịch chuyển gốc tọa độ kích hoạt thông qua $g_{\theta_t}(x) - c$ giúp phân phối năng lượng đồng đều, ngăn chặn hiện tượng co cụm vào một chiều thành phần.
- Nhiệt độ Teacher $\tau_t \in [0.04, 0.07]$ được thiết lập nhỏ hơn nhiệt độ Student $\tau_s = 0.1$, tạo hiệu ứng làm nhọn phân phối xác suất, ngăn chặn xu hướng entropy tiến tới cực đại (sụp đổ về phân phối đều).

3.2 Sự Phát Triển Kiến Trúc Từ DINOv1 Đến DINOv2

DINOv2 (Oquab et al., Meta AI 2023) mở rộng khung lý thuyết DINO từ việc học biểu diễn toàn cục $[CLS]$ thành mô hình nền tảng thị giác (Vision Foundation Model) có khả năng sinh biểu diễn dày đặc (dense representations) ở cấp độ từng patch, với các cải tiến kiến trúc then chốt:

1. **Cơ chế học đa nhiệm tích hợp Masked Image Modeling (MIM / iBOT):** DINOv2 kết hợp đồng thời việc tự chứng cất token toàn cục $[CLS]$ với bài toán phục hồi biểu diễn của các patch bị che ngẫu nhiên:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{DINO}}([CLS]) + \lambda_{\text{patch}} \mathcal{L}_{\text{iBOT}}(\text{Patch Tokens}) \quad (4)$$

Nhờ đó, mô hình đồng thời nắm bắt được ngữ nghĩa cấp cao ở cấp độ khung cảnh và đặc trưng không gian chi tiết ở từng patch $P \times P$.

2. **Ổn định hóa truyền gradient trên mô hình quy mô lớn:** DINOv2 loại bỏ các lớp phụ thuộc mở dữ liệu; áp dụng chuẩn hóa tiền vị tử (Pre-LayerNorm), hệ số co giãn tầng LayerScale nhằm hạn chế bùng nổ gradient khi tăng số tầng, và thay thế hàm kích hoạt GELU bằng hàm cổng phi tuyến SwiGLU (Swish Gated Linear Unit).
3. **Khử nhiễu đặc trưng cục bộ qua Register Tokens:** Ở các mô hình ViT sâu, các vùng ảnh đồng nhất (như mặt đường hoặc bầu trời) có xu hướng tích lũy các kích hoạt ngoại lai có chuẩn L_2 lớn. DINOv2 bổ sung 4 register tokens vào chuỗi đầu vào để hấp thụ các tín hiệu kích hoạt dư thừa này, giúp bảo toàn tính phân tách và chất lượng biểu diễn của các patch tokens đối với đối tượng tiền cảnh.
4. **Huấn luyện thích ứng đa độ phân giải (Multi-Resolution Training):** Mô hình thực hiện tiền huấn luyện trên lưới 224×224 để tối ưu hóa hiệu năng tính toán, sau đó tinh chỉnh ở giai đoạn cuối với độ phân giải cao 518×518 (tương ứng lưới 37×37 patches kích thước 14×14).

3.3 Chiến Lược Trích Xuất Đa Góc Nhìn (Multi-Crop) và Phân Tích Hình Học Không Gian

Chiến lược đa góc nhìn (Multi-crop strategy) thiết lập bài toán tối ưu hóa tương quan giữa các phần cấu thành và thực thể toàn cục (Part-to-Whole correspondence):

1. **Phân loại và cấu hình các góc nhìn:** Từ mỗi khung hình quan sát $I \in \mathbb{R}^{H_0 \times W_0 \times 3}$, toán tử lấy mẫu sinh ra tập hợp $V = N_g + N_l$ góc nhìn con:

- $N_g = 2$ **góc nhìn toàn cảnh (Global Crops – $x_g^{(1)}, x_g^{(2)}$):** Có tỷ lệ diện tích $s_g \in [0.4, 1.0]$ so với ảnh gốc, được chuẩn hóa về kích thước 224×224 . Các góc nhìn này được nạp vào cả mạng Teacher và mạng Student.
- $N_l = 4$ **đến 8 góc nhìn cục bộ (Local Crops – $x_l^{(1)}, \dots, x_l^{(N_l)}$):** Có tỷ lệ diện tích $s_l \in [0.05, 0.4]$, chuẩn hóa về kích thước 98×98 (đối với patch size $P = 14$, tương ứng 7×7 patches). Các góc nhìn này chỉ được nạp vào mạng Student nhằm tiết kiệm chi phí tính toán và bộ nhớ GPU.

2. **Phân tích độ giao thoa không gian (IoU) giữa hai góc nhìn toàn cảnh:** Trong pipeline chuẩn của DINO, hai vùng cắt toàn cảnh được lấy mẫu độc lập ngẫu nhiên (Uniform Random Sampling) trên không gian tọa độ hợp lệ, không áp đặt ràng buộc tiên nghiệm về điều kiện giao thoa $\text{IoU} \geq \tau$.

Gọi $\Omega = [0, W_0] \times [0, H_0]$ là không gian tọa độ ảnh gốc. Hai vùng cắt $B_1, B_2 \subset \Omega$ có diện tích tương đối $|B_1|/|\Omega| = s_1$, $|B_2|/|\Omega| = s_2$ với $s_1, s_2 \sim \mathcal{U}(0.4, 1.0)$. Theo nguyên lý bao hàm – loại trừ (Inclusion-Exclusion Principle):

$$|B_1 \cap B_2| = |B_1| + |B_2| - |B_1 \cup B_2| \geq (s_1 + s_2 - 1)|\Omega| \quad (5)$$

Khi $s_1 + s_2 > 1.0$, phần giao không gian luôn tồn tại ($B_1 \cap B_2 \neq \emptyset$). Do phân phối đều trên dải $[0.4, 1.0]$, kỳ vọng toán học của chỉ số IoU thỏa mãn:

$$\mathbb{E}[\text{IoU}(B_1, B_2)] \in [0.15, 0.60] \quad (6)$$

Tính biến thiên ngẫu nhiên của IoU đóng vai trò quan trọng trong việc định hình không gian biểu diễn:

- Khi $\text{IoU} > 0.4$: Hai góc nhìn có mức độ trùng lặp cao, mạng học tính bất biến đối với các biến đổi quang học (biến thiên chiếu sáng, làm mờ, nhiễu màu).
- Khi $\text{IoU} \rightarrow 0$: Hai góc nhìn quan sát các bộ phận không giao nhau của cùng một phương tiện (như đầu xe và đuôi xe), mạng Student buộc phải trừu tượng hóa ngữ cảnh toàn cục để nhận diện các thành phần rời rạc này thuộc cùng một thực thể phương tiện.

3. **Xử lý ảnh đầu vào có kích thước nhỏ hơn kích thước danh định:** Khi ảnh gốc có độ phân giải nhỏ hơn 224×224 ($\min(H_0, W_0) < 224$), toán tử ‘RandomResizedCrop’ thực hiện phép nội suy Bicubic liên tục bậc ba để mở rộng miền giá trị về kích thước danh định $(3, 224, 224)$:

$$\tilde{I}(x, y) = \sum_{i=-1}^2 \sum_{j=-1}^2 I(\lfloor x \rfloor + i, \lfloor y \rfloor + j) \cdot \mathcal{K}(x - (\lfloor x \rfloor + i)) \cdot \mathcal{K}(y - (\lfloor y \rfloor + j)) \quad (7)$$

với $\mathcal{K}(\cdot)$ là nhân spline Keys. Nhờ tính khả vi của hàm nội suy bậc ba, tensor đầu vào đưa vào ViT luôn duy trì cấu trúc liên tục và kích thước danh định. Tuy nhiên, việc phóng đại quá mức từ ảnh kích thước nhỏ sẽ làm suy giảm thông tin tần số cao (mờ đường biên). Trong bối cảnh camera giám sát giao thông thực tế, độ phân giải thường đạt từ chuẩn HD (720p) trở lên, do đó toán tử này chủ yếu thực hiện hạ mẫu (downsampling) kết hợp lọc khử hiện tượng răng cưa.

3.4 Cấu Trúc Tổ Chức Tensor Đầu Vào và Tối Ưu Hóa Hàm Mất Mất Đối Sánh

Về mặt đại số tuyến tính, việc ghép nhiều góc nhìn quan sát đòi hỏi sự tương thích nghiêm ngặt với cấu trúc chiều của Vision Transformer:

1. **Giới hạn cấu trúc của phép ghép kênh (Channel Concatenation):** Toán tử Patch Embedding trong Vision Transformer ánh xạ một patch không gian $\mathbf{x}_p \in \mathbb{R}^{P \times P \times 3}$ thành vector ẩn $\mathbf{z}_p \in \mathbb{R}^D$ qua ma trận chiều tham số:

$$\mathbf{z}_p = \text{vec}(\mathbf{x}_p) \mathbf{W}_E + \mathbf{b}_E, \quad \mathbf{W}_E \in \mathbb{R}^{(3P^2) \times D} \quad (8)$$

Nếu ghép V góc nhìn theo chiều kênh ($C' = 3V$), kích thước tensor đầu vào trở nên không tương thích với ma trận chiều $\mathbf{W}_E$. Hơn nữa, việc ghép kênh đồng nghĩa với việc xếp chồng điểm ảnh tại cùng một vị trí tọa độ từ các góc nhìn khác nhau, phá vỡ cấu trúc hình học quang học của ảnh quan sát.

2. **Tổ chức theo chiều lô dữ liệu (Batch Dimension):** Các góc nhìn từ B khung hình trong mini-batch được sắp xếp dọc theo chiều mẫu đầu tiên ('dim=0'). Do góc nhìn toàn cảnh (224×224) và góc nhìn cục bộ (98×98) có kích thước không gian khác nhau, dữ liệu được tổ chức thành hai khối tensor độc lập:

$$\mathbf{X}_{\text{global}} \in \mathbb{R}^{(B \cdot N_g) \times 3 \times 224 \times 224} \quad (9)$$

$$\mathbf{X}_{\text{local}} \in \mathbb{R}^{(B \cdot N_l) \times 3 \times 98 \times 98} \quad (10)$$

Mỗi góc nhìn được xử lý song song qua mạng ViT như một thực thể quan sát độc lập, trích xuất ra $B \cdot N_g$ vector biểu diễn Teacher và $B \cdot (N_g + N_l)$ vector biểu diễn Student.

3. **Hàm mất mát entropy chéo đa góc nhìn:** Mạng tối ưu hóa độ lệch entropy chéo giữa phân phối xác suất dự đoán của Teacher trên các góc nhìn toàn cảnh và phân phối của Student trên toàn bộ các góc nhìn:

$$\mathcal{L}_{\text{DINO}} = \frac{1}{N_g} \sum_{i=1}^{N_g} \sum_{\substack{v=1 \\ v \neq i}}^{N_g + N_l} H \left(P_t(x_g^{(i)}), P_s(x^{(v)}) \right) \quad (11)$$

trong đó $H(p, q) = - \sum_{k=1}^K p^{(k)} \log q^{(k)}$.

4 HƯỚNG 1: BG-GUIDED DINO – TIỀN HUẤN LUYỆN TỰ GIÁM SÁT LIÊN TỤC VỚI FOREGROUND-AWARE MASKING

4.1 Hạn Chế của Cơ Chế Che Ngẫu Nhiên Đồng Điều

Trong các mô hình nền tảng tự giám sát hiện nay (DINOv2, DINOv3, Masked Autoencoders), chiến lược che ảnh (Masking) được áp dụng theo phân phối ngẫu nhiên đồng đều (Uniform Random Masking).

Tuy nhiên, trong bối cảnh camera giao thông đô thị:

- Hơn 70% – 80% diện tích khung hình là nền đường bê tông, nhựa đường, vạch kẻ sơn và vỉa hè cố định.
- Phương tiện giao thông chỉ chiếm từ 20% – 30% diện tích nhưng chứa đựng toàn bộ thông tin ngữ nghĩa quan trọng phục vụ giám sát và điều hành.
- Nếu che ngẫu nhiên đồng đều, phần lớn các patch bị che sẽ rơi vào mặt đường. Mô hình Vision Transformer bị lãng phí dung lượng biểu diễn và gradient cập nhật chỉ để học tái tạo lại các mảng nhựa đường vô nghĩa.

4.2 Cơ Sở Toán Học của Chiến Lược Che Foreground-Aware Masking (FAM)

Ảnh được chia thành $N_{\text{patches}} = \left(\frac{H}{P}\right) \times \left(\frac{W}{P}\right)$ patch rời rạc kích thước $P \times P$ (mặc định $P = 16$).

Bản đồ sai khác Δ được tính toán trong không gian màu CIE-LAB nhằm hạn chế ảnh hưởng của biến thiên độ sáng:

$$\Delta(u, v) = 0.5 \cdot \frac{|L_{\text{origin}} - L_{\text{bg}}|}{255} + 0.25 \cdot \frac{|a_{\text{origin}} - a_{\text{bg}}|}{255} + 0.25 \cdot \frac{|b_{\text{origin}} - b_{\text{bg}}|}{255} \quad (12)$$

Trọng số sai khác trung bình của patch thứ p được định nghĩa:

$$w_p = \frac{1}{P^2} \sum_{(u,v) \in \text{Patch}_p} \Delta(u, v) \quad (13)$$

Xác suất để một patch p được chọn để che được mô hình hóa theo công thức nội suy tuyến tính:

$$P_{\text{mask}}(p) = \alpha \cdot \frac{w_p}{\max_q w_q + \epsilon} + (1 - \alpha) \cdot \frac{1}{N_{\text{patches}}} \quad (14)$$

trong đó $\epsilon = 10^{-8}$ là hằng số chống chia cho 0 và $\alpha \in [0, 1]$ là hệ số cân bằng (chọn $\alpha = 0.75$).

4.3 Phân Tích Cơ Sở Toán Học của Xác Suất Che

Công thức (14) được thiết lập dựa trên nguyên lý cân bằng giữa khai thác đặc trưng nổi bật (Exploitation) và thăm dò ngẫu nhiên (Exploration):

1. **Thành phần khai thác tiền cảnh $\frac{w_p}{\max_q w_q + \epsilon}$ (Foreground Exploitation):** Đóng vai trò như hàm mật độ nổi bật (Saliency Density). Việc chuẩn hóa theo giá trị cực đại $\max_q w_q$ đưa cường độ sai khác về đoạn $[0, 1]$. Các patch thuộc vùng phương tiện giao thông có độ sai biệt quang học lớn so với nền đường sẽ có $w_p \approx \max_q w_q$, tương ứng xác suất che cao. Khi các patch tiền cảnh bị che khuất, mạng Student không thể dựa vào thông tin cục bộ trực tiếp mà buộc phải khai thác ngữ cảnh xung quanh để suy diễn biểu diễn mục tiêu do mạng Teacher cung cấp.
2. **Thành phần thăm dò nền $\frac{1}{N_{\text{patches}}}$ (Background Exploration):** Đóng vai trò phân phối đều tiên nghiệm (Uniform Prior). Nếu thiết lập $\alpha = 1.0$ (chỉ che theo Δ), mô hình sẽ gặp hai hạn chế:
 - *Bỏ sót ngữ cảnh nền:* Các vùng mặt đường không bao giờ bị che, dẫn đến việc mô hình không học được biểu diễn không gian tương hỗ giữa bề mặt đường và phương tiện.

- *Hiện tượng suy biến khi mật độ phương tiện thấp*: Khi khung cảnh vắng xe hoặc quan sát ban đêm, $w_p \approx 0$ trên toàn bộ các patch, gây mất ổn định số học. Thành phần phân phối đều bảo đảm luôn duy trì một tỷ lệ che cơ sở tối thiểu.

3. **Vai trò của hệ số $\alpha = 0.75$** : Giá trị $\alpha = 0.75$ phân bổ 75% xác suất che tập trung vào các vùng phương tiện (nơi chứa thông tin ngữ nghĩa giao thông trọng tâm), trong khi 25% xác suất còn lại duy trì việc che ngẫu nhiên trên toàn bộ khung hình.

4.4 Tích Hợp Cơ Chế FAM Vào Pipeline Huấn Luyện Multi-Crop

Cơ chế che có định hướng tiền cảnh (FAM) được tích hợp vào chiến lược đa góc nhìn của DINO theo quy trình:

- **Đối với mạng Teacher**: Tiếp nhận hai góc nhìn toàn cảnh ở trạng thái nguyên vẹn không bị che (unmasked global crops). Điều này bảo đảm Teacher luôn duy trì mỏ neo ngữ nghĩa hoàn chỉnh của khung cảnh làm mục tiêu chứng cất.
- **Đối với mạng Student**: Tiếp nhận các góc nhìn toàn cảnh đã được áp dụng mặt nạ FAM (masked global crops) cùng các góc nhìn cục bộ (local crops). Hàm mất mát chứng cất buộc Student phải tái tạo phân phối biểu diễn toàn thể ngay cả khi các cấu trúc thành phần của phương tiện bị che khuất.
- **Hàm mất mát chứng cất đa góc nhìn**:

$$\mathcal{L}_{\text{DINO}} = - \sum_{x \in \{V_{\text{masked}}^g, V^l\}} \sum_{x' \in \{V_1^g, V_2^g\}, x' \neq x} P_t(x') \log P_s(x) \quad (15)$$

5 HƯỚNG 2: ZERO-SHOT VEHICLE SEMANTIC SEGMENTATION

5.1 Đặt Vấn Đề

Việc thu thập nhãn phân đoạn mức điểm ảnh (pixel-level mask) cho dữ liệu giao thông thực tế đòi hỏi chi phí nhân công rất lớn. Hướng nghiên cứu này đề xuất phương pháp phân đoạn phương tiện không cần dữ liệu huấn luyện có nhãn (Zero-Shot Semantic Segmentation), thông qua việc kết hợp tín hiệu sai khác quang học và không gian biểu diễn ngữ nghĩa sâu của Vision Transformer.

5.2 Đặc Tính Bổ Trợ Giữa Tín Hiệu Quang Học và Biểu Diễn Ngữ Nghĩa Sâu

Hệ thống thiết lập cơ chế kết hợp giữa hai nguồn tín hiệu:

1. **Nhánh sai khác quang học (Δ -Mask)**: Phép trừ nền trong không gian màu CIE-LAB kết hợp thuật toán phân ngưỡng tự động Otsu và các phép biến đổi hình thái học (Morphological Open 5×5 , Close 11×11).

- *Đặc tính*: Xác định ranh giới chuyển động chính xác ở cấp độ điểm ảnh.
- *Hạn chế*: Nhạy cảm với bóng đổ của phương tiện trên mặt đường do bóng đổ làm suy giảm cường độ sáng cục bộ.

2. **Nhánh ngữ nghĩa sâu (DINO PCA PC1)**: Trích xuất ma trận patch tokens $X \in \mathbb{R}^{N_{\text{patches}} \times D}$ tại tầng Transformer cuối cùng và chiếu lên thành phần chính thứ nhất thông qua phép phân tích PCA:

$$(X - \bar{X}) = U\Sigma V^T \implies \mathbf{z}_{\text{PC1}} = (X - \bar{X})v_1 \quad (16)$$

- *Đặc tính*: Cơ chế tự chú ý của DINO nhóm các patch theo tương đồng ngữ nghĩa đối tượng. Thành phần PC1 có khả năng phân tách tốt giữa phương tiện và nền đường, ít chịu ảnh hưởng bởi bóng đổ do vùng bóng đổ vẫn mang đặc trưng ngữ nghĩa của bề mặt đường.
- *Hạn chế*: Độ phân giải không gian thô, phụ thuộc vào kích thước patch (14×14).

5.3 Cơ Chế Dung Hợp Mặt Nạ (Mask Fusion Engine)

Sự kết hợp giữa hai nhánh tín hiệu được thực hiện qua toán tử giao không gian và lọc song phương:

$$M_{\text{fused}} = \text{BilateralFilter}\left(M_{\Delta} \cap \text{Threshold}(\text{Resize}(\mathbf{z}_{\text{PC1}}))\right) \quad (17)$$

Toán tử giao $\cap$ giúp loại bỏ phần lớn hiện tượng bóng đổ bề mặt đường và các dao động quang học ngẫu nhiên. Sau đó, bộ lọc song phương (Bilateral Filter) làm mịn và căn chỉnh đường biên phân đoạn theo độ tương phản cục bộ của khung hình gốc. Mặt nạ sinh ra có độ tin cậy cao, đóng vai trò nhãn giám sát giả (pseudo-labels) để huấn luyện một mạng phân đoạn nhẹ (Lightweight Segmentation Head) đạt thông lượng xử lý thời gian thực trên thiết bị biên.

6 HƯỚNG 3: SELF-SUPERVISED SCENE DECOMPOSITION NETWORK

6.1 Mô Hình Hóa Alpha Compositing

Khung cảnh quan sát được mô hình hóa theo phương trình hòa trộn quang học:

$$I_{\text{origin}} = M_{\alpha} \odot I_{\text{fg}} + (1 - M_{\alpha}) \odot I_{\text{bg}} \quad (18)$$

trong đó $I_{\text{bg}} \in \mathbb{R}^{H \times W \times 3}$ là lớp nền đường, $I_{\text{fg}} \in \mathbb{R}^{H \times W \times 3}$ là lớp chứa phương tiện, và $M_{\alpha} \in [0, 1]^{H \times W \times 1}$ là mặt nạ mờ (Alpha Matte) thể hiện mức độ chiếm dụng không gian của phương tiện.

Thông thường, việc phân rã một ảnh duy nhất I_{origin} thành cả ba thành phần $\{I_{\text{bg}}, I_{\text{fg}}, M_{\alpha}\}$ là bài toán nghịch đảo thiếu ràng buộc (Ill-posed Inverse Problem).

6.2 Mô Hình Hóa Ràng Buộc với Mỏ Neo Nền Tĩnh

Nghiên cứu sử dụng ảnh nền ước lượng $I_{\text{bg_real}}$ làm mỏ neo vật lý giám sát tự thân. Mạng nơ-ron sử dụng chung bộ trích xuất đặc trưng ViT và phân nhánh thành ba đầu giải mã (Background Head, Foreground Head, Alpha Head).

Hàm mục tiêu tối ưu hóa toàn diện gồm bốn thành phần:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{rec}}\mathcal{L}_{\text{recon}} + \lambda_{\text{bg}}\mathcal{L}_{\text{bg}} + \lambda_{\text{sparse}}\mathcal{L}_{\text{sparcity}} + \lambda_{\text{tv}}\mathcal{L}_{\text{tv}} \quad (19)$$

1. **Mất mát tái tạo ($\mathcal{L}_{\text{recon}}$):** Kết hợp khoảng cách L_1 và chỉ số tương đồng cấu trúc SSIM nhằm bảo đảm ảnh hòa trộn tái tạo khung hình gốc:

$$\mathcal{L}_{\text{recon}} = \|I_{\text{origin}} - \hat{I}_{\text{origin}}\|_1 + (1 - \text{SSIM}(I_{\text{origin}}, \hat{I}_{\text{origin}})) \quad (20)$$

2. **Mất mát mỏ neo nền ($\mathcal{L}_{\text{bg}}$):** Ràng buộc đầu ra của Decoder nền tiệm cận cấu trúc nền tĩnh thực tế:

$$\mathcal{L}_{\text{bg}} = \|\hat{I}_{\text{bg}} - I_{\text{bg_real}}\|_1 \quad (21)$$

buộc nhánh phương tiện (I_{fg}) và nhánh Alpha (M_{α}) phải hấp thụ toàn bộ các thành phần động.

3. **Ràng buộc độ thưa của mặt nạ Alpha ($\mathcal{L}_{\text{sparcity}}$):** Áp dụng chuẩn L_1 trên mặt nạ Alpha:

$$\mathcal{L}_{\text{sparcity}} = \frac{1}{H \cdot W} \sum_{u=1}^H \sum_{v=1}^W M_{\alpha}(u, v) \quad (22)$$

nhằm ngăn ngừa nghiệm suy biến khi mạng gán $M_{\alpha} = 1$ trên toàn bộ không gian.

4. **Làm mịn tổng biến thiên ($\mathcal{L}_{\text{tv}}$):** Khử nhiễu cục bộ và giảm hiện tượng phân mảnh viền:

$$\mathcal{L}_{\text{tv}} = \frac{1}{H \cdot W} \sum_{u,v} (|M_{\alpha}(u+1, v) - M_{\alpha}(u, v)| + |M_{\alpha}(u, v+1) - M_{\alpha}(u, v)|) \quad (23)$$

Mô hình cho phép loại bỏ phương tiện và phục hồi bề mặt nền đường (Scene Inpainting) trực tiếp từ khung hình quan sát đơn lẻ.

7 HƯỚNG 4: FOREGROUND-ENHANCED TRAFFIC COUNTING

7.1 Mở Rộng Tensor Đầu Vào Bốn Kênh

Bài toán ước lượng lưu lượng phương tiện đối mặt với thách thức lớn khi mật độ giao thông cao gây che khuất lẫn nhau và trong điều kiện huấn luyện ít mẫu (Few-shot learning: 5%, 10%, 20% nhân).

Để bổ sung thông tin vị trí chuyển động, tensor đầu vào được mở rộng thành bốn kênh:

$$X_{4\text{ch}} = [\text{R}, \text{G}, \text{B}, \Delta_{\text{norm}}] \in \mathbb{R}^{4 \times H \times W} \quad (24)$$

trong đó kênh thứ tư là bản đồ sai khác quang học được chuẩn hóa:

$$\Delta_{\text{norm}} = \frac{\Delta - 0.5}{0.5} \in [-1.0, 1.0] \quad (25)$$

7.2 Chiến Lược Khởi Tạo Thích Ứng (Warm-Start Initialization)

Lớp Patch Embedding trong Vision Transformer ánh xạ patch không gian thành vector D chiều với ma trận trọng số $W_{4\text{ch}} \in \mathbb{R}^{D \times 4 \times P \times P}$. Nếu khởi tạo ngẫu nhiên kênh thứ tư, các giá trị kích hoạt ban đầu sẽ làm mất ổn định không gian đặc trưng đã được tiền huấn luyện của mô hình.

Quy tắc khởi tạo thích ứng âm được thiết lập như sau:

$$W_{4\text{ch}}[:, 0 : 3, :, :] = W_{\text{pretrained}} \quad (26)$$

$$W_{4\text{ch}}[:, 3, :, :] = \frac{1}{3} \sum_{c=0}^2 W_{\text{pretrained}}[:, c, :, :] \quad (27)$$

Ba kênh đầu bảo toàn các bộ lọc trích xuất biên cạnh và kết cấu không gian đã học. Kênh thứ tư nhận giá trị trung bình cộng trọng số của ba kênh RGB, bảo đảm tại bước huấn luyện đầu tiên, kênh Δ đóng góp năng lượng đồng mức mà không gây đột biến gradient.

7.3 Quy Trình Đánh Giá Phân Tách Không Gian (Spatial Disjoint Evaluation)

Tập dữ liệu được phân chia theo danh tính camera độc lập (Camera ID Disjoint), bảo đảm camera dùng trong tập huấn luyện không xuất hiện trong tập kiểm thử. Quy trình này loại bỏ nguy cơ rò rỉ dữ liệu (Data Leakage) do nền đường cố định giữa các khung hình liên tiếp, đánh giá khách quan năng lực tổng quát hóa của kênh Δ trên các góc nhìn tuyến đường hoàn toàn mới.

8 HƯỚNG 5: PHÁT HIỆN BẤT THƯỜNG GIAO THÔNG KHÔNG GIÁM SÁT

8.1 Đặt vấn đề

Bài toán phát hiện bất thường không giám sát (Unsupervised Anomaly Detection - UAD) tập trung vào việc nhận diện các sự kiện hiếm gặp trong giao thông như tai nạn, vật cản hoặc sự cố dừng đỗ sai quy định, mà không cần dữ liệu huấn luyện có nhãn.

8.2 Biểu diễn kép Δ và DINO

Đặc trưng của mỗi vùng không gian được kết hợp từ sai khác quang học và biểu diễn ngữ nghĩa:

$$f_{\text{anomaly}} = \text{Concat}(\text{Pool}(\Delta^t), [CLS]^t) \in \mathbb{R}^{D+d_\Delta} \quad (28)$$

8.3 Memory Bank và Anomaly Score

Hệ thống duy trì một bộ nhớ (Memory Bank) lưu trữ các biểu diễn trạng thái bình thường. Điểm bất thường (Anomaly Score) tại thời điểm t được tính toán dựa trên khoảng cách Mahalanobis:

$$\text{score}(t) = d_{\text{Mahalanobis}}(f^t, \text{Memory Bank}) \quad (29)$$

Memory Bank được cập nhật liên tục theo cơ chế trung bình trượt hàm mũ (EMA) nhằm thích ứng với biến đổi quang học theo thời gian.

9 HƯỚNG 6: HỌC TƯƠNG PHẢN THỜI GIAN CHO ƯỚC LƯỢNG MẬT ĐỘ GIAO THÔNG

9.1 Khai thác chuỗi thời gian (Temporal Sequence)

Việc khai thác sự liên tục trong chuỗi thời gian của các khung hình cho phép cải thiện chất lượng ước lượng mật độ, tốc độ và mức độ phục vụ (Level of Service).

9.2 Contrastive Loss Temporal

Hàm mất mát tương phản thời gian được thiết kế để kéo gần các biểu diễn kề nhau và đẩy xa các biểu diễn khác biệt:

$$\mathcal{L}_{\text{temporal}} = -\log \left(\frac{\exp(\text{sim}(h_a, h_b^+)/\tau)}{\exp(\text{sim}(h_a, h_b^+)/\tau) + \sum \exp(\text{sim}(h_a, h_j^-)/\tau)} \right) \quad (30)$$

9.3 TemporalEncoder

Mạng TemporalEncoder kết hợp đặc trưng toàn cục từ DINO và sai khác Δ qua nhiều khung hình, phục vụ trực tiếp cho các tác vụ downstream (mật độ, tốc độ, Level of Service).

10 HƯỚNG 7: NHẬN DẠNG LẠI PHƯƠNG TIỆN LIÊN CAMERA DỰA TRÊN Δ -MASK

10.1 Trích xuất RoI (Region of Interest)

Các vùng quan tâm được trích xuất thông qua phân tích thành phần liên thông (Connected Components) trên mặt nạ $\Delta > \text{Otsu}$.

10.2 Biểu diễn Phương Tiện

Mỗi phương tiện i được trích xuất đặc trưng bằng mô hình DINO trên vùng cắt tương ứng:

$$e_i = \text{DINO}_{[CLS]}(\text{Crop}(I, \text{RoI}_i)) \quad (31)$$

10.3 Tracklet Mining và Hàm Mất Mát

Các tracklet được khai thác cho bài toán Re-ID không giám sát thông qua kết hợp hàm mất mát nội (intra-tracklet) và ngoại (inter-tracklet):

$$\mathcal{L}_{\text{ReID}} = \mathcal{L}_{\text{intra-tracklet}} + \mathcal{L}_{\text{inter-tracklet}} \quad (32)$$

11 HƯỚNG 8: HIỂU CẢNH GIAO THÔNG MỞ TỪ VÙNG VỚI Δ REGION PROPOSALS

11.1 Class-Agnostic Proposals

Mặt nạ Δ cung cấp các đề xuất vùng (proposals) không phụ thuộc lớp (class-agnostic), đóng vai trò như các đối tượng tiềm năng trong khung cảnh.

11.2 Phân Tích Đặc Trưng DINO và CLIP

Đặc trưng DINO được trích xuất trên từng vùng và ánh xạ (Projection) sang không gian đặc trưng của CLIP.

11.3 Điểm Tương Đồng

Mức độ phù hợp giữa một vùng r và mô tả văn bản text được tính bằng độ tương đồng cosine:

$$\text{score}(r, \text{text}) = \text{sim}(\text{DINO}(r), \text{CLIP}_{\text{text}}(\text{text})) \quad (33)$$

12 HƯỚNG 9: ƯỚC LƯỢNG ĐIỀU KIỆN MẶT ĐƯỜNG TỰ GIÁM SÁT

12.1 Chuỗi Ảnh Nền

Thu thập chuỗi ảnh nền I_{bg} trong 24 giờ từ 608 camera để xây dựng không gian dữ liệu đánh giá tình trạng mặt đường.

12.2 Biểu Diễn Tình Trạng Đường

Mô hình trích xuất đặc trưng DINO từ các khung hình nền:

$$z_{\text{road}} = \text{DINO}_{[\text{CLS}]}(I_{\text{bg}}^{c,h}) \quad (34)$$

12.3 Contrastive Learning

Huấn luyện học tương phản (Contrastive learning) trên chuỗi thời gian ảnh nền nhằm phát hiện các biến đổi như đọng nước, vỡ nứt hoặc tuyết phủ.

13 TỔNG HỢP VÀ ĐÁNH GIÁ CÁC HƯỚNG TIẾP CẬN

Bảng 1: Tổng hợp phương pháp luận và tiềm năng công bố của chín hướng nghiên cứu

Hướng	Tên Nghiên Cứu	Cơ Chế Cốt Lõi	Độ Mới	Venue Đề Xuất
Hướng 1	BG-Guided DINO Continual SSL	Foreground-Aware Masking (FAM) định hướng ViT che và học biểu diễn phương tiện	4/5	IEEE T-ITS, EAAI, Pattern Recognition
Hướng 2	Zero-Shot Vehicle Segmentation	Dùng hợp tín hiệu hỗ trợ Δ -Mask $\cap$ DINO PCA PC1	3/5	PR Letters, IEEE Access
Hướng 3	Scene Decomposition Network	Mô hình hóa Alpha Compositing với mô neo giám sát nền tĩnh	5/5	CVPR, ECCV, NeurIPS
Hướng 4	Foreground-Enhanced Counting	Mở rộng Patch Embedding 4 kênh (RGB+ Δ) kết hợp Warm-Start	2.5/5	EAAI Journal, ITSC
Hướng 5	Unsupervised Traffic Anomaly Detection	Biểu diễn kép Δ +DINO, Memory Bank với cập nhật EMA	4/5	IEEE T-ITS, ICIP
Hướng 6	Temporal Contrastive Learning	Khai thác chuỗi thời gian cho ước lượng mật độ	3.5/5	IEEE T-IV, ITSC
Hướng 7	Unsupervised Vehicle Re-ID	Trích xuất RoI từ Δ , tracklet mining, intra/inter-tracklet loss	4/5	CVPR, ICCV
Hướng 8	Open-Vocabulary Scene Understanding	Δ proposals và chiếu DINO sang không gian CLIP	4.5/5	CVPR, ECCV
Hướng 9	Ước lượng mật đường tự giám sát	Contrastive learning trên chuỗi I_{bg} 24h	3/5	IEEE T-ITS, TRB

14 KẾT LUẬN

Báo cáo đã hệ thống hóa cơ sở lý thuyết về mô hình học tự giám sát DINO và đề xuất chín hướng nghiên cứu khai thác cặp tín hiệu ảnh hiện trường và ảnh nền tĩnh trong giám sát giao thông đô thị. Các phương pháp trải rộng từ tiền huấn luyện thích ứng miền (Hướng 1), tạo nhân giả phân

đoạn không giám sát (Hướng 2), phân rã bối cảnh tự thân (Hướng 3), đến ước lượng lưu lượng phương tiện ít mẫu (Hướng 4), cùng các mở rộng ứng dụng trong phát hiện bất thường, ước lượng mật độ, nhận dạng lại, hiểu cảnh mở từ vựng và đánh giá mặt đường (Hướng 5-9). Việc kết hợp có hệ thống giữa các đặc tính quang học vật lý và mô hình học sâu giúp nâng cao độ chính xác biểu diễn, đồng thời giảm thiểu sự phụ thuộc vào dữ liệu gán nhãn thủ công trong các hệ thống giao thông thông minh.