

BÁO CÁO KHOA HỌC: PHƯƠNG PHÁP LUẬN VÀ THIẾT KẾ KIẾN TRÚC

KHAI THÁC CẤP ẢNH NỀN TĨNH VÀ PHƯƠNG TIỆN TRONG THỊ GIÁC GIAO THÔNG VỚI DINO

Nhóm Nghiên Cứu Thị Giác Máy Tính Đô Thị

October 2, 2026

Abstract

Trong hệ thống camera giám sát giao thông thông minh (CCTV), các thiết bị ghi hình cố định cung cấp cấp tín hiệu quang học tự nhiên có giá trị: ảnh hiện trường ghi nhận phương tiện di chuyển và ảnh nền tĩnh (background) sạch bóng xe được ước lượng qua chuỗi thời gian. Báo cáo này trình bày cơ sở lý thuyết, mô hình hóa toán học và phương pháp luận chuyên sâu của bốn hướng nghiên cứu trọng tâm học tự giám sát (Self-Supervised Learning) nhằm khai thác triệt để cấp tín hiệu trên. Hệ sinh thái nghiên cứu bao gồm: (1) Tiền huấn luyện Vision Transformer với cơ chế che có định hướng tiền cảnh (Foreground-Aware Masking); (2) Mạng phân rã bối cảnh tự giám sát (Scene Decomposition Network) dựa trên mô hình hòa trộn Alpha Compositing và xóa xe tự động (Inpainting); (3) Mở rộng biểu diễn Patch Embedding bốn kênh (RGB + Δ) phục vụ bài toán ước lượng lưu lượng phương tiện trong điều kiện ít mẫu (Few-shot learning); và (4) Dự đoán mật độ không-thời gian và phân loại cấp độ dịch vụ giao thông theo chuẩn Highway Capacity Manual (HCM LoS) dựa trên mạng hợp nhất DINO ViT, CNN và Bi-GRU. Hệ sinh thái tinh gọn loại bỏ các tiếp cận bất thường không có mô neo vật lý hoặc dễ bị nhiễu nhận dạng trong giao thông hỗn hợp để tập trung tối đa nguồn lực vào các bài toán đo lường động học, tách rã cảnh và lưu lượng có tính ứng dụng thực tiễn cao nhất.

1 ĐẶT VẤN ĐỀ VÀ MÔ HÌNH HÓA TÍN HIỆU QUANG HỌC

Trong bài toán giám sát giao thông đô thị qua camera tĩnh, mỗi khung hình tại thời điểm t được xem xét dưới hai trạng thái quan sát:

1. **Khung hình hiện trường** ($I_{\text{origin}} \in \mathbb{R}^{H \times W \times 3}$): Ghi nhận các phương tiện giao thông (xe máy, ô tô, xe buýt, xe tải) chuyển động trên bề mặt tuyến đường, kèm theo các yếu tố biến đổi về mật độ, điều kiện chiếu sáng và mức độ che khuất lẫn nhau.
2. **Ảnh nền tĩnh** ($I_{\text{bg}} \in \mathbb{R}^{H \times W \times 3}$): Thể hiện cấu trúc mặt đường khi không có phương tiện, được ước lượng thông qua thuật toán lọc trung vị theo thời gian (Temporal Median Filtering) kết hợp chuẩn hóa cường độ trong không gian màu HSV theo từng chu kỳ quan sát.

Mối quan hệ không gian giữa hai khung hình xác lập trường sai khác quang học:

$$\Delta(u, v) = \|I_{\text{origin}}(u, v) - I_{\text{bg}}(u, v)\| \quad (1)$$

Thay vì chỉ áp dụng $\Delta(u, v)$ trong các thuật toán phân đoạn ngưỡng cổ điển vốn nhạy cảm với biến thiên thời tiết và bóng đổ, hệ sinh thái DINO Suite tích hợp tín hiệu sai khác vật lý này vào không gian biểu diễn sâu của Vision Transformer (ViT), mở ra bốn hướng tiếp cận trọng tâm bổ trợ lẫn nhau trong giao thông thông minh.

2 CƠ SỞ PHƯƠNG PHÁP LUẬN VỀ HỌC TỰ GIÁM SÁT DINO

2.1 Cơ Chế Chung Cát Tự Thân và Động Học Ổn Định Biểu Diễn

Kiến trúc DINO (Caron et al., ICCV 2021) dựa trên nguyên lý tự chưng cất tri thức (self-distillation) giữa hai mạng nơ-ron có cấu trúc tham số tương đồng: mạng Student g_{θ_s} và mạng Teacher g_{θ_t} . Mỗi mạng bao gồm một bộ trích xuất đặc trưng Vision Transformer (ViT) kết hợp đầu chiếu phi tuyến đa tầng (MLP Projection Head) nhằm ánh xạ vector đặc trưng $[CLS]$ sang không gian phân phối xác suất K chiều ($K \in \{4096, 65536\}$).

Hệ thống tối ưu hóa vận hành theo quy tắc cập nhật tham số bất đối xứng:

1. **Tối ưu hóa Student qua lan truyền ngược:** Tham số θ_s được cập nhật trực tiếp bằng thuật toán AdamW dựa trên độ dốc của hàm mất mát entropy chéo giữa đầu ra Student và Teacher.
2. **Cập nhật Teacher theo trung bình trượt hàm mũ (EMA):** Trọng số của Teacher không tiếp nhận trực tiếp gradient ($\nabla_{\theta_t} \mathcal{L} = 0$), mà tiến hóa theo trung bình trượt động lượng từ tham số Student:

$$\theta_t \leftarrow \lambda \theta_t + (1 - \lambda) \theta_s \quad (2)$$

trong đó hệ số động lượng $\lambda \in [0.996, 1.0]$ được điều chỉnh tăng dần theo lịch trình cosin. Về mặt giải tích, cơ chế EMA đóng vai trò như bộ lọc thông thấp trong không gian tham số, giúp mạng Teacher cung cấp phân phối xác suất mục tiêu ổn định và có phương sai thấp qua các bước huấn luyện.

3. **Cơ chế kiểm soát sự sụp đổ biểu diễn (Representation Collapse Prevention):** DINO kiểm soát trạng thái suy biến bằng việc kết hợp kỹ thuật định tâm (*Centering*) và kỹ thuật làm nhọn phân phối (*Sharpening*):

$$P_t(x)^{(k)} = \frac{\exp\left(\frac{g_{\theta_t}(x)^{(k)} - c^{(k)}}{\tau_t}\right)}{\sum_{j=1}^K \exp\left(\frac{g_{\theta_t}(x)^{(j)} - c^{(j)}}{\tau_t}\right)}, \quad P_s(x)^{(k)} = \frac{\exp\left(\frac{g_{\theta_s}(x)^{(k)}}{\tau_s}\right)}{\sum_{j=1}^K \exp\left(\frac{g_{\theta_s}(x)^{(j)}}{\tau_s}\right)} \quad (3)$$

trong đó vector định tâm $c \in \mathbb{R}^K$ ước lượng kỳ vọng bậc một của phân phối đầu ra Teacher, và nhiệt độ $\tau_t < \tau_s$ tạo hiệu ứng làm nhọn phân phối xác suất.

2.2 Sự Phát Triển Kiến Trúc Từ DINOv1 Đến DINOv2

DINOv2 (Oquab et al., Meta AI 2023) mở rộng khung lý thuyết DINO từ việc học biểu diễn toàn cục $[CLS]$ thành mô hình nền tảng thị giác (Vision Foundation Model) có khả năng sinh biểu diễn dày đặc (dense representations) ở cấp độ từng patch, với các cải tiến kiến trúc then chốt:

1. **Cơ chế học đa nhiệm tích hợp Masked Image Modeling (MIM / iBOT):** DINOv2 kết hợp đồng thời việc tự chưng cất token toàn cục $[CLS]$ với bài toán phục hồi biểu diễn của các patch bị che ngẫu nhiên:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{DINO}}([CLS]) + \lambda_{\text{patch}} \mathcal{L}_{\text{iBOT}}(\text{Patch Tokens}) \quad (4)$$

2. **Ổn định hóa truyền gradient trên mô hình quy mô lớn:** Áp dụng LayerScale, Pre-LayerNorm, và SwiGLU FFN.
3. **Khử nhiễu đặc trưng cục bộ qua Register Tokens:** Bổ sung 4 register tokens vào chuỗi đầu vào để hấp thụ các tín hiệu kích hoạt ngoại lai trên nền trơn nhẵn (nhựa đường, bầu trời).

2.3 Chiến Lược Trích Xuất Đa Góc Nhìn (Multi-Crop)

Chiến lược đa góc nhìn sinh ra tập hợp gồm $N_g = 2$ góc nhìn toàn cảnh (224×224 , tỷ lệ diện tích $[0.4, 1.0]$) nạp vào cả Teacher và Student, cùng $N_l = 4$ đến 8 góc nhìn cục bộ (96×96 , tỷ lệ diện tích $[0.05, 0.4]$) chỉ nạp vào Student. Kỳ vọng toán học của độ giao thoa không gian giữa hai góc nhìn toàn cảnh ngẫu nhiên thỏa mãn $\mathbb{E}[\text{IoU}] \in [0.15, 0.60]$, ép mô hình vừa học tính bất biến quang học (khi IoU lớn) vừa trừu tượng hóa ngữ cảnh toàn cục của đối tượng (khi IoU $\rightarrow 0$).

3 HƯỚNG 1: BG-GUIDED DINO – TIỀN HUẤN LUYỆN TỰ GIÁM SÁT LIÊN TỤC VỚI FOREGROUND-AWARE MASKING

3.1 Hạn Chế của Cơ Chế Che Ngẫu Nhiên Đồng Điều

Trong ảnh camera giao thông đô thị, hơn 70% – 80% diện tích khung hình là nền đường tĩnh, vỉa hè và dải phân cách bê tông. Nếu áp dụng chiến lược che ngẫu nhiên đồng đều (Uniform Random Masking), phần lớn tài nguyên tính toán và gradient cập nhật của ViT bị lãng phí chỉ để tái tạo các mảng nhựa đường vô nghĩa.

3.2 Cơ Sở Toán Học của Chiến Lược Che Foreground-Aware Masking (FAM)

Ảnh được chia thành $N_{\text{patches}} = \left(\frac{H}{P}\right) \times \left(\frac{W}{P}\right)$ patch rời rạc ($P = 16$). Trọng số sai khác trung bình của patch thứ p được tính trong không gian màu CIE-LAB:

$$w_p = \frac{1}{P^2} \sum_{(u,v) \in \text{Patch}_p} \Delta(u, v) \quad (5)$$

Xác suất để patch p được lựa chọn che được xác định theo mô hình nội suy tuyến tính:

$$P_{\text{mask}}(p) = \alpha \cdot \frac{w_p}{\max_q w_q + \epsilon} + (1 - \alpha) \cdot \frac{1}{N_{\text{patches}}} \quad (6)$$

với $\alpha = 0.75$. Thành phần thứ nhất phân bổ 75% xác suất che tập trung vào các vùng phương tiện (buộc Student phải suy diễn ngữ nghĩa xe từ ngữ cảnh xung quanh), trong khi thành phần thứ hai duy trì 25% phân phối đều để bảo đảm mạng không bỏ sót cấu trúc không gian nền đường.

Hàm mất mát chung cất đa góc nhìn:

$$\mathcal{L}_{\text{DINO}} = - \sum_{x \in \{V_{\text{masked}}^g, V^l\}} \sum_{x' \in \{V_1^g, V_2^g\}, x' \neq x} P_t(x') \log P_s(x) \quad (7)$$

4 HƯỚNG 2: MẠNG PHÂN RÃ BỐI CẢNH TỰ GIÁM SÁT (TRAFFIC-DECOMPOSE)

4.1 Mô Hình Hóa Alpha Compositing với Mỏ Neo Nền Tĩnh

Khung cảnh giao thông được mô hình hóa theo phương trình hòa trộn quang học:

$$I_{\text{origin}} = M_{\alpha} \odot I_{\text{fg}} + (1 - M_{\alpha}) \odot I_{\text{bg}} \quad (8)$$

trong đó I_{bg} là lớp nền đường sạch bóng xe, I_{fg} là lớp chứa phương tiện cô lập, và $M_{\alpha} \in [0, 1]^{H \times W \times 1}$ là mặt nạ mờ trong suốt (Alpha Matte).

Để giải bài toán nghịch đảo thiếu ràng buộc này, nghiên cứu sử dụng ảnh nền tĩnh thật $I_{\text{bg_real}}$ làm mỏ neo vật lý giám sát tự thân. Mạng nơ-ron sử dụng chung bộ trích xuất đặc trưng ViT và phân nhánh thành ba đầu giải mã (Background Head, Foreground Head, Alpha Head).

4.2 Hàm Mất Mất Đa Ràng Buộc Vật Lý

$$\mathcal{L}_{\text{total}} = \lambda_{\text{rec}} \mathcal{L}_{\text{recon}} + \lambda_{\text{bg}} \mathcal{L}_{\text{bg}} + \lambda_{\text{sparse}} \mathcal{L}_{\text{sparse}} + \lambda_{\text{tv}} \mathcal{L}_{\text{tv}} \quad (9)$$

- $\mathcal{L}_{\text{recon}} = \|I_{\text{origin}} - \hat{I}_{\text{origin}}\|_1 + (1 - \text{SSIM}(I_{\text{origin}}, \hat{I}_{\text{origin}}))$: Đảm bảo tái tạo hoàn hảo ảnh gốc.
- $\mathcal{L}_{\text{bg}} = \|\hat{I}_{\text{bg}} - I_{\text{bg_real}}\|_1$: Khóa chặt nhánh nền vào lòng đường thực tế, buộc nhánh I_{fg} và M_{α} phải hấp thụ toàn bộ phương tiện chuyển động.
- $\mathcal{L}_{\text{sparse}} = \frac{1}{HW} \sum_{u,v} M_{\alpha}(u, v)$: Ngăn chặn nghiệm suy biến $M_{\alpha} = 1$.
- $\mathcal{L}_{\text{tv}} = \text{TotalVariation}(M_{\alpha})$: Khử nhiễu đốm và làm mịn đường biên thân xe.

Mô hình cho phép tự động xóa sạch phương tiện (Unsupervised Road Inpainting) trực tiếp từ một khung hình đơn lẻ.

5 HƯỚNG 3: MỞ RỘNG BIỂU DIỄN TIỀN CẢNH BỐN KÊNH TRONG ƯỚC LƯỢNG LƯU LƯỢNG PHƯƠNG TIỆN

5.1 Mở Rộng Tensor Đầu Vào và Khởi Tạo Thích Ứng Âm

Bài toán ước lượng lưu lượng phương tiện đối mặt với hiện tượng che khuất nghiêm trọng trong giờ cao điểm và điều kiện học ít mẫu (Few-shot learning: 5%, 10%, 20% nhãn). Tensor đầu vào được mở rộng thành bốn kênh:

$$X_{4\text{ch}} = [\mathbf{R}, \mathbf{G}, \mathbf{B}, \Delta_{\text{norm}}] \in \mathbb{R}^{4 \times H \times W} \quad (10)$$

Nhằm bảo toàn tri thức tiền huấn luyện của ViT, thuật toán Warm-Start Weight Adaptation được áp dụng cho ma trận trọng số Patch Embedding $W_{4\text{ch}} \in \mathbb{R}^{D \times 4 \times P \times P}$:

$$W_{4\text{ch}}[:, 0 : 3, :, :] = W_{\text{pretrained}}, \quad W_{4\text{ch}}[:, 3, :, :] = \frac{1}{3} \sum_{c=0}^2 W_{\text{pretrained}}[:, c, :, :] \quad (11)$$

Trọng số kênh Δ nhận trung bình cộng ba kênh màu RGB, bảo đảm tại bước huấn luyện đầu tiên kênh sai khác đóng góp năng lượng đồng mức mà không gây sốc gradient cho mạng nơ-ron. Đánh giá được thực hiện qua giao thức phân chia camera phân tách độc lập (Spatial Disjoint Splitting) nhằm triệt tiêu hiện tượng rò rỉ dữ liệu bối cảnh.

6 HƯỚNG 4: DỰ ĐOÁN MẬT ĐỘ KHÔNG-THỜI GIAN VÀ CẤP ĐỘ DỊCH VỤ GIAO THÔNG (SPATIO-TEMPORAL DENSITY & HCM LoS)

6.1 Đặt Vấn Đề và Mỏ Neo Vật Lý Tự Thân

Các mô hình thị giác truyền thống thường tiếp cận theo hướng đếm phương tiện rời rạc trên từng khung hình tĩnh. Trong dòng giao thông xe máy hỗn hợp đặc trưng tại các đô thị Đông Nam Á (hàng trăm xe máy di chuyển sát nhau), hiện tượng che khuất chổng chéo dẫn đến sai số lũy kế nghiêm trọng.

Nghiên cứu chuyển đổi mục tiêu sang ước lượng **Tỷ lệ Chiếm dụng Lòng đường Liên tục** $\rho(t) \in [0, 1]$ và **Cấp độ Dịch vụ Giao thông** theo chuẩn Highway Capacity Manual (HCM LoS). Trường sai khác quang học Δ_t cung cấp mỏ neo vật lý tự thân mà không cần gán nhãn thủ công:

$$\rho_{\text{phys}}(t) = \frac{1}{H \times W} \sum_{u=1}^H \sum_{v=1}^W \mathbb{I}(\Delta_t(u, v) > \tau) \quad (12)$$

trong đó $\mathbb{I}(\cdot)$ là hàm chỉ thị và τ là ngưỡng phân tách quang học thích ứng.

6.2 Rời Rạc Hóa Cấp Độ Dịch Vụ và Đạo Hàm Xu Hướng

Giá trị $\rho_{\text{phys}}(t)$ được phân loại thành 4 cấp độ dịch vụ chuẩn HCM LoS:

$$\text{LoS}(t) = \begin{cases} 0 & \text{(Free-Flow: Lưu thông tự do, thông thoáng),} & \rho(t) < 0.15 \\ 1 & \text{(Moderate: Dòng xe ổn định, mật độ trung bình),} & 0.15 \leq \rho(t) < 0.35 \\ 2 & \text{(Slow: Mật độ cao, dòng xe di chuyển chậm),} & 0.35 \leq \rho(t) < 0.60 \\ 3 & \text{(Gridlock: Kẹt xe nghiêm trọng, tê liệt),} & \rho(t) \geq 0.60 \end{cases} \quad (13)$$

Đạo hàm xu hướng biến thiên mật độ được mô hình hóa qua sai phân hữu hạn: $\delta(t) = \rho(t) - \rho(t-1) \in [-1, 1]$.

6.3 Kiến Trúc Hợp Nhất Không - Thời Gian (ViT + CNN + Bi-GRU)

Mô hình tiếp nhận chuỗi gồm T khung hình liên tiếp. Tại mỗi bước thời gian t :

1. Vector ngữ nghĩa sâu: $\mathbf{z}_{\text{sem}}^t = \text{DINO}(I_t)_{[CLS]} \in \mathbb{R}^D$.
2. Vector hình thái tiền cảnh: $\mathbf{z}_{\text{spatial}}^t = \text{CNN}(\Delta_t) \in \mathbb{R}^{128}$.
3. Hợp nhất không gian: $\mathbf{x}_t = \text{Linear}([\mathbf{z}_{\text{sem}}^t \parallel \mathbf{z}_{\text{spatial}}^t]) \in \mathbb{R}^{256}$.
4. Mô hình hóa chuỗi qua mạng Bi-GRU 2 tầng: $\mathbf{h}_t = \text{BiGRU}(\mathbf{x}_t, \mathbf{h}_{t-1}) \in \mathbb{R}^{256}$.

Hàm mất mát đa nhiệm tích hợp thành phần làm mịn thời gian:

$$\begin{aligned} \mathcal{L}_{\text{total}} = & \lambda_{\rho} \mathcal{L}_{\text{SmoothL1}}(\hat{\rho}, \rho_{\text{phys}}) + \lambda_{\text{LoS}} \mathcal{L}_{\text{CE}}(\hat{\mathbf{y}}_{\text{LoS}}, \mathbf{y}_{\text{LoS}}) \\ & + \lambda_{\text{trend}} \mathcal{L}_{\text{SmoothL1}}(\hat{\delta}, \delta_{\text{phys}}) + \lambda_{\text{smooth}} \frac{1}{T-1} \sum_{t=1}^{T-1} \|\hat{\rho}_{t+1} - \hat{\rho}_t\|_2^2 \end{aligned} \quad (14)$$

7 TỔNG HỢP VÀ ĐÁNH GIÁ 4 HƯỚNG TIẾP CẬN TRỌNG TÂM

Table 1: Tổng hợp phương pháp luận và tiềm năng công bố của 4 hướng nghiên cứu trọng tâm DINO Suite

Hướng	Tên Nghiên Cứu	Cơ Chế Cốt Lõi	Độ Mới	Venue Đề Xuất
Hướng 1	BG-Guided DINO Continual SSL	Foreground-Aware Masking (FAM) định hướng ViT che và học biểu diễn phương tiện	4/5	IEEE T-ITS, EAAI
Hướng 2	Scene Decomposition Network	Mô hình hóa Alpha Compositing với mô neo giám sát nền tĩnh (Road Inpainting)	5/5	CVPR, ECCV, NeurIPS
Hướng 3	Foreground-Enhanced Counting	Mở rộng Patch Embedding 4 kênh (RGB+ Δ) kết hợp Warm-Start	3.5/5	EAAI Journal, ITSC
Hướng 4	Spatio-Temporal Density & HCM LoS	Bi-GRU kết hợp DINO và Δ -CNN với mô neo ρ_{phys} dự đoán mật độ và LoS	4.5/5	IEEE T-ITS, CVPR

8 KẾT LUẬN

Báo cáo đã hệ thống hóa cơ sở lý thuyết về mô hình học tự giám sát DINO và hoàn thiện bốn hướng nghiên cứu trọng tâm có tính hỗ trợ chặt chẽ nhằm khai thác cấp tín hiệu ảnh hiện trường và ảnh nền tĩnh trong giám sát giao thông đô thị. Hệ sinh thái trải rộng từ tiền huấn luyện thích ứng miền (Hướng 1), phân rã bối cảnh tự thân (Hướng 2), ước lượng lưu lượng phương tiện ít mẫu (Hướng 3), đến dự báo mật độ không-thời gian và cấp độ dịch vụ giao thông (Hướng 4). Việc loại bỏ các hướng nghiên cứu thiếu tính khả thi trong giao thông hỗn hợp giúp tập trung toàn diện nguồn lực vào các bài toán có mô neo vật lý chặt chẽ, nâng cao độ bền vững và khả năng ứng dụng thực tiễn cho hệ thống giao thông thông minh quy mô lớn.