

# BÁO CÁO KHOA HỌC: PHƯƠNG PHÁP LUẬN VÀ THIẾT KẾ KIẾN TRÚC KHAI THÁC CẶP ẢNH NỀN TĨNH VÀ PHƯƠNG TIỆN TRONG THỊ GIÁC GIAO THÔNG VỚI DINO

Nhóm Nghiên Cứu Thị Giác Máy Tính Đô Thị

Ngày 1 tháng 10 năm 2026

## Tóm tắt nội dung

Trong hệ thống camera giám sát giao thông thông minh (CCTV), các thiết bị thu hình cố định cung cấp cặp tín hiệu quang học bổ trợ: ảnh hiện trường ghi nhận phương tiện di chuyển và ảnh nền tĩnh (background) được ước lượng qua chuỗi thời gian. Báo cáo này trình bày cơ sở lý thuyết, mô hình hóa toán học và phương pháp luận của tám hướng nghiên cứu học tự giám sát (Self-Supervised Learning) nhằm khai thác cặp tín hiệu trên. Các nội dung chính bao gồm: (1) Tiền huấn luyện Vision Transformer với chiến lược che có định hướng tiền cảnh (Foreground-Aware Masking); (2) Mạng phân rã bối cảnh tự giám sát (Scene Decomposition Network) dựa trên mô hình hòa trộn Alpha Compositing; (3) Mở rộng biểu diễn Patch Embedding bốn kênh ( $RGB + \Delta$ ) phục vụ bài toán ước lượng lưu lượng phương tiện trong điều kiện ít mẫu (Few-shot learning); (4) Phát hiện bất thường giao thông không giám sát (UAD) dựa trên bộ nhớ đặc trưng  $\Delta$ -Conditioned; (5) Học tương phản chuỗi thời gian (Temporal Contrastive Learning) nhằm ước lượng mật độ và vận tốc dòng xe; (6) Nhận dạng lại phương tiện liên camera (Vehicle Re-ID) không cần Object Detector dựa trên vùng quan tâm  $\Delta$ ; (7) Hiểu cảnh giao thông từ vựng mở (Open-Vocabulary Scene Understanding) kết hợp đề xuất vùng vật lý và không gian ngữ nghĩa CLIP; và (8) Đánh giá đa thuộc tính điều kiện mật đường tự giám sát từ chuỗi ảnh nền 24 giờ. Các phương pháp đề xuất hướng tới tính tối ưu về mặt tính toán, mở rộng khả năng suy luận mở và giảm thiểu sự phụ thuộc vào dữ liệu gán nhãn thủ công.

## 1 ĐẶT VẤN ĐỀ VÀ MÔ HÌNH HÓA TÍN HIỆU QUANG HỌC

Trong bài toán giám sát giao thông đô thị qua camera tĩnh, mỗi khung hình tại thời điểm  $t$  được xem xét dưới hai trạng thái quan sát:

- Khung hình hiện trường** ( $I_{\text{origin}} \in \mathbb{R}^{H \times W \times 3}$ ): Ghi nhận các phương tiện giao thông (xe máy, ô tô, xe buýt, xe tải) chuyển động trên bề mặt tuyến đường, kèm theo các yếu tố biến đổi về mật độ, điều kiện chiếu sáng và mức độ che khuất lẫn nhau.
- Ảnh nền tĩnh** ( $I_{\text{bg}} \in \mathbb{R}^{H \times W \times 3}$ ): Thể hiện cấu trúc mặt đường khi không có phương tiện, được ước lượng thông qua thuật toán lọc trung vị theo thời gian (Temporal Median Filtering) kết hợp chuẩn hóa cường độ trong không gian màu HSV theo từng chu kỳ quan sát.

Mối quan hệ không gian giữa hai khung hình xác lập trường sai khác quang học:

$$\Delta(u, v) = \|I_{\text{origin}}(u, v) - I_{\text{bg}}(u, v)\| \quad (1)$$

Thay vì chỉ áp dụng  $\Delta(u, v)$  trong các thuật toán phân đoạn ngưỡng cổ điển vốn nhạy cảm với biến thiên thời tiết và bóng đổ, hệ sinh thái DINO Suite tích hợp tín hiệu sai khác vật lý này vào không gian biểu diễn sâu của Vision Transformer (ViT), mở ra tám hướng tiếp cận bổ trợ lẫn nhau trong giao thông thông minh.

## 2 CƠ SỞ PHƯƠNG PHÁP LUẬN VỀ HỌC TỰ GIÁM SÁT DINO

### 2.1 Cơ Chế Chứng Cắt Tự Thân và Động Học Ổn Định Biểu Diễn

Kiến trúc DINO (Caron et al., ICCV 2021) dựa trên nguyên lý tự chưng cất tri thức (self-distillation) giữa hai mạng nơ-ron có cấu trúc tham số tương đồng: mạng Student  $g_{\theta_s}$  và mạng Teacher  $g_{\theta_t}$ . Mỗi mạng bao gồm một bộ trích xuất đặc trưng Vision Transformer (ViT) kết hợp đầu chiếu phi tuyến đa tầng (MLP Projection Head) nhằm ánh xạ vector đặc trưng  $[CLS]$  sang không gian phân phối xác suất  $K$  chiều ( $K \in \{4096, 65536\}$ ).

Hệ thống tối ưu hóa vận hành theo quy tắc cập nhật tham số bất đối xứng:

1. **Tối ưu hóa Student qua lan truyền ngược:** Tham số  $\theta_s$  được cập nhật trực tiếp bằng thuật toán AdamW dựa trên độ dốc của hàm mất mát entropy chéo giữa đầu ra Student và Teacher.
2. **Cập nhật Teacher theo trung bình trượt hàm mũ (EMA):** Trọng số của Teacher không tiếp nhận trực tiếp gradient ( $\nabla_{\theta_t} \mathcal{L} = 0$ ), mà tiến hóa theo trung bình trượt động lượng từ tham số Student:

$$\theta_t \leftarrow \lambda \theta_t + (1 - \lambda) \theta_s \quad (2)$$

trong đó hệ số động lượng  $\lambda \in [0.996, 1.0]$  được điều chỉnh tăng dần theo lịch trình cosin. Về mặt giải tích, cơ chế EMA đóng vai trò như bộ lọc thông thấp trong không gian tham số, giúp mạng Teacher cung cấp phân phối xác suất mục tiêu ổn định và có phương sai thấp qua các bước huấn luyện.

3. **Cơ chế kiểm soát sự sụp đổ biểu diễn (Representation Collapse Prevention):** DINO kiểm soát trạng thái suy biến bằng việc kết hợp kỹ thuật định tâm (*Centering*) và kỹ thuật làm nhọn phân phối (*Sharpening*):

$$P_t(x)^{(k)} = \frac{\exp\left(\frac{g_{\theta_t}(x)^{(k)} - c^{(k)}}{\tau_t}\right)}{\sum_{j=1}^K \exp\left(\frac{g_{\theta_t}(x)^{(j)} - c^{(j)}}{\tau_t}\right)}, \quad P_s(x)^{(k)} = \frac{\exp\left(\frac{g_{\theta_s}(x)^{(k)}}{\tau_s}\right)}{\sum_{j=1}^K \exp\left(\frac{g_{\theta_s}(x)^{(j)}}{\tau_s}\right)} \quad (3)$$

trong đó vector định tâm  $c \in \mathbb{R}^K$  ước lượng kỳ vọng bậc một của phân phối đầu ra Teacher, và nhiệt độ  $\tau_t < \tau_s$  tạo hiệu ứng làm nhọn phân phối xác suất.

## 2.2 Sự Phát Triển Kiến Trúc Từ DINOv1 Đến DINOv2

DINOv2 (Oquab et al., Meta AI 2023) mở rộng khung lý thuyết DINO từ việc học biểu diễn toàn cục  $[CLS]$  thành mô hình nền tảng thị giác (Vision Foundation Model) có khả năng sinh biểu diễn dày đặc (dense representations) ở cấp độ từng patch, với các cải tiến kiến trúc then chốt:

1. **Cơ chế học đa nhiệm tích hợp Masked Image Modeling (MIM / iBOT):** DINOv2 kết hợp đồng thời việc tự chứng cất token toàn cục  $[CLS]$  với bài toán phục hồi biểu diễn của các patch bị che ngẫu nhiên:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{DINO}}([CLS]) + \lambda_{\text{patch}} \mathcal{L}_{\text{iBOT}}(\text{Patch Tokens}) \quad (4)$$

2. **Ổn định hóa truyền gradient trên mô hình quy mô lớn:** Áp dụng LayerScale, Pre-LayerNorm, và SwiGLU FFN.
3. **Khử nhiễu đặc trưng cục bộ qua Register Tokens:** Bổ sung 4 register tokens vào chuỗi đầu vào để hấp thụ các tín hiệu kích hoạt ngoại lai trên nền trơn nhẵn (nhựa đường, bầu trời).

## 2.3 Chiến Lược Trích Xuất Đa Góc Nhìn (Multi-Crop)

Chiến lược đa góc nhìn sinh ra tập hợp gồm  $N_g = 2$  góc nhìn toàn cảnh ( $224 \times 224$ , tỷ lệ diện tích  $[0.4, 1.0]$ ) nạp vào cả Teacher và Student, cùng  $N_l = 4$  đến 8 góc nhìn cục bộ ( $96 \times 96$ , tỷ lệ diện tích  $[0.05, 0.4]$ ) chỉ nạp vào Student. Kỳ vọng toán học của độ giao thoa không gian giữa hai góc nhìn toàn cảnh ngẫu nhiên thỏa mãn  $\mathbb{E}[\text{IoU}] \in [0.15, 0.60]$ , ép mô hình vừa học tính bất biến quang học (khi IoU lớn) vừa trừu tượng hóa ngữ cảnh toàn cục của đối tượng (khi  $\text{IoU} \rightarrow 0$ ).

# 3 HƯỚNG 1: BG-GUIDED DINO – TIỀN HUẤN LUYỆN TỰ GIÁM SÁT LIÊN TỤC VỚI FOREGROUND-AWARE MASKING

## 3.1 Hạn Chế của Cơ Chế Che Ngẫu Nhiên Đồng Đều

Trong ảnh camera giao thông đô thị, hơn 70% – 80% diện tích khung hình là nền đường tĩnh, vỉa hè và dải phân cách bê tông. Nếu áp dụng chiến lược che ngẫu nhiên đồng đều (Uniform Random Masking), phần lớn tài nguyên tính toán và gradient cập nhật của ViT bị lãng phí chỉ để tái tạo các mảng nhựa đường vô nghĩa.

## 3.2 Cơ Sở Toán Học của Chiến Lược Che Foreground-Aware Masking (FAM)

Ảnh được chia thành  $N_{\text{patches}} = \left(\frac{H}{P}\right) \times \left(\frac{W}{P}\right)$  patch rời rạc ( $P = 16$ ). Trọng số sai khác trung bình của patch thứ  $p$  được tính trong không gian màu CIE-LAB:

$$w_p = \frac{1}{P^2} \sum_{(u,v) \in \text{Patch}_p} \Delta(u, v) \quad (5)$$

Xác suất để patch  $p$  được lựa chọn che được xác định theo mô hình nội suy tuyến tính:

$$P_{\text{mask}}(p) = \alpha \cdot \frac{w_p}{\max_q w_q + \epsilon} + (1 - \alpha) \cdot \frac{1}{N_{\text{patches}}} \quad (6)$$

với  $\alpha = 0.75$ . Thành phần thứ nhất phân bổ 75% xác suất che tập trung vào các vùng phương tiện (buộc Student phải suy diễn ngữ nghĩa xe từ ngữ cảnh xung quanh), trong khi thành phần thứ hai duy trì 25% phân phối đều để bảo đảm mạng không bỏ sót cấu trúc không gian nền đường.

Hàm mất mát chưng cất đa góc nhìn:

$$\mathcal{L}_{\text{DINO}} = - \sum_{x \in \{V_{\text{masked}}^g, V^l\}} \sum_{x' \in \{V_1^g, V_2^g\}, x' \neq x} P_t(x') \log P_s(x) \quad (7)$$

## 4 HƯỚNG 2: MẠNG PHÂN RÃ BỐI CẢNH TỰ GIÁM SÁT (TRAFFIC-DECOMPOSE)

### 4.1 Mô Hình Hóa Alpha Compositing với Mỏ Neo Nền Tĩnh

Khung cảnh giao thông được mô hình hóa theo phương trình hòa trộn quang học:

$$I_{\text{origin}} = M_{\alpha} \odot I_{\text{fg}} + (1 - M_{\alpha}) \odot I_{\text{bg}} \quad (8)$$

trong đó  $I_{\text{bg}}$  là lớp nền đường sạch bóng xe,  $I_{\text{fg}}$  là lớp chứa phương tiện cô lập, và  $M_{\alpha} \in [0, 1]^{H \times W \times 1}$  là mặt nạ mờ trong suốt (Alpha Matte).

Để giải bài toán nghịch đảo thiếu ràng buộc này, nghiên cứu sử dụng ảnh nền tĩnh thật  $I_{\text{bg\_real}}$  làm mỏ neo vật lý giám sát tự thân. Mạng nơ-ron sử dụng chung bộ trích xuất đặc trưng ViT và phân nhánh thành ba đầu giải mã (Background Head, Foreground Head, Alpha Head).

### 4.2 Hàm Mất Mát Đa Ràng Buộc Vật Lý

$$\mathcal{L}_{\text{total}} = \lambda_{\text{rec}} \mathcal{L}_{\text{recon}} + \lambda_{\text{bg}} \mathcal{L}_{\text{bg}} + \lambda_{\text{sparse}} \mathcal{L}_{\text{sparcity}} + \lambda_{\text{tv}} \mathcal{L}_{\text{tv}} \quad (9)$$

- $\mathcal{L}_{\text{recon}} = \|I_{\text{origin}} - \hat{I}_{\text{origin}}\|_1 + (1 - \text{SSIM}(I_{\text{origin}}, \hat{I}_{\text{origin}}))$ : Đảm bảo tái tạo hoàn hảo ảnh gốc.
- $\mathcal{L}_{\text{bg}} = \|\hat{I}_{\text{bg}} - I_{\text{bg\_real}}\|_1$ : Khóa chặt nhánh nền vào lòng đường thực tế, buộc nhánh  $I_{\text{fg}}$  và  $M_{\alpha}$  phải hấp thụ toàn bộ phương tiện chuyển động.
- $\mathcal{L}_{\text{sparcity}} = \frac{1}{HW} \sum_{u,v} M_{\alpha}(u,v)$ : Ngăn chặn nghiệm suy biến  $M_{\alpha} = 1$ .
- $\mathcal{L}_{\text{tv}} = \text{TotalVariation}(M_{\alpha})$ : Khử nhiễu đốm và làm mịn đường biên thân xe.

Mô hình cho phép tự động xóa sạch phương tiện (Unsupervised Road Inpainting) trực tiếp từ một khung hình đơn lẻ.

## 5 HƯỚNG 3: MỞ RỘNG BIỂU DIỄN TIỀN CẢNH BỐN KÊNH TRONG ƯỚC LƯỢNG LƯU LƯỢNG PHƯƠNG TIỆN

### 5.1 Mở Rộng Tensor Đầu Vào và Khởi Tạo Thích Ứng Ấm

Bài toán ước lượng lưu lượng phương tiện đối mặt với hiện tượng che khuất nghiêm trọng trong giờ cao điểm và điều kiện học ít mẫu (Few-shot learning: 5%, 10%, 20% nhãn). Tensor đầu vào được mở rộng thành bốn kênh:

$$X_{4ch} = [R, G, B, \Delta_{norm}] \in \mathbb{R}^{4 \times H \times W} \quad (10)$$

Nhằm bảo toàn tri thức tiền huấn luyện của ViT, thuật toán Warm-Start Weight Adaptation được áp dụng cho ma trận trọng số Patch Embedding  $W_{4ch} \in \mathbb{R}^{D \times 4 \times P \times P}$ :

$$W_{4ch}[:, 0 : 3, :, :] = W_{pretrained}, \quad W_{4ch}[:, 3, :, :] = \frac{1}{3} \sum_{c=0}^2 W_{pretrained}[:, c, :, :] \quad (11)$$

Trọng số kênh  $\Delta$  nhận trung bình cộng ba kênh màu RGB, bảo đảm tại bước huấn luyện đầu tiên kênh sai khác đóng góp năng lượng đồng mức mà không gây sốc gradient cho mạng nơ-ron. Đánh giá được thực hiện qua giao thức phân chia camera phân tách độc lập (Spatial Disjoint Splitting) nhằm triệt tiêu hiện tượng rò rỉ dữ liệu bối cảnh.

## 6 HƯỚNG 4: PHÁT HIỆN BẤT THƯỜNG GIAO THÔNG KHÔNG GIÁM SÁT VỚI BỘ NHỚ ĐẶC TRƯNG $\Delta$ -CONDITIONED

### 6.1 Đặt Vấn Đề và Giả Thuyết Khoa Học

Các sự kiện bất thường (tai nạn, xe dừng đỗ trái phép, phương tiện đi ngược chiều, vật cản rơi vãi) mang bản chất cực kỳ hiếm gặp, khiến việc xây dựng mô hình phân loại có giám sát gặp rào cản dữ liệu nhãn.

- **Trạng thái bình thường:** Trường sai khác  $\Delta$  tuân theo phân phối ổn định  $\mathcal{D}_{normal}$  phản ánh sự chuyển động nhịp nhàng của dòng xe.
- **Trạng thái bất thường:** Khi xảy ra sự cố,  $\Delta$  lệch khỏi phân phối bình thường về cả cường độ tĩnh (vùng  $\Delta$  lớn cố định qua nhiều frame) lẫn vị trí không gian bất thường trên mặt đường.

### 6.2 Bộ Mô Tả Kép và Ngân Hàng Nhớ Anomaly Score

Vector đặc trưng được xây dựng kết hợp giữa thống kê vật lý quang học và ngữ nghĩa sâu DINO:

$$\mathbf{f}_{anomaly} = \text{Concat}([mean(\Delta), std(\Delta), ratio(\Delta > \tau)], DINO_{[CLS]}) \in \mathbb{R}^{D+3} \quad (12)$$

Hệ thống duy trì một ngân hàng nhớ (Memory Bank) lưu trữ các vector đại diện trạng thái bình thường, được cập nhật theo cơ chế trung bình trượt hàm mũ (EMA). Điểm bất thường (Anomaly

Score) được tính dựa trên khoảng cách  $k$  láng giềng gần nhất ( $k$ -NN):

$$\text{Score}(x) = \frac{1}{k} \sum_{j=1}^k \|\mathbf{f}_x - \mathbf{m}_j\|_2, \quad \mathbf{m}_j \in \text{Top-}k\text{-NN}(\mathbf{f}_x, \text{MemoryBank}) \quad (13)$$

Phương pháp cho phép phát hiện sự cố theo thời gian thực mà hoàn toàn không cần dữ liệu huấn luyện có nhãn bất thường.

## 7 HƯỚNG 5: HỌC TƯƠNG PHẢN CHUỖI THỜI GIAN CHO ƯỚC LƯỢNG MẬT ĐỘ VÀ VẬN TỐC DÒNG XE

### 7.1 Mô Hình Hóa Động Học Thời Gian

Camera CCTV cung cấp luồng quan sát chuỗi thời gian liên tục  $\{I^{t_1}, \dots, I^{t_T}\}$ . Tốc độ di chuyển và mức độ ùn tắc được phản ánh trực tiếp qua đạo hàm biến thiên thời gian của trường sai khác  $\frac{\partial \Delta}{\partial t}$ .

Hệ thống tổ chức dữ liệu thành các cửa sổ trượt kích thước  $K$  khung hình. Hai cửa sổ liền kề  $W_a = [I^{t_1}, \dots, I^{t_K}]$  và  $W_b^+ = [I^{t_{K+1}}, \dots, I^{t_{2K}}]$  từ cùng một camera tạo thành cặp đường tự nhiên.

### 7.2 Kiến Trúc Temporal Transformer và Mất Mất InfoNCE Thời Gian

Mỗi khung hình được mã hóa đồng thời qua DINO ViT và mạng tích chập DeltaSpatialEncoder:

$$\mathbf{e}_t = \text{Linear}(\text{DINO}(I^t) \oplus \text{CNN}(\Delta^t)) + \text{PE}(t) \quad (14)$$

Chuỗi  $[\mathbf{e}_1, \dots, \mathbf{e}_K]$  được đưa qua khối Temporal Self-Attention Transformer để sinh ra vector biểu diễn động học thời gian  $\mathbf{h} \in \mathbb{R}^{256}$ . Mạng tối ưu hóa hàm mất mát tương phản đối xứng (Symmetric InfoNCE):

$$\mathcal{L}_{\text{temporal}} = -\frac{1}{2} \left[ \log \frac{\exp(\mathbf{z}_a \cdot \mathbf{z}_b^+ / \tau)}{\sum_j \exp(\mathbf{z}_a \cdot \mathbf{z}_j^- / \tau)} + \log \frac{\exp(\mathbf{z}_b^+ \cdot \mathbf{z}_a / \tau)}{\sum_j \exp(\mathbf{z}_b^+ \cdot \mathbf{z}_j^- / \tau)} \right] \quad (15)$$

Vector  $\mathbf{h}$  đóng vai trò làm đặc trưng nền tảng để dự đoán mật độ lưu lượng phương tiện và chỉ số mức độ phục vụ (Level of Service).

## 8 HƯỚNG 6: NHẬN DẠNG LẠI PHƯƠNG TIỆN LIÊN CAMERA DỰA TRÊN VÙNG QUAN TÂM $\Delta$

### 8.1 Trích Xuất Vùng Xe Không Cần Object Detector

Các phương pháp nhận dạng lại phương tiện (Vehicle Re-ID) truyền thống đòi hỏi bộ dò vật thể (YOLO/Faster R-CNN) gây tốn kém tài nguyên tính toán. Hướng tiếp cận này khai thác trực tiếp bản đồ sai khác  $\Delta$  qua thuật toán phân tích thành phần liên thông (Connected Components) kết hợp bộ lọc diện tích và tỷ lệ khung hình:

$$\text{RoI}_i = \text{ConnectedComponents}(\text{MorphClose}(\Delta > \tau_{\text{Otsu}}))_i \quad (16)$$

Các vùng xe hợp lệ được cắt tự động và chuẩn hóa về kích thước  $256 \times 128$ .

## 8.2 Kiến Trúc BNNeck và Học Tự Giám Sát Qua Chuỗi Tracklet

Mạng VehicleReIDModel sử dụng DINO ViT kết hợp cấu trúc cổ chai Batch Normalization Neck (BNNeck) tạo ra vector nhúng danh tính  $\mathbf{e}_i \in \mathbb{R}^{256}$  chuẩn hóa  $L_2$ .

Các góc nhìn khác nhau của cùng một phương tiện trong chuỗi khung hình liên tiếp của một camera tạo thành một tracklet tự nhiên (cặp dương tự thân), trong khi các phương tiện khác nhau tạo thành cặp âm. Mạng tối ưu hóa hàm mất mát Tracklet Contrastive Loss:

$$\mathcal{L}_{\text{ReID}} = - \sum_i \log \frac{\sum_{p \in \mathcal{P}_i} \exp(\mathbf{e}_i \cdot \mathbf{e}_p / \tau)}{\sum_{p \in \mathcal{P}_i} \exp(\mathbf{e}_i \cdot \mathbf{e}_p / \tau) + \sum_{n \in \mathcal{N}_i} \exp(\mathbf{e}_i \cdot \mathbf{e}_n / \tau)} \quad (17)$$

Hiệu năng so khớp liên camera được đánh giá khách quan qua đường cong tích lũy đặc trưng (CMC Rank-1, Rank-5) và mean Average Precision (mAP).

## 9 HƯỚNG 7: HIỂU CẢNH GIAO THÔNG TỪ VÙNG MỎ VỚI ĐỀ XUẤT VÙNG KHÔNG PHỤ THUỘC LỚP

### 9.1 Đề Xuất Vùng Vật Lý (Delta Region Proposals)

Các mô hình nhận diện thông thường bị giới hạn trong tập danh mục khép kín cố định. Nhằm nhận diện linh hoạt các phương tiện đặc thù đô thị (xe cứu thương, xe rác, xe ba gác, chướng ngại vật rơi vãi), động cơ DeltaProposalEngine sinh ra các hộp đề xuất vùng không phụ thuộc lớp (Class-Agnostic Proposals) từ bản đồ  $\Delta$  đa ngưỡng và áp dụng Non-Maximum Suppression (NMS).

### 9.2 Căn Chính Không Gian Thị Giác – Ngôn Ngữ DINO-CLIP

Mỗi vùng đề xuất  $r$  được trích xuất đặc trưng qua DINO ViT và ánh xạ qua bộ chiếu đa tầng sang không gian văn bản CLIP (512 chiều):

$$\mathbf{z}_r = \text{Normalize}(\text{Projector}(\text{DINO}(r))) \in \mathbb{R}^{512} \quad (18)$$

Xác suất phân loại không gian mở của vùng  $r$  đối với danh mục văn bản tự nhiên  $c$  (được mã hóa bởi CLIP Text Encoder thành vector  $\mathbf{w}_c$ ) được xác định bởi:

$$P(c|r) = \frac{\exp((\mathbf{z}_r \cdot \mathbf{w}_c)/\tau)}{\sum_{k=1}^C \exp((\mathbf{z}_r \cdot \mathbf{w}_k)/\tau)} \quad (19)$$

Hệ thống cho phép người vận hành truy vấn bất kỳ thực thể giao thông nào bằng câu mô tả văn bản tự nhiên tiếng Việt hoặc tiếng Anh mà không cần huấn luyện lại mạng.

## 10 HƯỚNG 8: ƯỚC LƯỢNG ĐA THUỘC TÍNH TÌNH TRẠNG MẶT ĐƯỜNG TỰ GIÁM SÁT

### 10.1 Khai Thác Chuỗi Ảnh Nền 24 Giờ

Kho ảnh nền tĩnh  $\{I_{\text{bg}}^{h=0}, \dots, I_{\text{bg}}^{h=23}\}$  trên 608 camera ghi nhận đầy đủ sự biến đổi môi trường của hạ tầng đường bộ đô thị theo thời gian:

- Điều kiện thời tiết: Mặt đường khô ráo vs. mặt đường ẩm ướt / động nước mưa (thể hiện qua các vùng phản chiếu gương Specular Reflection).
- Chu kỳ chiếu sáng: Ban ngày, hoàng hôn chạng vạng và chiếu sáng nhân tạo ban đêm.
- Chất lượng hạ tầng: Độ gồ ghề, ổ gà, bong tróc nứt nẻ mặt đường (phản ánh qua độ nhám gradient kết cấu).

## 10.2 Kiến Trúc Đa Nhiệm và Mất Mát Mỏ Neo Vật Lý

Mô hình RoadConditionClassifier sử dụng DINO ViT trích xuất vector kết cấu mặt đường  $\mathbf{z}_{\text{road}}$  từ  $[CLS]$  token và phân nhánh thành ba đầu dự đoán đồng thời:

1. Chỉ số ẩm ướt mặt đường  $\hat{y}_{\text{wet}} \in [0, 1]$  qua hàm kích hoạt Sigmoid.
2. Phân loại 3 trạng thái chiếu sáng  $\hat{\mathbf{y}}_{\text{illum}} \in \mathbb{R}^3$  (Đêm, Chạng vạng, Ngày).
3. Chỉ số suy giảm kết cấu mặt đường  $\hat{y}_{\text{deg}} \in [0, 1]$  phản ánh độ nứt nẻ ổ gà.

Hàm mất mát kết hợp mỏ neo vật lý sơ cấp:

$$\mathcal{L}_{\text{surface}} = \mathcal{L}_{\text{CE}}(\hat{\mathbf{y}}_{\text{illum}}, y_{\text{illum}}) + \lambda_1 \|\hat{y}_{\text{wet}} - s_{\text{specular}}\|_2^2 + \lambda_2 \|\hat{y}_{\text{deg}} - s_{\text{roughness}}\|_2^2 \quad (20)$$

Hệ thống tự động gom cụm phân tích PCA 2D và xuất báo cáo tình trạng toàn đô thị phục vụ công tác bảo trì hạ tầng giao thông thông minh.

# 11 TỔNG HỢP VÀ ĐÁNH GIÁ CÁC HƯỚNG TIẾP CẬN

## 12 KẾT LUẬN

Báo cáo đã hệ thống hóa cơ sở lý thuyết về mô hình học tự giám sát DINO và đề xuất tám hướng nghiên cứu có tính bổ trợ chặt chẽ nhằm khai thác cấp tín hiệu ảnh hiện trường và ảnh nền tĩnh trong giám sát giao thông đô thị. Hệ sinh thái trải rộng từ tiền huấn luyện thích ứng miền (Hướng 1), phân rã bối cảnh tự thân (Hướng 2), ước lượng lưu lượng phương tiện ít mẫu (Hướng 3), phát hiện sự cố bất thường không giám sát (Hướng 4), học tương phản chuỗi thời gian (Hướng 5), nhận dạng lại phương tiện liên camera (Hướng 6), hiểu cảnh từ vệt mở (Hướng 7), đến đánh giá điều kiện mặt đường đô thị (Hướng 8). Việc kết hợp có hệ thống giữa các đặc tính quang học vật lý và mô hình nền tảng thị giác giúp giải quyết triệt để bài toán thiếu hụt dữ liệu gắn nhãn, nâng cao độ bền vững và mở rộng khả năng suy luận thông minh cho các hệ thống giao thông đô thị quy mô lớn.

Bảng 1: Tổng hợp phương pháp luận và tiềm năng công bố của tám hướng nghiên cứu DINO Suite

| Hướng          | Tên Nghiên Cứu                            | Cơ Chế Cốt Lõi                                                                   | Độ Mới | Venue Đề Xuất       |
|----------------|-------------------------------------------|----------------------------------------------------------------------------------|--------|---------------------|
| <b>Hướng 1</b> | BG-Guided DINO<br>Continual SSL           | Foreground-Aware Masking (FAM) định hướng ViT che và học biểu diễn phương tiện   | 4/5    | IEEE EAAI T-ITS,    |
| <b>Hướng 2</b> | Scene Decomposition<br>Network            | Mô hình hóa Alpha Compositing với mô neo giám sát nền tĩnh (Road Inpainting)     | 5/5    | CVPR, ECCV, NeurIPS |
| <b>Hướng 3</b> | Foreground-Enhanced<br>Counting           | Mở rộng Patch Embedding 4 kênh (RGB+ $\Delta$ ) kết hợp Warm-Start               | 3/5    | EAAI ITSC Journal,  |
| <b>Hướng 4</b> | Unsupervised Traffic<br>Anomaly Detection | Biểu diễn kép $\Delta$ +DINO, Memory Bank với cập nhật EMA phát hiện sự cố       | 4/5    | IEEE WACV T-ITS,    |
| <b>Hướng 5</b> | Temporal Contrastive<br>Density           | Học tương phản thời gian trên chuỗi $\Delta$ -Maps để ước lượng mật độ và tốc độ | 4.5/5  | CVPR, IEEE ITS      |
| <b>Hướng 6</b> | Delta-Guided Vehicle<br>Re-ID             | Trích xuất RoI từ $\Delta$ , BNNeck DINO, tracklet contrastive, xếp hạng CMC/mAP | 4/5    | IEEE ICPR T-ITS,    |
| <b>Hướng 7</b> | Open-Vocabulary<br>Scene Understanding    | $\Delta$ proposals không phụ thuộc lớp kết hợp căn chỉnh DINO sang CLIP text     | 4/5    | ECCV, WACV          |
| <b>Hướng 8</b> | Road Surface Condi-<br>tion Estimation    | Đánh giá đa thuộc tính mặt đường (động nước, chiếu sáng, hư hại) từ ảnh nền 24h  | 3.5/5  | IEEE TRB T-ITS,     |