

# PHƯƠNG PHÁP LUẬN VÀ THIẾT KẾ MÔ HÌNH HỌC TỰ GIÁM SÁT TRONG HỆ SINH THÁI DINO TRAFFIC SUITE CHO CAMERA GIAO THÔNG ĐÔ THỊ

Nhóm Nghiên Cứu Thị Giác Máy Tính Giao Thông Đô Thị TP.HCM

Ngày 8 tháng 10 năm 2026

## Tóm tắt nội dung

Mạng lưới camera giám sát giao thông đô thị tại TP.HCM vận hành trong môi trường thực địa vô cùng phức tạp: xe máy chiếm ưu thế vượt trội (75%–85% lưu lượng), mật độ dòng phương tiện hỗn hợp dày đặc gây che khuất liên tục, góc quay camera xiên cao và dữ liệu ảnh chỉ được cập nhật ngắt quãng theo chu kỳ 3–5 phút do giới hạn hạ tầng truyền dẫn diện rộng. Trong điều kiện này, các giả định cổ điển về dòng quang học liên tục (Optical Flow) hay ảnh nền trung vị tĩnh hoàn toàn bị phá vỡ bởi hiện tượng bóng ma phương tiện dừng đỗ (Ghost Vehicles) và biến thiên quang học nhiệt đới. Báo cáo khoa học này trình bày chi tiết nền tảng toán học, phân tích giải tích và kiến trúc của hệ sinh thái nghiên cứu **DINO Traffic Suite**, tập trung làm rõ hai hướng nghiên cứu mũi nhọn đột phá hoàn toàn không phụ thuộc ảnh nền mẫu (Prior-Free) cùng hai hướng nghiên cứu suy luận ứng dụng và hệ thống đối chuẩn: (1) **Hướng 1 Mới (Vehicle-Centric Representation Learning)**: Tự học biểu diễn đặc trưng phương tiện bất biến bối cảnh độc lập với ảnh nền mẫu thông qua bản đồ dị biệt thời gian TAM, cơ chế che phân tầng thích ứng AGM và toán tử hoán đổi vùng tĩnh phản thực nghiệm SRS; (2) **Hướng 2 Mới (Prior-Free Traffic Scene Decomposition)**: Phân rã cấu trúc cảnh giao thông hai giai đoạn không cần ảnh nền mốc thông qua hệ cơ sở đa chiều sáng SceneBasis thích ứng trực tuyến với độ bất định Laplace; (3) **Hướng 3 (Context-Aware Weak Supervision)**: Mô hình hóa đồ thị xác suất Markov ẩn thích ứng 54 ngữ cảnh đô thị nhằm tổng hợp nhân yếu đa nguồn từ các bộ suy diễn kiên cố và chứng cất tri thức sang mạng nơ-ron chuỗi thời gian Causal GRU; (4) **Hướng 4 (Persistence Traffic Anomaly Detection)**: Phát hiện sự cố giao thông kéo dài bằng phép lọc trung vị thời gian trên không gian đặc trưng patch DINOv3, kết hợp ngân hàng mẫu chuẩn Coreset Bank và cơ chế phân tách lỗi dịch chuyển camera khỏi bất thường lòng đường; đi kèm hệ thống mô hình đối chuẩn nền trung vị (Baseline Hướng 1 FAM- $\Delta$ , Baseline Hướng 2 Median Prior) và công trình dữ liệu quy mô thành phố IC4SD-TrafficSnap. Toàn bộ phương pháp luận được thiết kế gắn liền với các ràng buộc vật lý thực địa và kiểm chứng định lượng trên mạng lưới camera thực tế quy mô thành phố.

## Mục lục

### 1 BỐI CẢNH VẬT LÝ VÀ PHÂN TÍCH SAI SỐ QUANG HỌC ĐÔ THỊ

2

|          |                                                                                                         |           |
|----------|---------------------------------------------------------------------------------------------------------|-----------|
| 1.1      | Đặc Thù Mạng Lưới Giám Sát Giao Thông Đô Thị TP.HCM . . . . .                                           | 2         |
| 1.2      | Bản Chất Sai Số của Ảnh Nền Trung Vị và Cạm Bẫy Học Biểu Diễn . . . . .                                 | 2         |
| 1.3      | Định Vị Phương Pháp Luận Của Hệ Sinh Thái . . . . .                                                     | 3         |
| <b>2</b> | <b>NỀN TẢNG PHƯƠNG PHÁP LUẬN VÀ XỬ LÝ NHIỀU MÔI TRƯỜNG</b>                                              | <b>3</b>  |
| 2.1      | Ước Lượng Độ Tin Cậy Vùng Tỉnh . . . . .                                                                | 3         |
| 2.2      | Căn Chỉnh Sai Lệch Trục Quang Học Camera . . . . .                                                      | 4         |
| 2.3      | Tối Ưu Hóa Tính Toán Phân Tán và Huấn Luyện Đa GPU . . . . .                                            | 4         |
| <b>3</b> | <b>HƯỚNG 1 MỚI: TỰ HỌC BIỂU DIỄN PHƯƠNG TIỆN BẤT BIẾN BỐI CẢNH (PRIOR-FREE VEHICLE-CENTRIC SSL)</b>     | <b>4</b>  |
| 3.1      | Đặt Vấn Đề Khoa Học và Sự Đột Phá Của Hướng 1 Mới . . . . .                                             | 4         |
| 3.2      | Khung Lý Thuyết Bản Đồ Dị Biệt Thời Gian TAM . . . . .                                                  | 5         |
| 3.3      | Cơ Chế Che Phên Tầng Thích Ứng AGM . . . . .                                                            | 6         |
| 3.4      | Toán Tử Hoán Đổi Vùng Tỉnh Phản Thực Nghiệm SRS . . . . .                                               | 6         |
| 3.5      | Hàm Mất Mất Chứng Cắt Tự Thân Đa Tầng . . . . .                                                         | 6         |
| <b>4</b> | <b>HƯỚNG 2 MỚI: PHÂN RÃ CẢNH GIAO THÔNG ĐỘC LẬP KHÔNG DỪNG ẢNH NỀN (PRIOR-FREE SCENE DECOMPOSITION)</b> | <b>7</b>  |
| 4.1      | Khuyết Tật Của Mô Hình Phụ Thuộc Nền Cũ và Đột Phá Hướng 2 Mới . . . . .                                | 7         |
| 4.2      | Giai Đoạn 1: Học Đa Tập Ánh Sáng Nền SceneBasis Bằng Thuật Toán Lặp Huber-IRLS                          | 7         |
| 4.3      | Giai Đoạn 2: Mạng Phân Rã Sâu Với Bộ Giải Hệ Số Ánh Sáng Trực Tuyến . . . . .                           | 7         |
| 4.4      | Hàm Mất Mất Laplace Negative Log-Likelihood . . . . .                                                   | 8         |
| <b>5</b> | <b>HƯỚNG 3: HỌC GIÁM SÁT YẾU THÍCH ỨNG THEO NGỮ CẢNH ĐÔ THỊ</b>                                         | <b>8</b>  |
| 5.1      | Tổng Hợp Nhân Yếu Đa Nguồn và Cơ Chế Kiềm Cữ . . . . .                                                  | 8         |
| 5.2      | Mô Hình Đồ Thị Xác Suất Markov Ẩn 54 Ngữ Cảnh . . . . .                                                 | 9         |
| 5.3      | Chứng Cắt Tri Thức Sang Mô Hình Dích Chuỗi Thời Gian . . . . .                                          | 9         |
| <b>6</b> | <b>HƯỚNG 4: PHÁT HIỆN SỰ CỐ BẤT THƯỜNG KÉO DÀI VÀ PHÂN TÁCH LỖI CAMERA</b>                              | <b>10</b> |
| 6.1      | Phép Lọc Trung Vị Thời Gian Trên Không Gian Đặc Trưng Patch . . . . .                                   | 10        |
| 6.2      | Ngân Hàng Đặc Trưng Chuẩn Nén Coreset Memory Bank . . . . .                                             | 10        |
| 6.3      | Cơ Chế Phân Tách Lỗi Camera Khỏi Sự Cố Lòng Đường . . . . .                                             | 10        |
| <b>7</b> | <b>HỆ THỐNG MÔ HÌNH ĐỐI CHUẨN VÀ CÔNG BỐ DỮ LIỆU</b>                                                    | <b>11</b> |

|     |                                                   |    |
|-----|---------------------------------------------------|----|
| 7.1 | Hệ Thống Mô Hình Đối Chuẩn Nền Trung Vị . . . . . | 11 |
| 7.2 | Công Trình Dữ Liệu IC4SD-TrafficSnap . . . . .    | 11 |

## 8 KẾT LUẬN 12

---

# 1 BỐI CẢNH VẬT LÝ VÀ PHÂN TÍCH SAI SỐ QUANG HỌC ĐÔ THỊ

## 1.1 Đặc Thù Mạng Lưới Giám Sát Giao Thông Đô Thị TP.HCM

Hệ thống quản lý giao thông thông minh tại TP.HCM vận hành hơn 600 trạm camera quan sát công cộng trải rộng trên địa bàn đô thị. Dữ liệu hình ảnh ghi nhận từ hệ thống sở hữu các đặc tính vật lý và cấu trúc vận hành chuyên biệt:

1. **Dòng giao thông xe máy mật độ cao:** Khác biệt với mạng lưới giao thông tại các quốc gia phát triển nơi ô tô chiếm phần lớn diện tích mặt đường, giao thông tại TP.HCM có tỷ lệ xe hai bánh chiếm 75%–85% lưu lượng. Kích thước hình học nhỏ, khoảng cách di chuyển giữa các xe sát nhau và quỹ đạo chuyển động phi tuyến tính dẫn đến tình trạng che khuất lẫn nhau ở mức độ rất nghiêm trọng.
2. **Cơ chế cập nhật ảnh thưa theo thời gian:** Băng thông truyền dẫn mạng diện rộng và chính sách đệm của máy chủ trung tâm quy định chu kỳ lấy mẫu ảnh chụp tĩnh ngắt quãng, dao động từ 3 đến 5 phút cho mỗi khung hình tại một vị trí. Do bước nhảy thời gian  $\Delta t \gg 1$  giây, toàn bộ các thuật toán thị giác dựa trên giả định chuyển động vi phân liên tục như Optical Flow hay các kiến trúc theo dõi quỹ đạo liên khung hình đều không thể áp dụng.
3. **Góc quan sát xiên cao và rung chấn cơ học:** Camera được lắp đặt trên các cột đèn chiếu sáng hoặc trụ giao lộ ở độ cao 6–15 m với khoảng cách quan sát thực địa 15–60 m. Khi gặp gió bão nhiệt đới hoặc rung chấn cơ học từ các phương tiện tải trọng lớn lưu thông trên cầu, trục quang học của camera thường xuyên bị dịch chuyển vài pixel đến vài chục pixel, gây trôi dạt tọa độ điểm ảnh nền.

## 1.2 Bản Chất Sai Số của Ảnh Nền Trung Vị và Cạm Bẫy Học Biểu Diễn

Trong các hệ thống phân tích video giám sát cổ điển, ảnh nền thường được tái tạo bằng phép lọc trung vị thời gian (Temporal Median Filtering) theo từng khung giờ trong ngày:

$$B_{\text{median}}(u, v) = \text{median}_{k=1}^K \{I_{t_k}(u, v)\} \quad (1)$$

với  $\{I_{t_k}\}_{k=1}^K$  là tập hợp các khung hình thu thập được tại cùng một khung giờ qua nhiều ngày quan sát. Tuy nhiên, trong điều kiện thực tế của đô thị nhiệt đới, ảnh nền trung vị bộc lộ các sai số bản chất nghiêm trọng:

- **Hiện tượng bóng ma phương tiện (Ghost Vehicles):** Tại các trục đường cửa ngõ và nút giao thường xuyên xảy ra ùn ứ kéo dài, phương tiện di chuyển với vận tốc gần như bằng không trong suốt 20–40 phút của giờ cao điểm. Phép lấy trung vị theo thời gian vô tình gộp các phương tiện này vào ảnh nền, biến chúng thành các bóng mờ vĩnh viễn trên mặt đường.
- **Nhiều loạn quang học nhiệt đới:** Ánh nắng nhiệt đới gay gắt tạo ra bóng đổ sắc nét di chuyển liên tục theo góc phương vị mặt trời. Khi có mưa rào, vũng nước trên mặt đường nhựa phản chiếu hình ảnh phương tiện và bầu trời, làm sai lệch phép trừ điểm ảnh thô  $\Delta(u, v) = |I(u, v) - B_{\text{median}}(u, v)|$ . Vào ban đêm, hiện tượng chói lóa từ đèn pha xe tải và xe máy làm bão hòa cảm biến CMOS.
- **Cạm bẫy đường tắt bối cảnh (Background Shortcut Trap):** Trong ảnh chụp từ camera tĩnh, diện tích vùng tĩnh (mặt đường, vỉa hè, nhà cửa, dải phân cách) chiếm từ 70% đến 85% tổng số điểm ảnh. Khi huấn luyện các mô hình học tự giám sát tiêu chuẩn như DINO hay MAE trên tập dữ liệu này, mạng nơ-ron có xu hướng tối ưu hóa hàm mất mát bằng cách ghi nhớ kết cấu bối cảnh tĩnh và góc đặt camera thay vì học các đặc trưng hình học của phương tiện. Hệ quả là biểu diễn trích xuất bị phụ thuộc chặt vào camera cụ thể và mất hoàn toàn khả năng khái quát hóa khi áp dụng sang camera mới.

### 1.3 Định Vị Phương Pháp Luận Của Hệ Sinh Thái

Nhằm giải quyết triệt để các hạn chế trên, hệ sinh thái DINO Traffic Suite được thiết lập dựa trên nguyên lý phân tầng:

1. **Nhóm mô hình độc lập hoàn toàn với ảnh nền mẫu (Prior-Free):** Trích xuất đặc trưng phương tiện và phân rã cấu trúc cảnh trực tiếp từ dòng dữ liệu ảnh đơn hoặc chuỗi ảnh đa ngày mà không cần sử dụng bất kỳ ảnh nền trung vị tham chiếu nào (**Hướng 1 Mới** và **Hướng 2 Mới**).
2. **Nhóm mô hình giám sát thông minh và phát hiện sự cố (Context-Aware & Anomaly):** Tự động thích ứng với sự thay đổi của ngữ cảnh đô thị để sinh nhân huấn luyện (**Hướng 3**) và phát hiện các biến cố giao thông bất thường kéo dài bằng cách phân tách rõ ràng sai lệch quang học khỏi sự cố mặt đường (**Hướng 4**).
3. **Hệ thống đối chuẩn có kiểm soát độ bất định (Baselines):** Duy trì các mô hình sử dụng ảnh nền trung vị truyền thống nhưng được trang bị cơ chế tự động điều chỉnh độ tin cậy để so sánh đối đầu trực tiếp về mặt học thuật.

## 2 NỀN TẢNG PHƯƠNG PHÁP LUẬN VÀ XỬ LÝ NHIỀU MÔI TRƯỜNG

### 2.1 Ước Lượng Độ Tin Cậy Vùng Tĩnh

Để đánh giá mức độ ổn định quang học của từng khung hình, tập hợp các điểm ảnh thuộc vùng tĩnh vật lý  $S$  được xác định dựa trên phương sai cường độ ánh sáng qua chuỗi thời gian nhiều ngày:

$$S = \{(u, v) \mid \text{Var}_t(I_t(u, v)) < \tau_{\text{var}}^2\} \quad (2)$$

Điểm ảnh thuộc  $S$  tương ứng với các cấu trúc kiến trúc cố định (tòa nhà, cột biển báo) ít chịu ảnh hưởng của luồng xe cộ. Đối với mỗi khung hình  $I_i$ , mức độ suy thoái của nền được đo lường thông qua độ lệch trung bình trên vùng tĩnh  $\bar{\Delta}_{\text{static}}$ :

$$\bar{\Delta}_{\text{static}} = \frac{1}{|S|} \sum_{(u,v) \in S} |I_i(u, v) - B_{\text{median}}(u, v)| \quad (3)$$

Hệ số độ tin cậy nền  $r_i \in (0, 1]$  được tính toán bằng hàm suy giảm hàm mũ:

$$r_i = \exp\left(-\frac{\bar{\Delta}_{\text{static}}}{\kappa}\right) \quad (4)$$

trong đó  $\kappa$  là hệ số tỷ lệ nhiệt độ quang học. Khi xảy ra biến động mạnh về thời tiết, chiếu sáng hoặc camera bị xô lệch,  $r_i$  tiến gần về 0, đóng vai trò là van điều tiết vô hiệu hóa ảnh hưởng của ảnh nền đối với các mô hình phụ thuộc.

### 2.2 Căn Chỉnh Sai Lệch Trục Quang Học Camera

Khi camera bị gió làm rung lắc hoặc bị can thiệp vật lý làm xoay góc nhìn, thuật toán tương quan pha trong miền tần số (Phase Correlation) được áp dụng trên vùng tĩnh  $S$ . Tọa độ dịch chuyển  $(\Delta x, \Delta y)$  giữa khung hình hiện tại  $I_i$  và khung hình chuẩn  $I_0$  được ước lượng thông qua ma trận mật độ phổ chéo:

$$R = \frac{\mathcal{F}\{I_i\} \odot \mathcal{F}\{I_0\}^*}{|\mathcal{F}\{I_i\} \odot \mathcal{F}\{I_0\}^*|}, \quad (\Delta x, \Delta y) = \arg \max_{(x,y)} \{\mathcal{F}^{-1}\{R\}\} \quad (5)$$

với  $\mathcal{F}$  biểu thị phép biến đổi Fourier nhanh 2 chiều. Thuật toán cho phép bù trừ dịch chuyển hình học với độ chính xác đạt mức dưới điểm ảnh (sub-pixel) trước khi thực hiện các phép phân tích tiếp theo.

### 2.3 Tối Ưu Hóa Tính Toán Phân Tán và Huấn Luyện Đa GPU

Để phục vụ việc huấn luyện các mô hình Vision Transformer trên tập dữ liệu hàng trăm nghìn khung hình, hệ thống áp dụng nguyên lý mở rộng tuyến tính (Linear Scaling Rule) trong tính toán phân tán. Khi phân bổ trên  $N$  bộ xử lý đồ họa, kích thước lô dữ liệu tổng cộng  $B_{\text{total}}$  và tốc độ học hiệu dụng  $\eta_{\text{eff}}$  được điều chỉnh đồng bộ:

$$B_{\text{total}} = N \cdot B_{\text{local}}, \quad \eta_{\text{eff}} = N \cdot \eta_{\text{base}} \quad (6)$$

kết hợp kỹ thuật khởi động mềm tốc độ học (Warmup Cosine Schedule) để đảm bảo tính ổn định hội tụ của gradient. Trạng thái tối ưu hóa bao gồm trọng số mô hình, trạng thái đạo hàm bậc một, bậc hai của thuật toán AdamW và bộ chia tỷ lệ độ chính xác hỗn hợp FP16 được lưu trữ đồng bộ, đảm bảo khả năng khôi phục chu trình huấn luyện mà không gây tổn thất giá trị hàm mục tiêu.

### 3 HƯỚNG 1 MỚI: TỰ HỌC BIỂU DIỄN PHƯƠNG TIỆN BẤT BIẾN BỐI CẢNH (PRIOR-FREE VEHICLE-CENTRIC SSL)

#### 3.1 Đặt Vấn Đề Khoa Học và Sự Đột Phá Của Hướng 1 Mới

Trong các giải pháp học tự giám sát truyền thống, việc che ngẫu nhiên các patch ảnh (Uniform Masking) khiến phần lớn năng lực học của mạng nơ-ron bị lãng phí vào việc tái tạo mặt đường và kiến trúc xung quanh. Khi áp dụng ảnh nền trung vị để hướng dẫn cơ chế che khuất (như trong mô hình đối chuẩn cũ), mô hình lại bị nhiễm độc bởi hiện tượng bóng ma phương tiện và phụ thuộc vào sự tồn tại của ảnh nền mẫu sạch. Hướng 1 Mới giải quyết triệt để vấn đề này bằng cách tự học biểu diễn tập trung hoàn toàn vào phương tiện giao thông chỉ từ chuỗi ảnh thừa của camera cố định với ba nguyên tắc:

1. **Hoàn toàn không cần ảnh nền mẫu sạch (Prior-Free):** Trích xuất quy luật xuất hiện của phương tiện trực tiếp qua độ dị biệt thống kê không-thời gian.
2. **Không đòi hỏi luồng video dày (No Optical Flow):** Hoạt động ổn định trên chuỗi ảnh chụp ngắt quãng với chu kỳ 3–5 phút mỗi khung hình.
3. **Bảo đảm tính bất biến bối cảnh tĩnh (Context Invariance):** Triệt tiêu tương quan giả tạo giữa hình dáng xe cộ và kết cấu mặt đường đặc thù của từng camera.

#### 3.2 Khung Lý Thuyết Bản Đồ Dị Biệt Thời Gian TAM

Khung hình đầu vào  $I_t \in \mathbb{R}^{3 \times H \times W}$  (tỷ lệ chuẩn 16:9, kích thước  $256 \times 448$ ) được phân chia thành  $N = 16 \times 28 = 448$  mảng điểm ảnh (patches) không chồng lấn kích thước  $16 \times 16$ . Vector đặc trưng của từng patch được trích xuất qua bộ mã hóa Vision Transformer đóng băng và chiếu giảm chiều tuyến tính xuống không gian  $d = 64$ :

$$u_t(p) = \frac{\mathbf{P} \cdot \text{Encoder}(I_t)_p}{\|\mathbf{P} \cdot \text{Encoder}(I_t)_p\|_2} \in \mathbb{S}^{63} \quad (7)$$

với  $\mathbf{P} \in \mathbb{R}^{64 \times D}$  là ma trận chiếu trực giao và  $\mathbb{S}^{63}$  biểu diễn mặt cầu đơn vị 64 chiều. Tại mỗi camera  $c$  và tại từng tọa độ patch  $p \in \{1, \dots, N\}$ , hệ thống duy trì trực tuyến  $K = 4$  cụm trạng thái quang học tĩnh:

$$\mathcal{C}_k(p) = \left( \boldsymbol{\mu}_k(p), n_k(p), t_k^{\text{last}}(p) \right), \quad k \in \{1, \dots, K\} \quad (8)$$

trong đó  $\boldsymbol{\mu}_k \in \mathbb{S}^{63}$  là vector tâm cụm đại diện cho các trạng thái chiếu sáng nền (năng gắt, bóng râm, đèn đường ban đêm, mặt đường ẩm),  $n_k$  là số lượt quan sát tích lũy và  $t_k^{\text{last}}$  là thời điểm cập

nhất gần nhất. Khoảng cách Cosine cực tiểu từ đặc trưng quan sát tức thời  $u_t(p)$  tới tập hợp các trạng thái nền tĩnh đại diện cho mức độ dị biệt không gian:

$$d_t(p) = 1 - \max_{k \in \{1, \dots, K\}} \boldsymbol{\mu}_k(p)^\top u_t(p) \quad (9)$$

Quy tắc cập nhật trạng thái trực tuyến được xác định:

- Nếu  $d_t(p) < \tau_{\text{match}}$  ( $\tau_{\text{match}} = 0.25$ ): Cụm khớp nhất  $k^*$  được cập nhật trọng tâm:

$$\boldsymbol{\mu}_{k^*}(p) \leftarrow \frac{(1 - \beta)\boldsymbol{\mu}_{k^*}(p) + \beta u_t(p)}{\|(1 - \beta)\boldsymbol{\mu}_{k^*}(p) + \beta u_t(p)\|_2} \quad (10)$$

- Nếu  $d_t(p) \geq \tau_{\text{match}}$ : Trạng thái hiện tại được xem là dị biệt; nếu kéo dài, cụm có tần suất xuất hiện thấp nhất sẽ bị thay thế.

Xác suất thuộc về phương tiện giao thông  $\pi_t(p) \in [0, 1]$  được ước lượng thông qua mô hình hỗn hợp Gauss (Gaussian Mixture Model) gồm 2 thành phần (Nền tĩnh  $\mathcal{N}_0$  và Phương tiện  $\mathcal{N}_1$ ):

$$\pi_t(p) = P(\text{Vehicle} \mid d_t(p)) = \frac{w_1 \mathcal{N}(d_t(p); \mu_1, \sigma_1^2)}{w_0 \mathcal{N}(d_t(p); \mu_0, \sigma_0^2) + w_1 \mathcal{N}(d_t(p); \mu_1, \sigma_1^2)} \quad (11)$$

### 3.3 Cơ Chế Che Phân Tầng Thích Ứng AGM

Thuật toán che phân tầng AGM phân bổ tổng ngân sách che  $M = \lfloor 0.6 \cdot N \rfloor = 268$  patches theo tỷ lệ cân bằng giữa vùng phương tiện và vùng nền:

$$M_v = \min(\lfloor \phi \cdot M \rfloor, \lfloor q_{\text{max}} \cdot |\mathcal{V}| \rfloor) \quad (12)$$

với  $\phi = 0.5$  là hệ số ưu tiên phương tiện,  $q_{\text{max}} = 0.6$  là tỷ lệ che tối đa trên diện tích xe để tránh hiện tượng mất dấu hoàn toàn thông tin hình thái, và  $\mathcal{V} = \{p \mid \pi_t(p) \geq 0.5\}$  là tập hợp các patch được xác định là phương tiện. Số patch nền cần che bổ sung là  $M_s = M - M_v$ . Tập hợp các patch bị che được lấy mẫu không hoàn lại dựa trên phân phối xác suất Gumbel Top-K:

$$g(p) = \log \pi_t(p) - \log(-\log U_p), \quad U_p \sim \text{Uniform}(0, 1) \quad (13)$$

Cơ chế này ép buộc mạng nơ-ron phải học cách tái tạo cấu trúc phương tiện bị che khuất dựa trên ngữ cảnh xung quanh và ngược lại.

### 3.4 Toán Tử Hoán Đổi Vùng Tĩnh Phản Thực Nghiệm SRS

Để triệt tiêu hoàn toàn sự phụ thuộc giả tạo giữa hình ảnh phương tiện và kết cấu nền đường đặc thù của từng camera, toán tử hoán đổi vùng tĩnh SRS tạo ra các mẫu huấn luyện phản thực nghiệm (Counterfactual Data Augmentation). Xét hai khung hình  $x_1$  và  $x_2$  chụp từ cùng một camera tại hai ngày khác nhau  $t_1 \neq t_2$  (khác biệt về điều kiện thời tiết, bóng đổ hoặc độ ẩm mặt đường). Mặt nạ vùng tĩnh chung được xác định bởi:

$$M_{\text{static}}(p) = \mathbb{I}(\pi_{x_1}(p) < 0.2 \wedge \pi_{x_2}(p) < 0.2) \quad (14)$$

Mặt nạ này được chuyển đổi sang kích thước điểm ảnh và làm mượt biên bằng bộ lọc Gauss  $\mathbf{G}_\sigma$  ( $\sigma = 4.0$  pixel):

$$M_{\text{feather}} = \mathbf{G}_\sigma * \text{Upsample}(M_{\text{static}}) \quad (15)$$

Khung hình phản thực nghiệm tổng hợp  $x_{\text{srs}}$  được tạo ra bằng phép kết hợp lỗi:

$$x_{\text{srs}} = M_{\text{feather}} \odot x_2 + (1 - M_{\text{feather}}) \odot x_1 \quad (16)$$

Trong ảnh  $x_{\text{srs}}$ , toàn bộ các phương tiện giao thông của ngày thứ nhất được đặt nguyên vẹn trên nền đường và bối cảnh ánh sáng của ngày thứ hai. Mạng nơ-ron khi xử lý  $x_{\text{srs}}$  buộc phải phân tách thuộc tính hình thái xe ra khỏi các đặc trưng kết cấu nền đường bên dưới.

### 3.5 Hàm Mất Mát Chưng Cát Tự Thân Đa Tầng

Hàm mất mát tổng thể kết hợp tối ưu hóa toàn cục trên token phân loại và tối ưu hóa cục bộ trên các patch điểm ảnh:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{DINO}}^{[\text{CLS}]} + \lambda_{\text{ibot}} \mathcal{L}_{\text{iBOT}}^{[\text{Patch}]}(\pi) + \lambda_{\text{koleo}} \mathcal{L}_{\text{KoLeo}} \quad (17)$$

Trong đó, thành phần mất mát chưng cất patch iBOT được điều tiết trực tiếp bởi xác suất phương tiện  $\pi(p)$  nhằm tập trung mật độ lan truyền đạo hàm vào các vùng chứa xe cộ:

$$\mathcal{L}_{\text{iBOT}}^{[\text{Patch}]}(\pi) = -\frac{1}{\sum_{p \in \mathcal{M}} \pi(p)} \sum_{p \in \mathcal{M}} \pi(p) \sum_{k=1}^K P_{\text{teacher}}(h_{x_1}(p))^{(k)} \log P_{\text{student}}(h_{x_{\text{srs}}}(p))^{(k)} \quad (18)$$

với  $\mathcal{M}$  là tập hợp các patch bị che bởi thuật toán AGM. Để ngăn chặn hiện tượng sụp đổ không gian biểu diễn (Representation Collapse), thành phần entropy KoLeo (Kozachenko-Leonenko) được bổ sung nhằm phân tán đều các vector đặc trưng trên mặt cầu đơn vị:

$$\mathcal{L}_{\text{KoLeo}} = -\frac{1}{B} \sum_{i=1}^B \log \min_{j \neq i} \|z_i - z_j\|_2 \quad (19)$$

## 4 HƯỚNG 2 MỚI: PHÂN RÃ CẢNH GIAO THÔNG ĐỘC LẬP KHÔNG DÙNG ẢNH NỀN (PRIOR-FREE SCENE DECOMPOSITION)

### 4.1 Khuyết Tật Của Mô Hình Phụ Thuộc Nền Cũ và Đột Phá Hướng 2 Mới

Trong mô hình phân rã cảnh giao thông cũ, hàm mất mát nhánh nền bị ràng buộc cường bức vào ảnh nền trung vị:

$$\mathcal{L}_{\text{bg\_old}} = \|\hat{B} - B_{\text{median}}\|_1 \quad (20)$$

Cách tiếp cận này gặp phải sai số nghiêm trọng: khi xe cộ dừng đỗ kéo dài trong giờ cao điểm, ảnh nền median bị dính bóng ma phương tiện; mạng nơ-ron học theo median sẽ bị ép phải tái tạo bóng ma vào lớp nền, biến lỗi của median thành lỗi vĩnh viễn của mô hình. Hướng 2 Mới loại bỏ hoàn toàn giả định về sự tồn tại của ảnh nền mốc. Dựa trên bản chất vật lý rằng nền đường của camera

cố định là một cảnh vật tĩnh duy nhất chỉ biến thiên quang học theo góc chiếu mặt trời, bóng râm và độ ẩm, các biến động này nằm trên một đa tạp tham số hóa ít chiều (Low-dimensional Lighting Manifold). Quy trình được thực hiện qua hai giai đoạn chặt chẽ:

## 4.2 Giai Đoạn 1: Học Đa Tập Ánh Sáng Nền SceneBasis Bằng Thuật Toán Lập Huber-IRLS

Từ chuỗi ảnh không nhãn thu thập qua nhiều ngày của mỗi camera, nền đường được biểu diễn dưới dạng một không gian con affine  $J$  chiều:

$$B(u, v; t) = E_0(u, v) + \sum_{j=1}^J \ell_j(t) E_j(u, v) \quad (21)$$

trong đó  $E_0 \in \mathbb{R}^{H \times W \times 3}$  biểu diễn kết cấu cảnh tĩnh cơ sở và  $\{E_j\}_{j=1}^J$  ( $J = 3$ ) là các cơ sở vi phân biểu diễn sự thay đổi của hướng bóng đổ mặt trời, cường độ tán xạ khí quyển và độ ẩm của mặt đường nhựa. Hệ cơ sở  $\{E_0, E_j\}$  được khởi tạo thông qua phân rã giá trị suy biến mạnh (Robust SVD) và tối ưu hóa lặp luân phiên qua thuật toán Huber-IRLS kháng ngoại lai, bóc tách hoàn toàn phương tiện chuyển động ra khỏi hệ cơ sở nền.

## 4.3 Giai Đoạn 2: Mạng Phân Rã Sâu Với Bộ Giải Hệ Số Ánh Sáng Trực Tuyến

Phương trình hòa trộn quang học có tính đến sai số đo lường bất định:

$$I(u, v) = \alpha(u, v) F(u, v) + (1 - \alpha(u, v)) B(u, v; t) + \epsilon(u, v) \quad (22)$$

với  $\alpha(u, v) \in [0, 1]$  là mặt nạ độ mờ của phương tiện giao thông,  $F(u, v)$  là màu sắc bề mặt xe và sai số quang học  $\epsilon(u, v) \sim \text{Laplace}(0, \sigma(u, v))$ . Mạng nơ-ron phân rã sâu dự đoán đồng thời:

$$\Phi(I) = (\hat{F}, \alpha, \sigma, \hat{\ell}) \quad (23)$$

Tại mỗi khung hình, hệ số chiếu sáng tức thời  $\ell^*(t) = [\ell_1, \dots, \ell_J]^\top$  được giải trực tiếp từ bài toán tối ưu bình phương tối thiểu có trọng số trên các vùng ảnh có xác suất nền cao  $W(u, v) = (1 - \alpha(u, v))^2$ :

$$\ell^* = \arg \min_{\ell} \sum_{u, v} W(u, v) \left\| I(u, v) - E_0(u, v) - \sum_{j=1}^J \ell_j E_j(u, v) \right\|_2^2 \quad (24)$$

Hàm trọng số Huber được cập nhật lặp:

$$w^{(k)}(u, v) = W(u, v) \cdot \psi_{\text{Huber}} \left( \|r^{(k-1)}(u, v)\|_2 \right), \quad \psi_{\text{Huber}}(e) = \begin{cases} 1, & \text{nếu } e \leq \delta \\ \frac{\delta}{e}, & \text{nếu } e > \delta \end{cases} \quad (25)$$

Nghiệm giải tích đóng tại mỗi bước lặp thông qua ma trận Gram:

$$\ell^{(k)} = \left( \sum_{u, v} w^{(k)}(u, v) \mathbf{A}(u, v)^\top \mathbf{A}(u, v) \right)^{-1} \left( \sum_{u, v} w^{(k)}(u, v) \mathbf{A}(u, v)^\top \mathbf{r}_0(u, v) \right) \quad (26)$$

trong đó  $\mathbf{A}(u, v) = [E_1(u, v), \dots, E_J(u, v)] \in \mathbb{R}^{3 \times J}$  và  $\mathbf{r}_0(u, v) = I(u, v) - E_0(u, v)$ .

#### 4.4 Hàm Mất Mát Laplace Negative Log-Likelihood

Hàm mục tiêu tối ưu hóa bao gồm thành phần tái tạo có học độ bất định và các ràng buộc vật lý:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{Laplace}} + \lambda_{\text{basis}}\mathcal{L}_{\text{basis}} + \lambda_{\alpha}\mathcal{L}_{\text{sparse}} + \lambda_{\text{tv}}\mathcal{L}_{\text{tv}}(\alpha) + \lambda_{\text{excl}}\mathcal{L}_{\text{excl}} \quad (27)$$

Thành phần mất mát Laplace Negative Log-Likelihood cho phép mạng nơ-ron tự động thích ứng với các vùng có độ phức tạp quang học cao bằng cách tăng giá trị sai số chuẩn  $\sigma(u, v)$ :

$$\mathcal{L}_{\text{Laplace}} = \frac{1}{HW} \sum_{u,v} \left[ \frac{|I(u, v) - \hat{I}_{\text{recon}}(u, v)|}{\sigma(u, v)} + \log \sigma(u, v) \right] \quad (28)$$

Ràng buộc triệt tiêu gradient giao thoa (Gradient Exclusion) ngăn chặn hiện tượng rò rỉ kết cấu mặt đường vào bề mặt phương tiện:

$$\mathcal{L}_{\text{excl}} = \frac{1}{HW} \sum_{u,v} \tanh(\|\nabla \hat{F}(u, v)\|) \odot \tanh(\|\nabla \hat{B}(u, v)\|) \quad (29)$$

kết hợp số hạng điều hòa tổng biến thiên (Total Variation)  $\mathcal{L}_{\text{tv}}(\alpha)$  để bảo đảm tính liên khối và độ sắc nét tại đường biên của mặt nạ phương tiện.

### 5 HƯỚNG 3: HỌC GIÁM SÁT YẾU THÍCH ỨNG THEO NGŨ CẢNH ĐÔ THỊ

#### 5.1 Tổng Hợp Nhãn Yếu Đa Nguồn và Cơ Chế Kiêng Cữ

Trong mạng lưới hàng trăm camera hoạt động liên tục, việc gán nhãn thủ công mức độ ùn tắc giao thông  $y_t \in \{0, 1, 2, 3\}$  (Tự do, Bình thường, Đông đúc, ùn tắc nghiêm trọng) là phương án không khả thi về mặt nhân lực. Hướng 3 xây dựng hệ thống gộp nhãn yếu dựa trên 5 hàm sinh nhãn (Labeling Functions) với khả năng kiêng cữ dự đoán ( $\lambda_j = -1$  khi độ tin cậy thấp):

1. **Hàm hình học phát hiện phương tiện ( $\text{LF}_1$ ):** Ước lượng tỷ lệ diện tích bao phủ bởi các hộp giới hạn phương tiện so với diện tích mặt đường khả dụng.
2. **Hàm sai khác ảnh nền ( $\text{LF}_2$ ):** Đo lường độ lệch cường độ trung bình có trọng số điều tiết bởi hệ số tin cậy vùng tính  $r_i$ .
3. **Hàm biến động quang thông liên khung hình ( $\text{LF}_3$ ):** Phân tích độ lệch giữa hai khung hình liên tiếp  $|I_t - I_{t-1}|$  nhằm phát hiện trạng thái giao thông dừng bất động.
4. **Hàm chu kỳ lịch sử ( $\text{LF}_4$ ):** Tra cứu phân bố mật độ lưu thông theo ma trận thời gian thực nghiệm trong tuần.
5. **Hàm suy diễn mô hình đa phương thức ( $\text{LF}_5$ ):** Truy vấn mô hình ngôn ngữ thị giác lớn (Vision-Language Model) với cơ chế lọc ngưỡng xác suất nghiêm ngặt.

## 5.2 Mô Hình Đồ Thị Xác Suất Markov Ẩn 54 Ngữ Cảnh

Do mỗi hàm sinh nhân có độ chính xác dao động mạnh tùy thuộc vào điều kiện ngoại cảnh, hệ thống phân hoạch không gian hoạt động thành 54 ngữ cảnh đô thị độc lập  $c \in \{1, \dots, 54\}$  dựa trên tổ hợp của: Khung giờ trong ngày, Điều kiện thời tiết, Cấp bậc tuyến đường và Chỉ số rung lắc camera. Trạng thái giao thông thực tế được mô hình hóa dưới dạng một chuỗi Markov ẩn (Hidden Markov Model) có tham số phát xạ phụ thuộc ngữ cảnh:

$$P(y_{1:T}, \mathbf{A}_{1:T} | c) = P(y_1) \prod_{t=2}^T P(y_t | y_{t-1}, \mathbf{A}) \prod_{t=1}^T \prod_{j=1}^5 \pi_j^{(c)}(\lambda_{t,j} | y_t) \quad (30)$$

trong đó  $\mathbf{A} \in \mathbb{R}^{4 \times 4}$  là ma trận xác suất chuyển trạng thái giao thông và  $\pi_j^{(c)}$  là xác suất phát xạ nhân của hàm thứ  $j$  trong ngữ cảnh  $c$ . Thuật toán Expectation-Maximization kết hợp giải thuật Forward-Backward được thực hiện hoàn toàn trong miền logarit (log-sum-exp) nhằm triệt tiêu hoàn toàn nguy cơ tràn số dưới (arithmetic underflow). Kết quả trả về phân phối nhân mềm chân lý ước lượng  $q(y_t) \in \Delta^3$ .

## 5.3 Chứng Cắt Tri Thức Sang Mô Hình Đích Chuỗi Thời Gian

Phân phối xác suất nhân mềm thu được từ mô hình Markov đóng vai trò là mục tiêu giám sát để huấn luyện mô hình suy luận độc lập (End Model) bao gồm bộ trích xuất đặc trưng Vision Transformer kết hợp mạng nơ-ron hồi quy Causal GRU:

$$\mathcal{L}_{\text{soft}} = - \sum_{k=0}^3 q_k(y_t) \log \hat{p}_k(I_{t-H:t}) \quad (31)$$

Khi triển khai trên hệ thống giám sát thực tế, mô hình đích suy luận trực tiếp từ chuỗi ảnh hiện trường mà không cần gọi lại 5 hàm sinh nhân yếu, đạt tốc độ xử lý thời gian thực với độ chính xác cao.

# 6 HƯỚNG 4: PHÁT HIỆN SỰ CỐ BẤT THƯỜNG KÉO DÀI VÀ PHÂN TÁCH LỖI CAMERA

## 6.1 Phép Lọc Trung Vị Thời Gian Trên Không Gian Đặc Trưng Patch

Các biến cố giao thông nghiêm trọng tại đô thị (ngập úng do triều cường, tai nạn va chạm dẫn đến ùn tắc cục bộ, rào chắn công trình thi công) mang bản chất kéo dài qua nhiều khung hình, trong khi xe cộ di chuyển thông thường chỉ xuất hiện thoáng qua tại một vị trí trong một chu kỳ chụp ảnh. Để triệt tiêu ảnh hưởng của luồng xe di chuyển mà không làm mờ biên độ bất thường, Hướng 4 thực hiện phép lọc trung vị thời gian trên cửa sổ trượt  $W$  khung hình trong không gian đặc trưng patch-token của mô hình Vision Transformer:

$$\tilde{F}_t(p) = \text{median}_{w=0}^{W-1} \{F_{t-w}(p)\} \in \mathbb{R}^d \quad (32)$$

Vector đặc trưng trung vị  $\tilde{F}_t(p)$  loại bỏ hoàn toàn các thay đổi đột ngột ngắn hạn của xe cộ, chỉ giữ lại các biến đổi bền vững của mặt đường và cảnh quan.

## 6.2 Ngân Hàng Đặc Trưng Chuẩn Nén Coreset Memory Bank

Để xây dựng tiêu chuẩn trạng thái bình thường cho từng vị trí camera theo từng khung giờ trong ngày, tập hợp các vector đặc trưng mẫu được chọn lọc thông qua thuật toán tối ưu hóa bao phủ K-Center Greedy (tương tự nguyên lý PatchCore). Thuật toán xây dựng tập con coreset  $\mathcal{C}$  từ tập mẫu ban đầu  $\mathcal{M}$  sao cho bán kính bao phủ cực đại là nhỏ nhất:

$$\mathcal{C}^* = \arg \min_{\mathcal{C} \subseteq \mathcal{M}, |\mathcal{C}|=K} \max_{x \in \mathcal{M}} \min_{c \in \mathcal{C}} \|x - c\|_2 \quad (33)$$

Cơ chế này cho phép nén 90% dung lượng lưu trữ đặc trưng chuẩn mà vẫn bảo toàn đầy đủ tính đa dạng quang học của bối cảnh bình thường. Điểm dị biệt của từng patch được tính bằng khoảng cách tối mẫu chuẩn gần nhất:

$$a_t(p) = \min_{m \in \mathcal{C}} \|\tilde{F}_t(p) - m\|_2 \quad (34)$$

## 6.3 Cơ Chế Phân Tách Lỗi Camera Khỏi Sự Cố Lồng Đường

Một trong những nguyên nhân hàng đầu gây ra báo động sai trong các hệ thống giám sát tự động là hiện tượng camera bị trôi góc quay do gió hoặc ống kính bị bám bụi bẩn, nước mưa. Hướng 4 giải quyết bài toán này bằng cơ chế phân tách không gian hai vùng:

$$s_{\text{road}} = \text{TopK}_{p \in \Omega_{\text{road}}} \{a_t(p)\}, \quad s_{\text{static}} = \text{TopK}_{p \notin \Omega_{\text{road}}} \{a_t(p)\} \quad (35)$$

với  $\Omega_{\text{road}}$  là mặt nạ không gian lòng đường được định hình từ trước. Quy tắc chẩn đoán trạng thái được thực hiện theo logic:

- Nếu  $s_{\text{static}} > \tau_{\text{static}}$ : Toàn bộ khung cảnh bị biến dạng quang học, hệ thống phát cảnh báo lỗi phần cứng hoặc lệch góc camera, ngăn chặn việc báo động sai sự cố giao thông.
- Nếu  $s_{\text{road}} > \tau_{\text{road}}$  và  $s_{\text{static}} \leq \tau_{\text{static}}$ : Sự bất thường chỉ khu trú trong phạm vi mặt đường, hệ thống kích hoạt cảnh báo sự cố giao thông.

Để dập tắt hoàn toàn các dao động ngẫu nhiên, cảnh báo chỉ được xác nhận chính thức khi sự cố duy trì liên tục qua  $N \geq 3$  cửa sổ trượt liên tiếp, khống chế tỷ lệ báo động giả ở mức cực thấp trên toàn mạng lưới.

# 7 HỆ THỐNG MÔ HÌNH ĐỐI CHUẨN VÀ CÔNG BỐ DỮ LIỆU

## 7.1 Hệ Thống Mô Hình Đối Chuẩn Nền Trung Vị

Để kiểm chứng một cách khách quan tính ưu việt của cách tiếp cận độc lập với ảnh nền (Prior-Free), hệ sinh thái duy trì hai mô hình đối chuẩn có sử dụng ảnh nền trung vị truyền thống:

1. **Mô hình đối chuẩn FAM- $\Delta$  (Baseline Hướng 1):** Tận dụng ảnh nền trung vị để hướng dẫn cơ chế che khuất patch trong học tự giám sát. Xác suất che từng patch tỷ lệ thuận với

chênh lệch cường độ quang học thô  $\Delta = |I - B_{\text{median}}|$ , đồng thời được điều tiết bởi hệ số tin cậy vùng tính  $r_i$ :

$$w(p) = r_i \cdot \text{RankNorm}(\bar{\Delta}_p) + (1 - r_i) \cdot \frac{1}{N} \quad (36)$$

Khi ảnh nền bị suy thoái ( $r_i \rightarrow 0$ ), mô hình tự động chuyển dịch về phép che ngẫu nhiên đều để hạn chế rủi ro lan truyền sai số.

2. **Mô hình đối chuẩn phân rã cảnh có tiên nghiệm Laplace (Baseline Hướng 2):** Sử dụng ảnh nền trung vị làm điều kiện ràng buộc mềm thông qua hàm mất mát Laplace Prior:

$$\mathcal{L}_{\text{prior}} = \frac{1}{HW} \sum_{u,v} \left[ \frac{|\hat{B}(u,v) - B_{\text{median}}(u,v)|}{\sigma(u,v)} + \log \sigma(u,v) \right] \quad (37)$$

kết hợp ràng buộc tính nhất quán của nền qua nhiều ngày quan sát. Mô hình cho phép hấp thụ các sai lệch nhỏ của nền median thông qua việc nâng cao độ bất định  $\sigma$ .

## 7.2 Công Trình Dữ Liệu IC4SD-TrafficSnap

Toàn bộ phương pháp luận được xây dựng dựa trên tập dữ liệu giám sát quy mô lớn IC4SD-TrafficSnap bao gồm 608 trạm camera tại TP.HCM với 714,123 khung hình độ phân giải cao và đồ thị mạng lưới đường bộ OSRM gồm 2,450 liên kết có hướng (trong đó có 238 cặp liên kết bất đối xứng cự ly do đặc thù đường một chiều và dải phân cách đô thị). Bộ dữ liệu vượt qua quy trình kiểm toán bảo mật thông tin định danh cá nhân (PII) dựa trên giới hạn quang học vật lý Sub-Nyquist (độ phân giải mặt đất  $\text{GSD} \geq 2.73 \text{ cm/pixel}$ , nét chữ biển số xe  $< 2 \text{ pixel}$ ) kết hợp quy tắc thống kê Rule of Three, bảo đảm tỷ lệ vi phạm bảo mật thực tế  $< 0.00042\%$  với độ tin cậy 95%.

## 8 KẾT LUẬN

Hệ sinh thái DINO Traffic Suite đã thiết lập một hệ thống phương pháp luận hoàn chỉnh và chặt chẽ, giải quyết tận gốc các thách thức thị giác máy tính trong mạng lưới camera giao thông đô thị đặc thù. Bằng việc kết hợp hài hòa giữa các mô hình tự học biểu diễn độc lập với ảnh nền (Hướng 1 Mới và Hướng 2 Mới), mô hình học giám sát yếu thích ứng ngữ cảnh (Hướng 3) và cơ chế phát hiện sự cố bền vững chống báo động sai (Hướng 4), hệ thống mở ra tiềm năng ứng dụng to lớn trong quản trị giao thông đô thị thông minh và đặt nền móng vững chắc cho các công bố khoa học tại các diễn đàn quốc tế uy tín.