

- xut *Specimen-Centric Data Protocol* (SCDP), mt khung tng quòt cho d liu nh cú nhieu quan sòt trở cng thc th

vt lý, bao gồm quy c thu thập, lưu trữ, manifest truy vt, kim toàn vị ònh giò.

- Xóy dng CEGS-Split, mt c ch phón chia theo nhúm ngun, cú phón tng theo loại vị cú kim tra embedding phòt hìn còc cp lión tp cn c rị soòt. C ch này gi nguyễn toịn b nh ca mt mu vt trong ững mt tp.
- Tòch hp giao thc d liu vị bị toòn nhn ãn vị hc biu ãn: mĩ la chn mũ hính vị siỏ tham s c phòt trin trỏn train-validation; tp kim th ch ãng bởo cởo cui cững trỏn cởo mu vt b gi li.
- Thc nghiũm trỏn b d liu S3 gĩm 19 loại thuc 6 chi, ng thi nh lng nhũy ca kt qu i vị n v phón chia d liu vị cung cp benchmark cho còc phng phỏp phón loi, metric learning vị self-supervised learning.

II. RELATED WORK

A. Wood Species Identification with Computer Vision

Còc h thng nhn ãn g trũy thng ãa vớo mũ t gii phu hoc c trng thit k th cũng. Còc nghiũn cu gĩn óy chũyũn sang CNN vị hc chũyũn giao trỏch xut c trng trc tip t nh mt ct, nh lũĩ hoc nh theo còc mt gii phu khỏc nhau [?], [?], [?]. Kt qu ca còc nghiũn cu này cho thy tim nng ca hc sỏu, ng thi ch ra s ph thuc mnh vớo loi nh, phũng i, chũn b b mt vị thĩnh phn b d liu. SCDP khũng thay th còc mũ hính ú; nú to iũ kin so sỏnh cũng trong mt bĩ cnh d liu c kim soòt.

B. Data Governance and Leakage-Free Evaluation

Rũ r xy ra khi quy trỏnh hc hoc ònh giò s dng thũng tin khũng hp l tĩ thi im d oòn [?]. Vĩ d liu cú phỏp o lp li, vĩc cũng mt ngun xut hĩn nhiũ tp lĩm vị phm gi nh c lp ca ònh giò. Kinh nghiũm t nh y sĩnh cho thy còc sai sút v thĩt k tp d liu, phón chia theo bnh nhón vị kim soòt ngun cú th ãn n còc kt lun quỏ lc quan [?]. Còc nguyễn tc này cú th khỏĩ quỏt cho nh g: ngun cn cũ lp lĩ mu vt hoc, nu phũ hp vĩ mc tiỏu trin khai, mt cp ngun rng hn nh cỏy, lũ thu thập hay phỏĩn chp.

C. Representation Learning for Fine-Grained Classification

Hc khong còch sỏu t chĩc embedding sao cho còc quan sỏt cũng lp gĩn nhau vị khỏc lp tỏch bĩt hn; còc hĩm mc tiỏu nh ArcFace, Multi-Similarity, Circle Loss vị supervised contrastive learning lĩ nhĩng i ãĩn ph bĩn [?], [?], [?], [?]. Hc t gĩỏm sỏt nh SimCLR, BYOL, SimSiam vị Barlow Twins cũng hu òch khi d liu nhón hn ch [?], [?], [?], [?]. Tuy nhiỏn, mt embedding tt ch cú ý nghĩa khi c ònh giò trỏn còc ngun cha quan sỏt. Trong nghiũn cu này, hc biu ãĩn lĩ tng nhn ãĩn t sau, vị tuỏn th, giao thc qũn tr d liu.

III. PROPOSED METHODOLOGY

A. Overall Framework

SCDP lĩ mt protocol cho còc bị toòn mĩ mt thc th vt lý sĩnh ra nhiũ quan sỏt nh tng quan. Protocol gĩm nm pha theo th t: (i) xỏc nh n v ngun vị k hoch thu thập; (ii) lưu trữ cú truy vt; (iii) kim toòn d liu; (iv) phón b theo nhúm ngun vị khũa tp kim th; vị (v) hũn lũyũn, la chn mũ hính vị bởo cởo. Th t này cú ý nghĩa phng phỏp lun: thũng tin ngun gĩc phĩ tn tĩ trc khi d liu c chia, vị khũng c suy ãĩn ngĩc t kt qu mũ hính.

Trong bị toòn g, n v ngun tĩ thiũ lĩ *mu vt vt lý* (specimen). Tũy mc tiỏu trin khai, n v này cú th c m rng thĩnh cỏy, lũ thu thập hoc phỏĩn chp. Vớo d, nu h thng cũ tng quỏt hĩa sang cỏy mĩ, còc mu vt cũng mt cỏy phĩ c t trong cũng mt tp. Protocol khũng gi nh rng th mc cũn lũũn tng ng mu vt; s tng ng này phĩ c xỏc nhĩn vị ghi trong manifest.

B. Collection, Storage, and Traceability

1) *Data Units and Required Metadata*: Mĩ mu vt c cp mt `specimen_id` bĩt bĩn. Mĩ ln thu nhĩn c cp `session_id`, vị mĩ tp nh cú `image_id` cũng ng ãĩn hoc mũ bĩm nĩ dung. Nhón loại cũn kỏĩm ngun nh ãĩn vị mc chĩc chĩn; còc mu ch xỏc nh tĩ cp chĩ khũng c gĩp ngĩm vớo nhón loại. Bĩng ?? mũ t b trĩng tĩ thiũ. Còc trĩng này cho phỏĩp tởĩ to split mĩ khũng ph thuc vớo tởĩn tp hay cũ trũc th mc cũc b.

Table I
MINIMUM FIELDS OF THE TRACEABLE MANIFEST.

Field group	Content and purpose
Identifiers	<code>image_id</code> , <code>specimen_id</code> , <code>session_id</code> , path, and content hash; defines the one-image-one-source relation.
Biological identity	Standardized species name, identification level, expert source, confirmation date, and uncertainty flag.
Acquisition	Device, magnification, section plane, capture location, lighting condition, and collector or collection protocol.
Governance	Dataset version, validation status, exclusion reason, <code>split_id</code> , and seed after the split is frozen.

V t chĩc, nh gĩc c lũ bĩt bĩn; còc nh õ chũn hĩa, crop hoc tng cũng c to ãĩn xut t nh gĩc vị khũng thay th nh ngun. Mĩ cũ trũc th mc kh ãĩng lĩ `raw/specimen_id/session_id/image_id` kt hp vị mt manifest dng CSV hoc Parquet cp b d liu. Cũ trũc th mc gĩũp thao tỏc thũn tĩn, trong khi manifest lĩ ngun chỏĩn lĩ cho nhón vị qũn h ngun. Vĩc này trỏĩnh suy lun `specimen_id` ch t quy c t tởĩn vĩn d b thay i theo thi gian.

2) *Audit Before Split*: Trc khi to tp hũn lũyũn, SCDP thc hĩn bĩn kim tra. Th nhĩt, kim tra schema bỏ m mĩ nh cú nh ãĩn, nhón vị trĩng thỏĩi hp l. Th hai, kim tra toĩĩn vĩn nhũm bỏ m mt `specimen_id` khũng mang còc nhón mớũ thũn, tr trĩng hp c gĩn c chũyũn gia xem xỏĩt. Th ba, mũ bĩm vị tng ng nh c ãĩng phòt hĩn tp trũĩng, nh crop lĩ hoc nh xut hĩn ãĩ nhiũ tởĩn. Th t, thĩng kỏĩ s mu vt vị s nh theo loại xỏc nh còc lp khũng s nhũm cho train-validation-test.

Còc kim tra này phón bĩt hai tỏĩnh hũng. nh gĩĩng nhau ãĩng cũng mu vt lĩ lĩ phón chia nu cũĩng hai tp khỏc nhau. nh gĩĩng nhau ãĩng hai mu vt khỏc nhau cú th lĩ bĩn thỏĩĩn sĩnh hc hp l, nhĩng vĩn cũn c lũ ý khi ãĩn gĩĩ khũa ca benchmark. Khũng cú kim tra embedding nỏĩ thay th c thũng tin ngun gĩc cũn lĩ tt.

C. Embedding-Aware Class-wise Specimen Split (CEGS-Split)

1) *Allocation Constraints*: Sau khi manifest c kim toòn, CEGS-Split phón b cp mu vt. Vĩ bĩn nh phón $a_{j,t}$ ch vĩc gỏĩn

mu vt S_j vj ỏ tp $t \in \{\text{train, val, test}\}$, ỏng buc chỏnh lỏ

$$\sum_t a_{j,t} = 1, \quad \forall S_j \in \mathcal{S}. \quad (3)$$

Kt hp vj ỏnh x t nh sang mu vt, (??) bo m iu kin ri nhau (??). Vj mỏi lỏi c , s nh hoc s mu vt trong tp t c gỏi ỏn t l nh trc p_t :

$$|n_{c,t} - p_t n_c| \leq \delta_c, \quad (4)$$

trong ỏ $n_{c,t}$ lỏ s n v c chn cón bng, n_c lỏ tng s n v ca lỏi c , vj δ_c phn ỏnh tỏnh ri rc do s mu vt cú hn. Khi s nhúm ca mt lỏi quỏ ỏt, protocol u tỏn bỏo cỏo gii hn ỏ thay vớ tỏch nh ca mt mu vt t t l hỏnh thc.

2) *Specimen-Level Representation*: kim tra cu trỏc hỏnh nh ngoj metadata, CEGS-Split ỏng b trỏch xut c trng tham chiu f_0 ỏ ỏng bng vj khỏng c tnh chnh bng nhỏn ca b d liu ỏch. Vj nh x_i , embedding chun húa lỏ

$$z_i = \frac{f_0(x_i)}{\|f_0(x_i)\|_2}. \quad (5)$$

i din ca mu vt S_j lỏ trung bnh ca cỏc embedding nh:

$$h_j = \frac{1}{|S_j|} \sum_{x_i \in S_j} z_i. \quad (6)$$

Nu cn c lng hip phng sai vj s nhúm nh, PCA ch c fit trỏn phn phỏt trin ca d liu vj s chiu c gii hn trỏnh ma trn suy bin.

3) *Allocation Strategies and Selection Criteria*: CEGS-Split trin khai bn chỏn lc ỏp nhúm: (i) *stratified group allocation*, ti u cón bng lỏi; (ii) *hierarchical allocation*, gỏi nguyỏn cỏc cm mu vt ỏn nhau khi phỏn b; (iii) *Mahalanobis stratification*, phỏn tng mu vt theo in hỏnh i vj phỏn b ca lỏi; vj (iv) *agglomerative stratified allocation*, kt hp cm vj cón bng cỏc di khỏng cỏch. Mỏi chỏn lc u phi tha (??); chỏng khỏc nhau cỏch x lý mt cón bng vj cu trỏc a nh trong tng lỏi.

Chỏn lc c chn bng tiỏu chỏ ỏ xỏc nh trc trỏn phn phỏt trin, gm sai lch cón bng theo (??), s mu vt ti thiu ca mỏi lỏi, n nh qua cỏc seed vj cỏc ch s kim toỏn embedding. Khỏng chn split ch lỏm kt qu nhn din cao hn hoc thp hn. Sau khi chn seed vj cu hỏnh, manifest split c ỏng bng trc khi hun lỏyn mủ hỏnh ỏch; mỏi thay i sau ỏ phi to mt phiỏn bn benchmark mỏi.

4) *Mahalanobis Distance-based Split*: Chỏn lc nỏy xem cỏc mu vt xa trng tỏm (centroid) ca lp lỏi cỏc mu d bit (outlier) v mt ng ngha vj u tỏn a chỏng vj ỏ tp kim th hoc kim nh. Vj tp mu cha phỏn b U , centroid μ_U vj hip phng sai Σ_U c xỏc nh bi:

$$\mu_U = \frac{1}{|U|} \sum_{j \in U} z_j, \quad (7)$$

$$\Sigma_U = \frac{1}{|U|-1} \sum_{j \in U} (z_j - \mu_U)(z_j - \mu_U)^T + \epsilon I. \quad (8)$$

Khỏng cỏch Mahalanobis ca mu j n centroid hỏn ti lỏ:

$$d_{\text{Mahal}}(z_j, \mu_U) = \sqrt{(z_j - \mu_U)^T \Sigma_U^{-1} (z_j - \mu_U)}. \quad (9)$$

Ti mỏi vũng lp, mu xa nht $j^* = \arg \max_{j \in U} d_{\text{Mahal}}(z_j, \mu_U)$ c chn theo dung lng cùn thiu ca tp ỏch, cùn cỏc mu khỏc c gỏi li cho vũng sau.

5) *Hierarchical Clustering-based Split*: Chỏn lc nỏy phỏt hỏn cỏc nhúm mu vt t nhỏn trong cụng mt lỏi bng Agglomerative Hierarchical Clustering vj Ward linkage. S lng cm ti u K^* c xỏc nh bng phng phỏp khu tay (elbow method) trỏn tng bnh phng khỏng cỏch trong cm:

$$\text{WCSS}(K) = \sum_{k=1}^K \sum_{z_j \in \mathcal{C}_k} \|z_j - \mu_{\mathcal{C}_k}\|_2^2. \quad (10)$$

After scaling K and $\text{WCSS}(K)$ to $[0, 1]$, the elbow point is selected by:

$$K^* = \arg \max_K \frac{|x_K + y_K - 1|}{\sqrt{2}}. \quad (11)$$

Mỏi cm $\mathcal{C}_k$ c gỏi nguyỏn vn khi phỏn b vj ỏ tp hun lỏyn, kim nh hoc kim th, nhm trỏnh ct t cỏc nhúm vón g cú cu trỏc b mt ỏn nhau.

6) *Stratified Group-based Split*: Phng phỏp phỏn chia nhúm cú phỏn tng ti u húa ng thi cũ lp nhúm mu vt vj cón bng phỏn b lp gia cỏc tp. Gỏi $w_{g,c}$ lỏ s lng nh ca lỏi c trong nhúm g , s lng mu mc tiỏu cho phỏn chia f lỏ:

$$T_{f,c} = \frac{1}{K} \sum_{g=1}^G w_{g,c}. \quad (12)$$

Thut toỏn gỏn tham lam s la chn tp:

$$f^* = \arg \min_f \sum_{c=1}^C \left(\frac{C_{f,c} + w_{g,c}}{T_{f,c}} - 1 \right)^2, \quad (13)$$

trong ỏ $C_{f,c}$ lỏ s lng mu hỏn ti ca lỏi c trong tp f .

7) *Agglomerative Stratified Split*: Phng phỏp nỏy kt hp gia phỏn cm c trng vj phỏn chia phỏn tng theo khỏng cỏch hỏnh hc. Sau khi gom cm mu vt, khỏng cỏch t trng tỏm cm $\mu_{\mathcal{C}_k}$ n trng tỏm chung ca toỏn lỏi μ_{global} c tỏnh bng:

$$d(\mathcal{C}_k) = \sqrt{D^2(\mu_{\mathcal{C}_k}, \mu_{\text{global}})}, \quad (14)$$

Trong ỏ:

$$D^2(\mu_{\mathcal{C}_k}, \mu_{\text{global}}) = (\mu_{\mathcal{C}_k} - \mu_{\text{global}})^T \Sigma_{\text{global}}^{-1} (\mu_{\mathcal{C}_k} - \mu_{\text{global}}). \quad (15)$$

Cỏc cm c chia thnh ba di Near, Mid vj Far. Khi phỏn b, thut toỏn chn tp cú ht ln nht so vj mc tiỏu:

$$\Delta_s = \max(0, N_s^{\text{target}} - N_s^{\text{current}}), \quad s \in \{\text{train, val, test}\}. \quad (16)$$

Nh ỏ, c ba tp hun lỏyn, kim nh vj kim th u cha y cỏc mu in hỏnh, mu trung gian vj mu d bit.

8) *CEGS-Split Configuration*: Bng ?? trỏnh bọ cu hỏnh theo lỏi c ỏng trong benchmark gc ca CEGS-Split.

i vj cỏc lỏi g cú phỏn b hoỏn i (Swapped (Val)), kt qu chia tm thi c iu chnh nh sau:

$$\mathcal{D}_{\text{train}} = \mathcal{D}_{\text{train_temp}}, \quad \mathcal{D}_{\text{val}} = \mathcal{D}_{\text{test_temp}}, \quad \mathcal{D}_{\text{test}} = \mathcal{D}_{\text{val_temp}}. \quad (17)$$

Vj cỏc lỏi cú cu hỏnh tiỏu chun (Standard (Test)), kt qu ban u c gỏi nguyỏn. C ch nỏy giỏp cón bng khú gia tp kim nh vj tp kim th theo c thứ ca tng lỏi g, ng thi vn duy trỏ s cũ lp th mc con nghiỏm ngt.

Table II
CLASS-SPECIFIC CONFIGURATION OF THE CEGS-SPLIT PROTOCOL

Species	Split Strategy
<i>Afzelia africana</i>	Stratified Group
<i>Afzelia bella</i>	Hierarchical Clustering
<i>Afzelia pachyloba</i>	Agglomerative Stratified
<i>Afzelia quanzensis</i>	Mahalanobis Iterative
<i>Dalbergia cochinchinensis</i>	Agglomerative Stratified
<i>Dalbergia melanoxylon</i>	Mahalanobis Iterative
<i>Dalbergia oliveri</i>	Stratified Group
<i>Dalbergia rimosa</i>	Hierarchical Clustering
<i>Dalbergia tonkinensis</i>	Hierarchical Clustering
<i>Guibourtia arnoldiana</i>	Hierarchical Clustering
<i>Guibourtia coleosperma</i>	Agglomerative Stratified
<i>Guibourtia ehie</i>	Hierarchical Clustering
<i>Peltogyne pubescens</i>	Mahalanobis Iterative
<i>Pterocarpus erinaceus</i>	Agglomerative Stratified
<i>Pterocarpus indicus</i>	Agglomerative Stratified
<i>Pterocarpus macrocarpus</i>	Hierarchical Clustering
<i>Pterocarpus soyauxii</i>	Hierarchical Clustering
<i>Sindora cochinchinensis</i>	Mahalanobis Iterative
<i>Sindora tonkinensis</i>	Agglomerative Stratified

9) *Cross-Split Near-Duplicate Audit*: Vì mt mu vt kim th S_j , gn ln nht tì tp hun luyn c nh ngha:

$$r_j = \max_{S_k \in S_{\text{train}}} \frac{h_j^\top h_k}{\|h_j\|_2 \|h_k\|_2}. \quad (18)$$

Còc mu cú r_j thuc uũi cao ca phón b, hoc cú nh gn trng lp theo mỗ bm nhn thc, c a vjo danh sòch kim tra. Nhúm nghiõn cu i chiu li specimen_id, session_id, ngun thu thp vị nh gc. Nu phòt hin cng ngun b gòn nhiu nh danh, còc bn ghi c sa vị split c tòi to. Nu ngun khòc nhau nhng hp l, mu c gi li vị c kim toàn c lu trong manifest. Còch lịm nịy s dng embedding nh cng c phòt hin, khng bin tng ng hnh nh thnh nh ngha ca rù r.

D. Feature Backbone and Nonlinear Projection Head

Sau khi tp kim th c khóa, bị toàn nhn đin cú th đng mt b phón loi trc tip hoc mt mỗ hnh hc biu đin. Trong thc nghiõm, ConvNeXt-Tiny [?] to c trng u_i , tip theo lị projection head hai tng sinh embedding $v_i \in \mathbb{R}^{256}$:

$$\tilde{v}_i = W_2 \text{ReLU}(W_1 u_i + b_1) + b_2, \quad v_i = \frac{\tilde{v}_i}{\|\tilde{v}_i\|_2}. \quad (19)$$

Backbone cú th c thay bng EfficientNetV2 hoc Swin Transformer theo cng protocol [?], [?]. Mt mỗ hnh phón loi tì u entropy chỏ; mt mỗ hnh metric learning hoc self-supervised learning thay th hịm mc tiỏ nhng khng thay i manifest, split, augmentation c s hoc quy tc la chn trỏn validation. Nh ú, khòc bit quan sỏt c gĩa còc phng phỏp nhn đin khng b ln vì khòc bit do phón b đ liu.

E. Deep Metric Learning Loss Functions and Baselines

ònh giò khòch quan còc hng hc biu đin c trng, chng tũi thc nghiõm i chiu 14 hịm loss hc khong còch trong cng mt quy trỏnh hun luyn thng nht v mng c s, b u chiu, tng cng đ liu vị giao thc CEGS-Split. Kỳ hiu chung: $\mathbf{z}_i \in \mathbb{R}^D$ lị c trng nhng ò chun hĩa L_2 , y_i lị nhón loị, $d_{ij} = \|\mathbf{z}_i - \mathbf{z}_j\|_2$ lị khong còch Euclid, $S_{ij} = \mathbf{z}_i^\top \mathbf{z}_j$ lị cosine similarity vị $[u]_+ = \max(0, u)$.

1) *Standard Triplet Loss*: Triplet Loss tì u hĩa mĩ quan h gia b ba mu gm mu neo (anchor) a , mu tỏch cc (positive) p thuc cng loị vị mu tiỏ cc (negative) n thuc loị khòc. Mc tiỏ ca hịm loss lị thu hp khong còch gia mu neo vị mu tỏch cc, ng thi y mu tiỏ cc ra xa hn mu neo ỏt nht mt khong biỏn (margin) α :

$$L_{\text{triplet}} = \frac{1}{|\mathcal{T}|} \sum_{(a,p,n) \in \mathcal{T}} [d(a,p)^2 - d(a,n)^2 + \alpha]_+. \quad (20)$$

2) *Semi-hard Triplet Loss*: Phng phỏp Triplet bòn khũ (Semi-hard Triplet Loss) la chn còc mu tiỏ cc (negative) khng quỏ đ nhng cng khng quỏ nhiu. Vì mt cp mu neo vị mu tỏch cc (a,p) , mu tiỏ cc n c chn nu tha mỗn:

$$d(a,p)^2 < d(a,n)^2 < d(a,p)^2 + \alpha. \quad (21)$$

Loss vn gi dng triplet chun:

$$L_{\text{semi-hard}} = \frac{1}{|\mathcal{T}_{sh}|} \sum_{(a,p,n) \in \mathcal{T}_{sh}} [d(a,p)^2 - d(a,n)^2 + \alpha]_+. \quad (22)$$

3) *Soft-Margin Triplet Loss*: Phng phỏp Triplet biỏn mm (Soft-Margin Triplet) thay th hịm hĩng cng bng hịm log-sum-exp mn:

$$L_{\text{soft-triplet}} = \frac{1}{N} \sum_{i=1}^N \log \left[1 + e^{d(a_i,p_i)^2 - d(a_i,n_i)^2} \right]. \quad (23)$$

4) *Angular Loss*: Hịm loss Angular (Angular Loss) tì u hĩa quan h gúc ca tam giỏc c to bi b ba mu (triplet) thay vớ ch tì u hĩa khong còch Euclid n thun:

$$L_{\text{angular}} = \frac{1}{|\mathcal{T}|} \sum_{(a,p,n) \in \mathcal{T}} \log \left[1 + e^{\Delta_\theta(a,p,n)} \right], \quad (24)$$

Trong ú:

$$\Delta_\theta(a,p,n) = 4 \tan^2 \alpha (\mathbf{z}_a + \mathbf{z}_p)^T \mathbf{z}_n - 2(1 + \tan^2 \alpha) \mathbf{z}_a^T \mathbf{z}_p. \quad (25)$$

5) *Multi-Similarity Loss*: Multi-Similarity Loss khai thỏc ng thi thũng tĩn t nhiu cp tỏch cc vị tiỏ cc trong cng mt lữ đ liu, ng thi gòn trng s ln hn cho còc cp cú khũ cao:

$$L_{\text{MS}} = \frac{1}{N} \sum_{i=1}^N [\phi^+(P_i) + \phi^-(N_i)], \quad (26)$$

Trong ú:

$$\begin{aligned} \phi^+(P_i) &= \frac{1}{\alpha} \log \left[1 + \sum_{p \in P_i} e^{-\alpha(S_{ip} - \lambda)} \right], \\ \phi^-(N_i) &= \frac{1}{\beta} \log \left[1 + \sum_{n \in N_i} e^{\beta(S_{in} - \lambda)} \right]. \end{aligned} \quad (27)$$

6) *Standard Contrastive Loss*: Contrastive Loss tỉ u hóa không còch trỏn tng cp mu riỏng l:

$$L_{\text{contrastive}} = (1 - q_{ij}) \frac{1}{2} d_{ij}^2 + q_{ij} \frac{1}{2} [m - d_{ij}]_+^2. \quad (28)$$

7) *Online Hard Contrastive Loss*: Phng phỏp tng phn khai thỏc mu khủ trc tuyt (Online Hard Contrastive) tp trung tỉ u hóa trỏn cp tỏch cc xa nhỏt vị cp tiỏu cc gỏn nhỏt trong cúng mt lủ d liu (batch):

$$d_{\text{pos_max}}^i = \max_{p:y_p=y_i, p \neq i} d_{ip}, \quad d_{\text{neg_min}}^i = \min_{n:y_n \neq y_i} d_{in}. \quad (29)$$

$$L_{\text{hard-cont}} = \frac{1}{B} \sum_{i=1}^B [(d_{\text{pos_max}}^i)^2 + [m - d_{\text{neg_min}}^i]_+^2]. \quad (30)$$

8) *Lifted Structured Loss*: Lifted Structured Loss m rỏng c ch hc tng phn bng cỏch ng thi xem xỏt tt c cỏc mu tiỏu cc liỏn quan n mt cp mu tỏch cc (i, j) :

$$L_{\text{lifted}} = \frac{1}{2|P|} \sum_{(i,j) \in P} [d_{ij} + \log(\Phi(i, j))]^2, \quad (31)$$

Trong ú:

$$\begin{aligned} \Phi(i, j) &= \sum_{k:y_k \neq y_i} e^{\alpha - d_{ik}} \\ &+ \sum_{k:y_k \neq y_j} e^{\alpha - d_{jk}}. \end{aligned} \quad (32)$$

9) *Circle Loss*: Circle Loss xut mt cỏch tip cn tỉ u hóa tng ng thng nhỏt, trong ú cỏc mu tỏch cc vị tiỏu cc c gỏn cỏc trỏng s t iu chnh:

$$L_{\text{circle}} = \log[1 + \Omega_{\text{circle}}(i)], \quad (33)$$

Trong ú:

$$\begin{aligned} \Omega_{\text{circle}}(i) &= \sum_{n \in N_i} e^{\gamma \alpha_n (S_{in} - \Delta_n)} \times \\ &\sum_{p \in P_i} e^{-\gamma \alpha_p (S_{ip} - \Delta_p)}, \end{aligned} \quad (34)$$

and:

$$\alpha_p = [O_p - S_{ip}]_+, \quad \alpha_n = [S_{in} - O_n]_+. \quad (35)$$

10) *Proxy Anchor Loss*: Phng phỏp Proxy Anchor thay th vic so sỏnh trc tip giá cỏc hỏnh nh bng vic so sỏnh hỏnh nh vi cỏc mu i đin (proxy) ca tng lp:

$$L_{\text{PA}} = \frac{1}{|P^+|} \sum_{p \in P^+} \log \Gamma^+(p) + \frac{1}{|P^-|} \sum_{p \in P^-} \log \Gamma^-(p), \quad (36)$$

Trong ú:

$$\begin{aligned} \Gamma^+(p) &= 1 + \sum_{\mathbf{z} \in X_p^+} e^{-\alpha(S(\mathbf{z}, p) - \delta)}, \\ \Gamma^-(p) &= 1 + \sum_{\mathbf{z} \in X_p^-} e^{\alpha(S(\mathbf{z}, p) + \delta)}. \end{aligned} \quad (37)$$

11) *ArcFace Loss*: Phng phỏp ArcFace (Additive Angular Margin Loss) ỏp dng trc tip mt biỏn gúc cng (additive angular margin) vọ giỏ tr logit ca lp chỏnh xỏc:

$$L_{\text{ArcFace}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{s \cos(\theta_{y_i} + m)}}{\Lambda_i}, \quad (38)$$

Trong ú:

$$\Lambda_i = e^{s \cos(\theta_{y_i} + m)} + \sum_{j \neq y_i} e^{s \cos \theta_j}. \quad (39)$$

12) *SubCenter ArcFace Loss*: Phng phỏp SubCenter ArcFace m rỏng thut toỏn ArcFace bng cỏch gỏn nhiu trỏng tỏm ph (sub-center) cho mi lp. Vi cu hỏnh K trỏng tỏm ph cho mi loỏi, giỏ tr logit ca lp chỏnh xỏc c tỏnh toỏn da trỏn trỏng tỏm ph gỏn nhỏt:

$$\cos \theta_{y_i} = \max_{k=1}^K \frac{\mathbf{z}_i^T \mathbf{W}_{y_i}^{(k)}}{\|\mathbf{z}_i\|_2 \|\mathbf{W}_{y_i}^{(k)}\|_2}. \quad (40)$$

13) *SoftTriple Loss*: Tng t, phng phỏp SoftTriple cng s dng nhiu trỏng tỏm i đin cho mi lp nhng ỏp dng c ch gỏn mm (soft assignment) thay vọ lý giỏ tr cc i:

$$S_{i,c} = \sum_{k=1}^K \frac{e^{\mathbf{z}_i^T \mathbf{w}_c^{(k)} / \gamma}}{\sum_{t=1}^K e^{\mathbf{z}_i^T \mathbf{w}_c^{(t)} / \gamma}} \mathbf{z}_i^T \mathbf{w}_c^{(k)}. \quad (41)$$

Loss phỏn loi cú margin:

$$L_{\text{SoftTriple}} = -\log \frac{e^{\lambda(S_{i,y_i} - \delta)}}{e^{\lambda(S_{i,y_i} - \delta)} + \sum_{c \neq y_i} e^{\lambda S_{i,c}}}. \quad (42)$$

14) *Supervised Contrastive Loss (SupCon)*: Contrastive Loss cú giỏm sỏt (Supervised Contrastive Loss - SupCon) m rỏng phng phỏp SimCLR sang hc cú giỏm sỏt bng cỏch coi tt c cỏc mu thuc cúng mt loỏi trong lủ d liu lị cỏc mu tỏch cc ca nhau:

$$L_{\text{SupCon}} = \sum_{i \in I} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{e^{\mathbf{z}_i^T \mathbf{z}_p / \tau}}{\sum_{a \in A(i)} e^{\mathbf{z}_i^T \mathbf{z}_a / \tau}}. \quad (43)$$

SupCon tỉ u hóa vic sp t c trỏng trỏn toỏn b lủ d liu vị thng to ra khỏng gian những cú kh nng chuyt giao tt.

F. Self-Supervised Learning Loss Functions

Trong hc biu đin t giỏm sỏt (Self-Supervised Learning - SSL), mủ hỏnh thc hín tỉ u hóa c trỏng thũng qua cỏc bin th tng cng ngu nhỏn ca hỏnh nh mị khỏng cn s dng nhỏn lp giỏm sỏt. Phn nỳ trỏnh bỳ cỏc hỏm loss ca bn phng phỏp hc t giỏm sỏt c kho sỏt trong nghiỏn cu.

1) *SimCLR Loss*: Phng phỏp SimCLR (Simple Framework for Contrastive Learning of Visual Representations) tỉ u hóa hỏm loss tng phn InfoNCE trỏn cỏc cp nh tng cng. Vi kỏch thc lủ d liu lị N , mị hỏnh nh c tng cng ngu nhỏn thnh 2 phiỏn bn (views), to thnh mt lủ gm $2N$ mu d liu. Cp mu tỏch cc (positive pair) lị (i, j) gm hai phiỏn bn tng cng khỏc nhau ca cúng mt hỏnh nh gc. Hỏm loss cho mi cp mu tỏch cc (i, j) c phỏt biu:

$$\ell(i, j) = -\log \frac{e^{\mathbf{z}_i^T \mathbf{z}_j / \tau}}{\Omega_i}, \quad (44)$$

Trong ú:

$$\Omega_i = \sum_{k=1}^{2N} \mathbb{I}_{[k \neq i]} e^{\mathbf{z}_i^T \mathbf{z}_k / \tau}. \quad (45)$$

trong ú τ lị siỏu tham s nhit (temperature). Hỏm loss tng th c tỏnh bng macro average ca toỏn b cỏc cp mu tỏch cc trong lủ d liu:

$$L_{\text{SimCLR}} = \frac{1}{2N} \sum_{k=1}^N [\ell(2k-1, 2k) + \ell(2k, 2k-1)]. \quad (46)$$

2) *BYOL Loss*: Phng phòp BYOL (Bootstrap Your Own Latent) s dng hai mng n-ron song song: mng hc trc tip (online network) vi tham s θ vi target network vi tham s ξ . Mng hc trc tip cú nhim v d oàn biu din ca mng mc tiúu t mt phiến bn nh khòc. BYOL ti u hóa sai s bnh phng trung bnh (MSE) gia vector d oàn ô chun hóa ca mng trc tip vi vector c trng ca mng mc tiúu:

$$L_{\text{MSE}}(q_{\theta}(z_{\theta}), z'_{\xi}) = \|\bar{q}_{\theta} - \bar{z}'_{\xi}\|_2^2 = 2 - 2\bar{q}_{\theta}^T \bar{z}'_{\xi}, \quad (47)$$

Trong ú:

$$\bar{q}_{\theta} = \frac{q_{\theta}(z_{\theta})}{\|q_{\theta}(z_{\theta})\|_2}, \quad \bar{z}'_{\xi} = \frac{z'_{\xi}}{\|z'_{\xi}\|_2}. \quad (48)$$

Vic ngn chn hin tng sp biu din c trng (representation collapse) c m bo bng c ch dng cp nht o hịm (stop-gradient) t trón mng mc tiúu:

$$L_{\text{BYOL}} = L_{\text{MSE}}(q_{\theta}(z_{\theta}), \text{stop_gradient}(z'_{\xi})). \quad (49)$$

Tham s mng mc tiúu ξ c cp nht chm theo c ch trung bnh trt ly tha (EMA) t θ :

$$\xi \leftarrow m\xi + (1 - m)\theta, \quad (50)$$

trong ú $m \in [0, 1]$ lị h s momentum.

3) *SimSiam Loss*: Phng phòp SimSiam (Simple Siamese) n gin hóa kin trức BYOL bng còch loi b hoịn toịn momentum target network (momentum target network, tc thit lp $\xi = \theta$). SimSiam chng minh rng ch cn s dng c ch dng cp nht o hịm kt hp vi kin trức khùng i xng (b d oàn predictor) lị ngn chn s sp biu din c trng. Hịm loss i xng c nh ngha nh sau:

$$L_{\text{SimSiam}} = \frac{1}{2}\mathcal{D}(p_1, \text{sg}(z_2)) + \frac{1}{2}\mathcal{D}(p_2, \text{sg}(z_1)), \quad (51)$$

trong ú $p_1 = q_{\theta}(z_1)$ vi $p_2 = q_{\theta}(z_2)$ lị u ra ca b d oàn cho hai phiến bn nh, cùn z_1, z_2 lị u ra ca b u chiu. sg biu th toàn t dng o hịm (stop-gradient). $\mathcal{D}$ lị cosine similarity óm:

$$\mathcal{D}(p, z) = -\frac{p^T z}{\|p\|_2 \|z\|_2}. \quad (52)$$

4) *Barlow Twins Loss*: Phng phòp Barlow Twins òp dng nguỷn lý gim thiu thũng tin d tha (redundancy reduction) lỏn ma trn tng quan chỏo thu c t hai phiến bn nh tng cng. Gi C lị ma trn tng quan chỏo kỏch thc $D \times D$ tỏnh toàn dc theo chiu lũ d liu B gia hai tp c trng chiu $\mathbf{z}^A$ vi $\mathbf{z}^B$:

$$C_{ij} = \frac{\sum_{b=1}^B z_{b,i}^A z_{b,j}^B}{\sqrt{\sum_{b=1}^B (z_{b,i}^A)^2} \sqrt{\sum_{b=1}^B (z_{b,j}^B)^2}}, \quad (53)$$

trong ú i, j i din cho còc chiu ca khùng gian c trng nhũng. Hịm mt mọt Barlow Twins c nh ngha lị:

$$L_{\text{BarlowTwins}} = \sum_{i=1}^D (1 - C_{ii})^2 + \lambda \sum_{i=1}^D \sum_{j \neq i}^D C_{ij}^2, \quad (54)$$

trong ú s hng th nht (invariance term) òp còc h s tng quan chỏo trón ng chỏo chỏnh tin v 1 (ti a hóa tng ng gia hai phiến bn nh), s hng th hai (redundancy reduction term) òp còc h s tng quan chỏo ngoị ng chỏo chỏnh tin v 0 vi h s pht $\lambda > 0$ (gim thiu s trũng lp thũng tin gia còc chiu c trng nhũng).

G. Generality

SCDP khùng ph thuc vọ g. Vi nh da liu, lòt ct y sinh, sn phm cũng nhp, nh v tnh a thi im hoc d liu cũn trũng, specimen_id cú th c thay ln lt bng bnh nhón, chỉ tit sn phm, ù a lý-thi gian hoc cò th. Nguỷn tc gi nguỷn lị: xỏc nh n v mị h thng phi tng quỏt hóa tí, ghi nhn quan h ngun trc khi hun luy, vi phón chia theo n v ú.

IV. EXPERIMENTAL CONFIGURATION

A. S3 Dataset and Analysis Unit

B d liu S3 gm nh mt ct ngang mc v mũ ca 19 loịi thuc 6 chỉ: *Afzelia*, *Dalbergia*, *Guibourtia*, *Peltogyne*, *Pterocarpus* vi *Sindora*. Mị loịi cú nhũ th mc con; trong phiến bn d liu c s dng, mt th mc con biu din mt nhũm nh ca cũng mt mu vt. Còc bn ghi ch xỏc nh tí cp chỉ b loi khi tp giỏm sỏt theo loịi. Trc khi òp dng SCDP cho mt phiến bn mị ca S3, mị quan h gia th mc con vi mu vt phi c xỏc nhn trong manifest thay vớ ch c gi nh t tỏn th mc.

Hỏnh ?? trỏnh bọ phón b s nh vi s nhũm ngun theo loịi sau khi òp dng CEGS-Split. Bỏo cỏo c hai i lng lị cn thit: nhũ nh ca mt mu vt cỉ thĩn ph b mt, nhng khũng lịm tng s n v c lp ònh giỏ kh nng tng quỏt hóa.




Figure 1. Class-wise image and specimen distribution in S3 after CEGS-Split allocation.

B. Split Protocol and Comparison

Chũng tũi so sỏnh hai iu kin ònh giỏ. iu kin *Random Image Split* chia nh cú phón tng theo nhón loịi nhng khũng rịng buc nh cũng ngun cũng mt tp. iu kin *CEGS-Split* s dng specimen_id phón b toịn b nh ca mt nhũm ngun vọ duy nht train, validation hoc test, ng thi kim tra cón bng lp vi còc cp liỏn tp cú gn cao. Hai iu kin đũng cũng b trỏch xut c trng vi cũng th tc KNN trong phỏp i chiu v split; do ú, chỏnh lch quan sỏt c c quy cho n v phón chia, khũng phi kin trức nhn din.

Random Image Split c thc hin vi ba seed (42, 123, 456). CEGS-Split hin c bỏo cỏo nh mt split ò khũa nhm phc v benchmark tòi lp. Vớ ch cú mt phiến bn CEGS-Split trong kt qu hin tí, mị so sỏnh nh lng vi random split c hũu lị mũ t nhy ca benchmark, khũng phi kim nh ý ngha thng kỏ. Còc nghiỏn cu tip theo nỏn phỏt hịnh nhũ split group-disjoint hoc đũng group cross-validation khi s mu vt cho phỏp.

C. Recognition Model Training

Mô hình photon loss sử dụng ConvNeXt-Tiny [?] khi tạo tập dữ liệu huấn luyện. Các tập dữ liệu 768 chiều đi qua projection head phi tuyến tính để chèn hóa L_2 thành embedding 256 chiều. Trong cấu hình ban đầu, khoảng 90% tập dữ liệu của backbone được sử dụng bằng cách lấy mẫu ngẫu nhiên từ tập dữ liệu gốc để huấn luyện. Mô hình được huấn luyện với AdamW và learning rate 10^{-4} , weight decay 10^{-2} , cosine annealing trong 100 epoch và early stopping theo harmonic mAP validation và patience 30.

Tập dữ liệu được chia thành tập huấn luyện và tập kiểm tra, *random resized crop*, biến đổi màu sắc, thêm nhiễu Gaussian, xoay, lật, cắt ngẫu nhiên và *random erasing*. Các biến đổi khác nhau được áp dụng để cải thiện khả năng tổng quát hóa của mô hình. Tập dữ liệu được chia thành tập huấn luyện và tập kiểm tra, và checkpoint được lưu trữ để phục vụ cho việc huấn luyện và kiểm tra.

D. Representation Learning Methods

Trở ngại manifest của split khóa, benchmark bao gồm các hàm mất mát pairwise/triplet (Contrastive, Hard Contrastive, Triplet, Semi-hard Triplet, Soft-Margin Triplet và Lifted Structured), pair weighting học angular/proxy (Multi-Similarity, Circle, Angular, Proxy Anchor, ArcFace, SubCenter ArcFace và SoftTriple), cũng như Supervised Contrastive. Bản phương pháp tổng hợp của SimCLR, BYOL, SimSiam và Barlow Twins. Các tiêu chí benchmark không phải là tổng hợp của các hàm mất mát mà là tổng hợp của các hàm mất mát và các hàm mất mát khác. Các hàm mất mát này được sử dụng để huấn luyện mô hình và các hàm mất mát khác được sử dụng để kiểm tra mô hình.

E. Evaluation Metrics

Vì photon loss, chúng tôi báo cáo accuracy, precision, recall, F1 theo loại, macro-F1 và weighted-F1. Macro-F1 là trung bình của các giá trị F1 theo loại. Vi embedding, các chỉ số retrieval gồm Recall@k, Precision@k và mAP; giữa macro và harmonic mean của báo cáo trên các loại dữ liệu. Harmonic mean và tổng hợp của các giá trị $\epsilon = 0.01$ là:

$$HM = \frac{C}{\sum_{c=1}^C \frac{1}{m_c + \epsilon}}, \quad (55)$$

trong đó m_c là số lượng của loại c và C là số loại.

Chúng tôi sử dụng cấu trúc embedding của bộ lọc Silhouette, Davies–Bouldin, Calinski–Harabasz, Dunn và NMI. Các chỉ số này không thay đổi theo hướng nhìn, nhưng giúp photon bit tổng hợp của mô hình photon loss ứng với classifier head và tổng hợp của các chỉ số khác.

F. Split Audit Metrics

Ngay khi nhìn nhận, chúng tôi ghi nhận sự nhầm lẫn trong tập dữ liệu, *specimen_id* giao nhau giữa các tập, vì tổng hợp cosine liên tục bị rò rỉ tham chiếu. Vì photon loss là một hàm mất mát, các chỉ số cosine liên tục bị rò rỉ tham chiếu và các chỉ số khác. Chúng tôi sử dụng các chỉ số khác để kiểm tra mô hình và các chỉ số khác để kiểm tra mô hình.

V. RESULTS AND DISCUSSION

A. Recognition Performance on Held-Out Specimens

Bảng ?? báo cáo về photon loss ConvNeXt-Tiny dùng entropy cho tập dữ liệu kim loại của CEGS-Split. Accuracy là 80.28%, macro-F1 là 76.77% và weighted-F1 là 80.15%. Chênh lệch giữa macro-F1 và weighted-F1 cho thấy hiệu suất không đồng đều giữa các loại.

Table III
PER-SPECIES CLASSIFICATION REPORT OF THE BASELINE MODEL ON THE CEGS-SPLIT TEST SET.

Species	Precision	Recall	F1	Support
<i>Afzelia africana</i>	0.5833	0.5185	0.5490	54
<i>Afzelia bella</i>	0.0270	0.0250	0.0260	40
<i>Afzelia pachyloba</i>	0.2500	0.2955	0.2708	44
<i>Afzelia quanzensis</i>	0.6628	1.0000	0.7972	57
<i>Dalbergia cochinchinensis</i>	0.9028	0.9286	0.9155	70
<i>Dalbergia melanoxylon</i>	1.0000	0.9636	0.9815	55
<i>Dalbergia oliveri</i>	0.9118	1.0000	0.9538	62
<i>Dalbergia rimosa</i>	0.8571	1.0000	0.9231	30
<i>Dalbergia tonkinensis</i>	0.9565	0.7333	0.8302	30
<i>Guibourtia arnoldiana</i>	1.0000	0.5588	0.7170	34
<i>Guibourtia coleosperma</i>	1.0000	0.9861	0.9930	72
<i>Guibourtia ehie</i>	0.4906	0.6500	0.5591	40
<i>Peltogyne pubescens</i>	1.0000	1.0000	1.0000	110
<i>Pterocarpus erinaceus</i>	0.7882	1.0000	0.8816	67
<i>Pterocarpus indicus</i>	1.0000	0.6034	0.7527	58
<i>Pterocarpus macrocarpus</i>	1.0000	0.6667	0.8000	51
<i>Pterocarpus soyauxii</i>	0.8209	1.0000	0.9016	55
<i>Sindora cochinchinensis</i>	0.9474	0.7129	0.8136	101
<i>Sindora tonkinensis</i>	0.8537	1.0000	0.9211	35
Accuracy	—	—	0.8028	1065
Macro avg.	0.7922	0.7707	0.7677	1065
Weighted avg.	0.8250	0.8028	0.8015	1065

Các loại *A. bella* và *A. pachyloba* thuộc chi *Afzelia* là những loại khó nhất trong tập dữ liệu. Kết quả này phù hợp vì nhìn nhận rằng bị toàn bộ các biến thể của loài này rất khó để phân biệt; nếu không cho phép quy kết nguồn gốc của mẫu mà trên thực tế. Hình ?? cung cấp chi tiết về các phép nhầm lẫn và những kim tra nhận, nhận và quy trình thu nhận.




Figure 2. Confusion matrix of the baseline model on the CEGS-Split test set.

Table IV

SENSITIVITY OF KNN ON FROZEN SWIN-LARGE EMBEDDINGS TO THE DATA SPLIT. COSINE SIMILARITY IS REPORTED AS AN INTER-SPLIT IMAGE-LEVEL STATISTIC.

Split	Seed	KNN Acc.	Macro-F1	Weighted-F1	Mean CosSim	Max CosSim	Train	Test
Random image	42	0.9522	0.9343	0.9495	0.5678	0.9139	3900	1026
Random image	123	0.9429	0.9390	0.9426	0.5754	0.9173	3963	1015
Random image	456	0.9793	0.9745	0.9792	0.5758	0.9171	3895	1064
CEGS-Split	42	0.9087	0.8858	0.9062	0.5711	0.8999	4151	1041
Random image (mean)	—	0.9581 ± 0.0155	0.9493 ± 0.0179	0.9571 ± 0.0159	0.5730 ± 0.0037	0.9161 ± 0.0015	—	—
CEGS-Split	—	0.9087	0.8858	0.9062	0.5711	0.8999	—	—




Figure 5. Example Grad-CAM and Finer-CAM maps for qualitative inspection of the image regions driving predictions.

tộc ph sau khi thu thp, SCDP xem truy vt ngun, cu trức lu tr, manifest, kim toàn vị phón b group-disjoint lị còc thịnh phn ca phng phòp. CEGS-Split hin thc hóa pha phón b bng còch gi toịn b nh ca mt mu vt trong mt tp, cón bng theo lòi vị dứng embedding úng bng phòt hin còc trng hp cn kim tra li ngun gc.

Thc nghi m trón S3 cho thy cúng mt pipeline KNN cú kt qu khòc bit òng k gia random image split vị CEGS-Split. Kt qu nỳ khũng chng minh mi benchmark chia theo nh u cú rừ r, nhng cho thy n v phón chia lị mt gi nh cú nh hng trc tip n kt lun v mữ hnh. Do ú, còc kt qu nhn din, metric learning vị self-supervised learning nỏn luũn c bòo còo cúng nh ngha n v ngun, manifest split vị quy tc chn mữ hnh.

Còc bc tip theo gm xòc minh vị phòt hnh manifest phiỏn bn hóa, to nhieu group-disjoint split hoc group cross-validation, vị xóy dng tp kim th ngoi ngun vị thit b vị mu vt c lp. Vic kt hp kim toàn d liu vị chuyển gia gii phu g cng cn thit phón bit tòn hiu sinh hc thc s vị tòn hiu do quy trnh thu nhn nh.

REFERENCES

- [1] Convention on International Trade in Endangered Species of Wild Fauna and Flora, *Text of the Convention*, 1973. [Online]. Available: <https://cites.org/eng/disc/text.php>
- [2] S.-W. Hwang and J. Sugiyama, *Computer vision-based wood identification and its expansion and contribution potentials in wood science: A review*, *Plant Methods*, vol. 17, art. 47, 2021.
- [3] F. Wu, R. Gazo, E. Haviarova, and B. Benes, *Wood identification based on longitudinal section images by using deep learning*, *Wood Science and Technology*, vol. 55, pp. 553–563, 2021.

- [4] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, *Leakage in data mining: Formulation, detection, and avoidance*, *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, art. 15, 2012.
- [5] M. Roberts et al., *Common pitfalls and recommendations for using machine learning to detect and prognosticate for COVID-19 using chest radiographs and CT scans*, *Nature Machine Intelligence*, vol. 3, pp. 199–217, 2021.
- [6] A. Fabijanska, M. Danek, and J. Barniak, *Wood species automatic identification from wood core images with a residual convolutional neural network*, *Computers and Electronics in Agriculture*, vol. 181, art. 105941, 2021.
- [7] J. Deng, J. Guo, N. Xue, and S. Zafeiriou, *ArcFace: Additive angular margin loss for deep face recognition*, in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition*, 2019, pp. 4690–4699.
- [8] X. Wang, X. Han, W. Huang, D. Dong, and M. R. Scott, *Multi-similarity loss with general pair weighting for deep metric learning*, in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition*, 2019, pp. 5022–5030.
- [9] Y. Sun, Y. Cheng, Y. Zhang, C. Zhang, L. Wei, Z. Wang, and Y. Liu, *Circle loss: A unified perspective of pair similarity optimization*, in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition*, 2020, pp. 6398–6407.
- [10] P. Khosla et al., *Supervised contrastive learning*, in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 18661–18673.
- [11] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, *A simple framework for contrastive learning of visual representations*, in *Proc. International Conference on Machine Learning*, 2020, pp. 1597–1607.
- [12] J.-B. Grill et al., *Bootstrap your own latent: A new approach to self-supervised learning*, in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 21271–21284.
- [13] X. Chen and K. He, *Exploring simple Siamese representation learning*, in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition*, 2021, pp. 15750–15758.
- [14] J. Zbontar et al., *Barlow Twins: Self-supervised learning via redundancy reduction*, in *Proc. International Conference on Machine Learning*, 2021, pp. 12310–12320.
- [15] Z. Liu et al., *A ConvNet for the 2020s*, in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition*, 2022, pp. 11976–11986.
- [16] M. Tan and Q. Le, *EfficientNetV2: Smaller models and faster training*, in *Proc. International Conference on Machine Learning*, 2021, pp. 10096–10106.
- [17] Z. Liu et al., *Swin Transformer: Hierarchical vision transformer using shifted windows*, in *Proc. IEEE/CVF International Conference on Computer Vision*, 2021, pp. 10012–10022.
- [18] L. van der Maaten and G. Hinton, *Visualizing data using t-SNE*, *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.
- [19] R. R. Selvaraju et al., *Grad-CAM: Visual explanations from deep networks via gradient-based localization*, in *Proc. IEEE International Conference on Computer Vision*, 2017, pp. 618–626.